Bachelor Thesis

Proactive AI moderation for goal-oriented remote meetings: Design and acceptance of a context-sensitive system to support convergent decision-making processes
Bachelor thesis in the department of Computer Science by Oliver Hönig
Date of submission: 22.10.2026

1. Review: Prof. Dr. Jan Gugenheimer
2. Review: Yanni Mei
Darmstadt



TECHNISCHE UNIVERSITÄT DARMSTADT

Computer Science Department

HCI

Human Computer Interaction

Note on the Use of Artificial Intelligence

AI applications were used to edit the language of this work. The content, argumentation, and academic evaluation were developed independently by the author.

AI applications were used to assist with research in the preparation of this work. The academic review, selection, and classification of the content were carried out by the author.

AI-based programming tools were used to assist in the implementation of the prototype. This was done in consultation with the supervising examiners.

Since English is not the author's native language, DeepL [1] was used in some places to translate sections of German text written by the author into English.

Zusammenfassung

Abstract

Contents

1 Introduction **1**
- 1.1 General Problem and Relevance . . . 1
- 1.2 Research Objectives and Questions . . . 2
  - 1.2.1 RQ1: Facilitating strategies and challenges in goal-oriented remote meetings . . . 3
  - 1.2.2 RQ2: Design requirements for an AI-based moderation system . . . 4
  - 1.2.3 RQ3: Perception of the meeting with a proactive AI moderator . . . 4

2 Theoretical Foundations **5**
- 2.1 Remote Meetings (RQ1) . . . 5
  - 2.1.1 Meetings in Modern Work: Trends and Context . . . 6
  - 2.1.2 Key challenges: Off-topic discussions, unequal participation, lack of structure . . . 6
- 2.2 Facilitation and Convergent Group Decision-Making (RQ1) . . . 7
  - 2.2.1 Group Support Systems and collaboration tools . . . 7
  - 2.2.2 The facilitator role . . . 9
  - 2.2.3 Divergent and Convergent Thinking in Meetings . . . 10
  - 2.2.4 Biases in information exchange (Hidden profiles) . . . 10
- 2.3 AI in Meeting Support Systems (RQ2) . . . 13
  - 2.3.1 Overview of existing Meeting AI Tools . . . 13
  - 2.3.2 Research Approaches to AI-Supported Meeting-Systems . . . 14
  - 2.3.3 Interaction Paradigms in Human-AI Systems: Reactive, Proactive, and Mixed-Initiative . . . 14
  - 2.3.4 Proactive AI-Interactions: From Turn-Taking to intrinsic Motivation with the Inner Thoughts Framework . . . 14
- 2.4 LLM-based AI-Systems and Agents in General (RQ2) . . . 15
  - 2.4.1 Prompt Engineering and Context Engineering . . . 16
  - 2.4.2 Building blocks for LLM-based Workflows and Agents . . . 18

2.4.3 Evaluating and Testing of AI-Systems . . . 23

3 Empirical Analysis of Facilitating Strategies (RQ1 & RQ2) 26
3.1 Methodology: Expert Interviews . . . 26
3.1.1 Sampling: Purposeful selection of 3 facilitating experts . . . 28
3.1.2 Data Collection: Conduction of semi-structured interviews (30 min) 28
3.1.3 Analysis: Thematic coding . . . 28
3.2 Results: Facilitating Strategies and Challenges . . . 29
3.2.1 Comparison with literature (Chapter 2) . . . 29
3.3 Implications for AI System Design . . . 29
3.3.1 Derived requirements for RQ2 . . . 29

4 System Design and Implementation of a Scoped Prototype (RQ2) 30
4.1 Requirements Analysis and Scoped Requirements Catalog for the Prototype (User Stories) . . . 31
4.2 Prototype Development . . . 36
4.2.1 Evaluation-Driven Development: Formative Prototype Evaluation during Development . . . 36
4.2.2 System Architecture: Adapted version of the “Inner Thoughts” framework . . . 39
4.2.3 Components: Transcription, Analysis, and Intervention Modules . . 43
4.2.4 Technology Stack: Facilitation Agent Runtime and Meeting Client . 50
4.2.5 UX und UI of Meeting Client . . . 50
4.3 Limitations of the Prototype . . . 51

5 Empirical Prototype Validation (RQ2 & RQ3) 53
5.1 Methodology: Hidden-Profile Scenario and Questionnaire Instrument . . . 53
5.1.1 Study Design . . . 53
5.1.2 Sample . . . 55
5.1.3 Data Collection . . . 55
5.2 Results . . . 55
5.2.1 Observed Intervention Dynamics . . . 55
5.2.2 Perceived Meeting Quality (Davison Instrument) . . . 55
5.2.3 Participants’ Perception of the Proactive AI Moderator’s Interventions 59
5.3 Discussion . . . 60
5.3.1 Identified Key Challenges and Potentials . . . 61
5.3.2 Lessons Learned: Implications for similar System Designs . . . 63

6 Conclusion **66**
6.1 Summary of Findings 66
6.2 Limitations 66
6.3 Future Work 66

7 Appendix **73**
7.1 Semi-Structured Interview Guide for Expert Interviews with Facilitators . . 74
7.2 Expected thematic clusters and coverage 78
7.3 Hidden Profile Exercise 79
7.4 FIM Scoring Prompt for Thought Evaluation 98
7.5 Articulation Prompt for Utterance Formation 108
7.6 Meeting-Success Questionnaire (Davison Instrument) 111
7.7 Codebook for the Open Questionnaire Items 116

List of Figures

1 Scope of the thesis: Primary focus and secondary focus, broken down by meeting phases – *Source: Own illustration, created with draw.io.* 3

2 Venn-Diagram: Prompt Engineering as a subset of Context Engineering – *Source: Own illustration, created with draw.io.* 17

3 AI-Building-Block:Prompt chaining: A complex task is decomposed into sequential LLM calls – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.* 19

4 AI-Building-Block:Routing: A complex task is decomposed into subtasks and routed to specialized systems – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.* 19

5 AI-Building-Block: Parallelization: Multiple tasks are processed in parallel and the results are aggregated programatically – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.* 20

6 AI-Building-Block: Orchestrator-workers: A central LLM decomposes a main task dynamically into subtasks and delegates them to a variable number of worker LLMs – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.* 21

7 AI-Building-Block: Evaluator-optimizer: A LLM generates answers, while another evaluates and optimizes them through feedback – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.* 22

8 Evaluation-driven development loop: From exploratory testing to system adaptation – *Source: Own illustration, created with draw.io.* 37

9 Langfuse: Screenshot of the Traceviewer in Langfuse that shows the trace of the AI-Facilitator processing a new conversation event. – *Source: Own screenshot, created with Langfuse.* 38

10 System Architecture: Adapted version of the “Inner Thoughts” framework – *Source: Own illustration based on ”Inner Thoughts” by Liu et al.[36], created with draw.io.* 39
11 Thought Pipeline Sequence: Sequence of the thought pipeline – *Source: Own illustration based on ”Inner Thoughts” by Liu et al.[36], created with draw.io.* 40
12 From User Story to System Decision: Graphical overview of what User Stories motivated a system design decision. – *Source: Own illustration, created with draw.io.* 43
13 Linear aging of the FIM score at three hold-times. Each panel shows the same scores $s_0 \in \{4.5, 4.7, 5.0\}$; the vertical line is t_{hold}, where a score-5 thought crosses τ. Within a panel, weaker thoughts expire sooner. Left to right, a shorter t_{hold} steepens every line. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – *Source: Own illustration, created with LaTeX and TikZ* 47
14 Cooldown factor after a thought is spoken, for $t_{\text{cool}} \in \{30, 60, 90\}$ s. Each panel compares the Hermite smoothstep with a linear ramp; the vertical line is t_{cool}, where recovery completes. The smoothstep stays flat at both ends; the linear ramp starts immediately and kinks at t_{cool}. – *Source: Own illustration, created with LaTeX and TikZ* 48
15 Weighted FIM score of a thought with $s_0 = 5$, never spoken versus spoken at $t = 12$ s. Aging uses $t_{\text{hold}} = 45$ s; cooldown uses $t_{\text{cool}} = 60$ s. Recovery restores the aged remainder; whether that remainder still exceeds τ depends on how long the thought has already lived. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – *Source: Own illustration, created with LaTeX and TikZ* 49

16 Perceived communication (Davison items C1–C4). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.* . . . 56
17 Perceived discussion quality (Davison items D1–D4). Each bar shows the share of responses on the five-point semantic differential. The marker above the scale names the unfavorable and favorable ends. Counts are illustrative. – *Source: Own illustration.* 57
18 Perceived status effects (Davison items S1–S4). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.* 57
19 Perceived teamwork (Davison items T1–T3). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.* 58

20 Estimated share of meeting time spent in serious discussion (Davison item E4). Each dot is one participant. The line spans the lowest and highest estimate in that group. The vertical mark is the group median, and the diamond is the group mean. – *Source: Own illustration.* 58
21 Perceived attributes of the proactive AI agent (items A1, A3, A6, A7, and A8). Each bar shows the share of responses on the five-point scale. Counts are illustrative. – *Source: Own illustration.* 59
22 Perceived disruption and intervention frequency of the proactive AI agent (items A2, A4a, and A4b). Each bar shows the share of responses on the five-point scale. Counts are illustrative. – *Source: Own illustration.* 59

List of Tables

4.1 Derived user stories for an AI facilitator, including acceptance criteria and references to the source chapters 32
4.2 Architectural design decisions of the adapted Inner Thoughts prototype, with rationale and pointers to the motivating chapters of this thesis. 45

7.1 Mapping from the original Intrinsic Motivation factors to the FIM heuristic, with the warrant used in this thesis. 107
7.2 Mapping from the original Inner Thoughts articulation prompt to the facilitation version, with the warrant used in this thesis. 110
7.3 Codebook for the free-text answers to questionnaire items F1 and F2. Anchor examples are quoted in the original German. 117

1 Introduction

Knowledge work now runs, to a remarkable degree, through remote meetings. Since the COVID-19 pandemic, video conferencing tools such as Zoom have moved from contingency measure to default infrastructure [2]. The medium that made distributed collaboration routine did not, however, resolve the process inside the meeting.

1.1 General Problem and Relevance

As early as the 1980s, research on Group Support Systems (GSS) identified key challenges that are still evident today in unproductive meetings: an inappropriate pace, poor meeting design, a lack of focus, a failure to reach decisions, or inefficient processes [3, p. 152].

Despite the long-standing awareness of these problems and the recognized importance of facilitation approaches, these insights still do not appear to be sufficiently implemented in practice. A negative assessment can be drawn from a study by Atlassian, in which 72% of meetings were rated as ineffective. The study identifies the same typical problems such as off-topic discussions, uneven participant engagement, and a lack of structure. [4]

One possible explanation for why these well-documented problems have nonetheless persisted, despite long-standing awareness, is the combination of inadequate training, lack of experience, and a natural resistance to change [5, p. 153].

In addition, the responsibilities of a facilitator are extremely broad and complex (see 2.2.2), and it is likely that not everyone is suited for such a role.

AI-powered meeting tools have the potential to democratize this facilitating knowledge.

Current meeting tools primarily support the preparation and follow-up of meetings. Features used during the meeting, which could be categorized under “facilitation,” are mainly reactiv or interactive. (see 2.3.1)

One reason for this is that a large body of literature suggests that AI systems in this context should primarily be designed to be interactive, and that proactive approaches are significantly more difficult to implement (see 2.3.3 and 2.3.4).

At the same time, problems arise in meetings that participants are often unaware of, such as cognitive biases, drifting off topic, or communication difficulties (see 2.1.2). In such cases participants cannot actively ask an AI system for assistance because they are not aware of the issue at that moment. Even if the system itself sends a notification, for example, via chat, it may be ignored or rationalized away. [6, ”4.4.3 Intervene”]

In the field of Human-Computer Interaction (HCI), there are some preliminary studies on AI systems in this context (see 2.3.2). However, the vast majority of these studies remain theoretical or follow an interactive or reactive interaction model. Practice-oriented systems that proactively intervene and moderate meetings via voice have barely been noted in the literature.

This work therefore focuses on convergent decision-making processes in remote meetings, that is, on group processes in which existing information and options are evaluated and synthesized into a shared outcome.

This narrow focus reflects the current state of meeting support: preparation and especially follow-up are already partially covered in commercial meeting tools (see 2.3.1), and for divergent practices (such as brainstorming), there are relatively well-established AI approaches. [TODO: Cite sources] In the convergent phase, key GSS problems such as a lack of focus, failure to reach a conclusion, and distorted information exchange persist. Since participants are often unaware of these issues, a purely interactive design falls short here. Therefore, this work investigates how an AI system can proactively facilitate during this phase to support the participants.

1.2 Research Objectives and Questions

This thesis investigates support during a goal-oriented remote meeting, and it narrows that investigation to the convergent phase: when a group must evaluate existing options, remain aligned with a stated objective, and move toward a joint decision. Within that scope, the work asks how a proactive, context-sensitive AI moderator can intervene while the meeting is still running, especially where participants may not necessarily be aware that something is not going ideally or is even counterproductive.

The research problem gets addressed with a structured approach that integrates three complementary research objectives. This bridges the gap between theoretical facilitation techniques and a practically applicable AI-supported prototype. This prototype integrates a system proposal that builds upon existing HCI research and concretizes it through features derived from domain-specific knowledge in the field of facilitation. The result is a functional system that can be further evaluated and is intended to serve as a basis for further iterations or as a source of inspiration for similar systems.

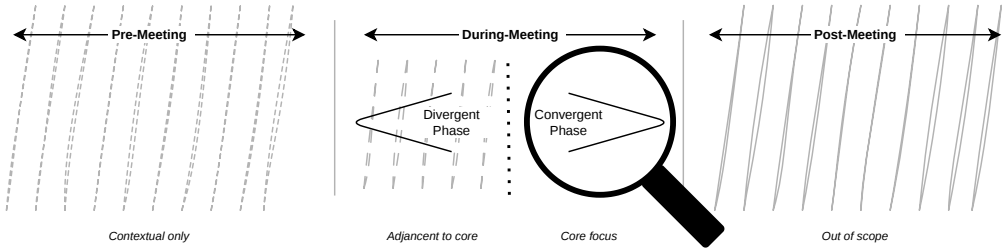


Figure 1: Scope of the thesis: Primary focus and secondary focus, broken down by meeting phases – *Source: Own illustration, created with draw.io.*

1.2.1 RQ1: Facilitating strategies and challenges in goal-oriented remote meetings

> *Which facilitating strategies are suitable for the goal-oriented management of remote meetings with convergent objectives (such as decision-making, prioritization, problem-solving)? What specific challenges typically arise in this context?*

The first research question aims to identify effective strategies for managing convergent remote meetings, such as decision-making, prioritization, and problem-solving, while also analyzing the specific challenges that arise. To achieve this, the thesis conducts expert interviews with certified facilitators, agile coaches, and team leads to gather empirical insights. It also analyzes literature on facilitation techniques, including timeboxing and role assignment, as well as the dynamics of remote collaboration. The findings are compared with existing research to derive best practices and identify pain points, such as off-topic discussions and unequal participation, which AI could potentially address.

1.2.2 RQ2: Design requirements for an AI-based moderation system

> *Which of the challenges identified in RQ1 can be addressed by an AI-based moderation system during a goal-oriented remote meeting with convergent objectives, and how should such a system be designed to intervene in a context-sensitive way?*

The second research question asks which of the challenges identified in RQ1 can be addressed by an AI-based moderation system during a goal-oriented remote meeting with convergent objectives, and how such a system should be designed. Rather than presupposing a single failure mode, the thesis first maps the problem space from the expert interviews and the literature, then assesses which challenges are both technically addressable and most promising for delivering added value. From this selection, functional and non-functional requirements for a proactive, context-sensitive moderator are derived. Because a system that attempts to address every facilitation problem at once would not be evaluable, the subsequent prototype isolates one high-impact, measurable sub-problem as a proof of concept for the following evaluation.

1.2.3 RQ3: Perception of the meeting with a proactive AI moderator

> *How do knowledge workers perceive a goal-oriented remote meeting with convergent objectives in which a proactive AI moderator intervenes, with regard to communication, quality of discussion, status effects, teamwork, and efficiency, and how do they experience the agent's contributions?*

The third research question investigates how knowledge workers experience a convergent remote meeting that is supported by the prototype. The evaluation uses a hidden-profile hiring simulation in which relevant information is distributed asymmetrically, so that a well-founded group decision depends on sharing unique information. Meeting outcomes are measured with the questionnaire instrument revalidated by Davison, covering communication, quality of discussion, status effects, teamwork, and efficiency. Because that instrument was developed for earlier group support systems, additional items address how participants experience the agent's interventions, including timing, disruption, context-appropriateness, frequency, acceptance of unsolicited speech, whether unique information was brought into the discussion, and whether the remarks were face-saving.

2 Theoretical Foundations

This chapter presents the theoretical foundations and the current state of research. These form the basis for the subsequent work. Based on a systematic literature review, five key challenges in the context of meetings were identified (2.1.2). These serve as the starting point for the in-depth analysis in the following expert interviews (see Chapter 3) and provide indicators of what to focus on during the subsequent requirements gathering process (see Chapter 4.1).

2.1 Remote Meetings (RQ1)

Definition Meeting (Abgrenzung zu WS und Meetings -> Eigentlich das gleiche)

Was sind remote Meetings?

Einige ARbeiten definieren Meetings als ein ziel oder outcome-gerichtet interaction zwischen zwei oder mehr Leuten. [3, p. 148] Eine schwachstelle dieser Definition ist, dass viel treffen die als Meetings verstanden werden , beretis an der annahme der definition scheitern ziel orientiert zu sein. [TODO Quelle]

Aus den experten Interviews mit Facilitatoren von Hughes und Roy [7] lässt sich ableiten, dass in physischen Treffen Facilitatoren leichter eine gemeinseme ”energetische Präsenz” aufbauen udn Momente der Spannung im Raum leicher halten können. aus diesen würden oft die eigentlichen ”Aha-Momente” und kreativen Druchbrüche entstehen. Im remote Kontext sei es schwer diese Spannung aufrechtzuerhalten, da man sich physich distanziert fühle und oft ”bild” für die feinen emotionalen Schwingungen der anderen sei. [7, ”5.5 Unstructured Expert Interviews”]

2.1.1 Meetings in Modern Work: Trends and Context

The Doolde Report ”State of Meetings 2023” finds that 40% of meetings are scheduled 1–4 weeks in advance (55% in North America). In contrast, the Mirsooft report reveals that most meetings (57%) are ad hoc, without formal invitations. [8]

Welche Arten von Meetings gibt es?

2.1.2 Key challenges: Off-topic discussions, unequal participation, lack of structure

A clear issue with goal-oriented meetings is the absence or unclear communication of objectives. It seems plausible that a significant number of meetings are scheduled without a defined goal or agenda (as discussed in section 2.1.1). A lack of structure in meetings is therefore one of the key challenges. While an agenda can serve as the foundation for such structure, it alone does not guarantee a successful meeting. Meeting goals are often dynamic and may need to be adjusted as the meeting progresses, due to the associated uncertainties [9, chap 4.1]. Although the agenda can outline a path to achieving the overall meeting goal [10, chap 2.1], without linked sub-goals, it guarantees neither the success of the meeting nor a timely conclusion. [9, chap 4.1] Discussions can nevertheless get out of hand if participants do no know what to priorities. [9, chap 4.1] An agenda was identified by many respondents (67%) as a key element for successful meetings in Doodle's State of Meetings Report 2019. Only the setting of clear meeting objectives (72%) was cited even more frequently. [11, p. 11]

Based on this, the following summary challenge statement was derived:

> **Challenge 1: Clear goal-setting and structure.** Goal-oriented meetings frequently lack clearly communicated objectives and a reliable structure, so that discussions lose focus and the meeting neither succeeds nor concludes on time.

Chen et al. noted, as a secondary finding, that individuals in higher hierarchical positions tended to intervene more frequently and maintain focus on meeting objectives when a clear list of goals was provided. Conversely, those in lower hierarchical positions felt less obligated to intervene, even when they observed deviations from the main topic. [9] Doodle's Stat of Meetings Report 2019 identified a correlation between salary and self-perceived participation in meetings. Respondents with higher salaries were more likely to

describe themselves as active participants. [11, p. 6] This may stem from inexperience, hierarchical constraints, group dynamics, or a lack of error culture, where dissent risks loss of face. Low participation can narrow solution spaces, yield monotonous outcomes, and reduce meeting effectiveness.

Dysfunctional communication—such as complaining, criticizing, and digressing—reduces effectiveness. [12, p. 130]

-> Unausgeglichen / geringe participation -> Unvorhergesehen veränderungen im Meeting (flasch Annahmen, meetingziel ändert sich) -> technische Probleme: Instablie internetverbindungen, Störungen etc. (nicht im scope dieser arbeit aber dennoch relevant)

Graph der zeigt das sich diese challanges alle gegenseitig beiflussen könnnen. (z.B. wenn nicht nicht alle ansichten geührt wurde, kann es später dazu kommen das wenn man eigentlich eien entscheidung treffen möchte (convergent thinking) wieder zurück in divergent htink fällt, was zu zirkuläeren diskussionen führen kann.)

Umgekert, kann ein zulanges verweilen in der coonvergnen zone dazuführen, dass kein entshciedung getroffen wird und kein fortschirtt wahrgenommen wird.

temkultur und hierarchie beinfluss ebenfalls die offen tielnehmer ideen teilen und wer welche ideen wie bewertet.

2.2 Facilitation and Convergent Group Decision-Making (RQ1)

Rechreche was sind eingelich die aufgaben eines Facilitators? was macht ein facilitator?

Welche rolle spielen collaborations tools wie white boards (Google Jamboard, Miro, etc.) in der facilitation?

2.2.1 Group Support Systems and collaboration tools

Recherechen zu Group Support systeme begannen in den 1980er jahren mit den stetigen herausfoderungen von komplexerwerten problmen die in organsiation oft in gruppen / Teams gelöst werden müssen. [13, p. 628]

Laut Akerman waren die Anfänge in diesem Forschungsbereich durch eine starke Fragmentierung geprägt. Verschiedene Forschungsteams arbeiteten unabhängig voneinander und

ohne Abstimmung an überlappenden Themen. Dies führte dazu, dass es kein standardisiertes Vorgehen gab und sich unterschiedliche Bezeichnungen für dasselbe Forschungsgebiet etablierten, wie etwa „Meeting Support Systems“, „Computer-Supported Cooperative Work Systems“, „Group Support Systems“ oder „Group Decision Support Systems“ (GDSS). [13, p.628f] Das übergeordnete Ziel besteht allerdgins darin, Meetings sowohl in Bezug auf ihre Ergebnisqualität als auch auf ihre Prozessstruktur zu optimieren. [13, p.629]

Hierbei kommen oft computerunterstützte tools zum Einsatz. So definierte Huber [14, p. 195]:

> ”GDSS consists of a set of software, hardware, and language components and procedures that support a group of people engaged in a decision-related meeting.”

Klassische und initiale Group Support Systems (GSS) variieren stark in ihrer Komplexität und ihrer Funktionalität.

TODO: Quellen ergänzen Einige Systeme ermöglichen es Teilnehmenden, simultan und anonym Textbeiträge einzugeben, um elektronisches Brainstorming, Kriterienanalysen oder Priorisierungsabstimmungen durchzuführen. Ein Beispiel hierfür ist GroupSystems (später als ThinkTank bekannt, vermutlich basierend auf Plexsys) [13, p.634]. Andere, strukturorientierte Ansätze setzen auf qualitative Methoden wie das Causal Mapping, um komplexe Problemstellungen als visuelle Ursache-Wirkungs-Netzwerke abzubilden. Ein Vertreter dieser Kategorie ist der Group Explorer (ehemals COPE bzw. Decision Explorer) [4][5]. Darüber hinaus nutzen einige Systeme quantitative Multi-Kriterien-Entscheidungsanalysen (MCDA), bei denen Handlungsalternativen anhand mathematisch gewichteter Kriterien bewertet werden. Hierzu zählen etwa MeetingWorks oder Decision Conferencing [6]. Ergänzend dazu strukturieren weitere Ansätze unübersichtliche Debatten mithilfe des Issue-Based Information System (IBIS). Dabei werden Beiträge systematisch in Kernfragen, Lösungsoptionen sowie Pro- und Contra-Argumente unterteilt, wie es etwa beim Dialogue Mapping der Fall ist [9][10].

Um diese unterschiedlichen Systemfunktionen in verlässliche, wiederholbare Interaktionsmuster zu überführen, wurden schließlich **ThinkLets** als standardisierte Moderationsbausteine entwickelt[11].

Moderne Tools wie Miro, Conceptboard oder Figma Jam, die als digitale Whiteboard-Lösungen klassifiziert werden können, greifen einige dieser ursprünglichen Methoden auf und verbinden sie mit den Möglichkeiten modernern Technologien das disitrubiteve zusammenarbeiten ermöglihct. Integirerte KI-basierter Systeme, erweitern diese Tools

durch smarte funktionen wie z.B. die automatische bundlung von Ideen durch KI zu Themenclustern oder die Anreicherung von Ideen durch KI-generierte Vorschläge.

Zudem gibt es diverse sammlungen an Übungen, Methodne und Tools inkluse anweisungen zur Druchführung und Hilfestellungen worauf zu achten ist, welche für verschiende Gruppensituationen und Herausfoderungen in meetings geeigent sind wie z.B.:

- Liberating Structures (LS): A collection of methods and tools for facilitation.
- 9 Spaces: A framework for facilitation.
- SessionLab Libary: SessionLab ist ein Tools zum erstellen von Workshop agendas. Es gibt eine von der Community gepflegt Libary in der viele Methoden geteilt werden.
- TODO: add more and add Foodnotes for each item

2.2.2 The facilitator role

Bereits in den Anfängen der GSS-Forschung (Group Support Systems) wiesen Beranek et al. darauf hin, dass GSS allein die Effektivität einer Sitzung vermutlich nicht gewährleisten können. Vielmehr hängt der Erfolg maßgeblich davon ab wie diese Systeme genutzt werden würden. [3, p. 147] Hierbei würde die Qualität der Gruppensitzung maßgeblich von dem Facilitators abhängen. [3, p.146]

Im deutschsprachigen Kontext wird der Begriff „Facilitator“ häufig mit „Moderator“ übersetzt. Diese Gleichsetzung ist jedoch unzureichend, da die Rollen unterschiedliche Schwerpunkte aufweisen: Während ein Moderator primär die Steuerung einer Sitzung übernimmt, zielt die Tätigkeit eines Facilitators auf die prozessuale und inhaltliche Unterstützung der Gruppe ab. Die Rolle des Facilitators umfasst zwar moderierende Elemente, geht jedoch darüber hinaus

According to Haney, researchers in the 1990s agreed that facilitation is a combination of “(1)managing relationships between people, tasks and technology, (2) structuring tasks, and (3) contributing to the effective accomplishment of the meeting outcomes.” [5, p. 73]

In his book ”The Skilled Facilitator”, regarded as a standard work in the field, organizational psychologist Roger Schwarz defines the term “Facilitator” as follows: ([15] as cited in [16] & [17, p.9]):

> ”Group facilitation is a process in which a person who is acceptable to all members of a group, substantively neutral, and has no decision making authority, intervenes to help a group improve the way it identifies and solves problems, and makes decisions, in order to increase the group’s effectiveness.”

2.2.3 Divergent and Convergent Thinking in Meetings

Divergent thinking is the process of generating new ideas and concepts [TODO: QUELLE]. Convergent thinking is the process of evaluating and selecting the best ideas from a set of options. [TODO: QUELLE]

According to Anne Manning, generating new ideas and evaluating them are two fundamentally different processes. However, she says that in meetings, people often try to carry out both steps at the same time. [18, min 02:30] Immediately evaluating and weighing an idea hinders the creative process of generating ideas.

A predominance of divergent thinking without sufficient integration of convergent thought processes can lead to unreflective and excessive modifications. [19] Corply [19] further argues that both a lack and an excess of convergent or divergent thinking have adverse effects on creativity.

In the context of facilitation, the terms ”Convergence Zone / Phase” and ”Divergence Zone / Phase” are widely recognized. A recurring framework in this domain is the group process map, developed by facilitator Sam Kaner, commonly referred to as ”Diamond of Participatory Decision-Making” or ”Kaner’s Diamond”. [20] Kaner’s Diamond model describes typical phases that groups go through in the decision-making process. The left side represents the Divergent Zone, where diverse perspectives are expressed and disagreements are explored. The right side embodies the Convergent Zone, where opinions align and the process moves toward closure. At the center of the Diamond lies the ”Groan Zone”, a transitional phase where the tension between divergence and convergence often manifests.

TODO: add figure of Kaner’s Diamond

2.2.4 Biases in information exchange (Hidden profiles)

Diese Arbeit geht von der Hypothese aus, dass ein proaktives Meeting-Supporsystem insbesondere dort eine Lücke schließen kann, wo die Gruppe ihre eigene Ineffizienz nicht

erkennt. Ein interaktives System setzt voraus, dass Teilnehmende ein Problem bemerken und um Unterstützung bitten. Genau das entfällt, wenn der Prozess subjektiv reibungslos wirkt, obwohl er systematisch verzerrt ist.

Typischerweise liegt diese Unbewusstheit bei Biases vor, etwa Confirmation Bias, Groupthink, Authority Bias, Halo-Effekt, Anchoring oder Status-Quo-Bias, um nur ein paar zu nennen. Nicht alle diese Verzerrungen greifen jedoch am selben Punkt an. Authority Bias oder Halo-Effekt betreffen vor allem, wessen Beitrag oder welcher Gesamteindruck übergewichtet wird. Confirmation Bias und Groupthink betreffen dagegen, welche Informationen überhaupt geteilt und diskutiert werden.

Für die konvergente Phase wird daher angenommen, dass zunächst vor allem der Informationsaustausch als grundlage entscheidungsrelevant ist.

Dieses Problem wird in der Literatur als Hidden-Profile-Paradigma beschreiben. In Meetings verfügen Teilnehmende typischerweise über unterschiedliche Informationen. Einen Teil kennen alle (geteilte Informationen), einen anderen Teil nur einzelne Personen (ungeteilte/private Informationen). Ein Hidden Profile liegt vor, wenn die bessere Lösung nur sichtbar wird, sobald die ungeteilten Informationen zusammengeführt werden. Gruppen diskutieren jedoch vorwiegend geteilte Informationen und ungeteilte informationen kommen zu krz oder werden nicht erwähnt. [21, 22, 23].

Confirmation Bias und Groupthink verstärken diesen blinden Fleck, weil einzigartige Informationen den bestehenden Konsens stören [23, 24]. Ohne externe Intervention bleibt die Ineffizienz unbemerkt.

Laut Verhein-Jarren et al. ist Voraussetzung für eine gute Kommunikation das Erkennen des eigenen Persönlichkeitsstils sowie das Wissen darum, dass es verschiedene Bezugswelten gibt, in denen sich die Beteiligten während des Gesprächs bewegen. Menschen neigen dazu, andere unbewusst nach eigenen Mustern zu interpretieren. Laut Verhein-Jarren et al. sei ein Durchbrechen dieses Automatismus der Wahrnehmung notwendig, um einen geteilten Bezugsrahmen zu schaffen. [25, p. 9]

Innerhlab des bleichen bezugsrahmen, kann es dann allerdgins druch aus auch zu meindugnsverscheidnheiten kommen, was nicht unbedingt schlecht ist. Schulz-Hardt et al. (2006) zeigen empirisch, dass Meinungsverschiedenheiten (Dissent) die Diskussionsintensität massiv erhöhen und die Lösungsrate des Hidden Profiles drastisch steigern. [24]

Geteilte vs. Ungeteilte Informationen: Das Hidden Profil

Ein typisches Experiment, um Entscheidungsprozesse in Gruppen zu untersuchen sieht folgendermaßen aus: Ein Team hat die Aufgabe aus unterschiedlichen BewerberInnen

den Besten oder die Beste auszuwählen. Dazu erhält jedes Team-Mitglied Informationen über die einzelnen BewerberInnen. Einen Teil der Information erhalten alle Teammitglieder. Diese Informationen sind also im Team geteilte Informationen. Einen anderen Teil der Informationen erhält jeweils nur ein Team-Mitglied. Diese Informationen sind also ungeteilt. Die Aufgabe ist nun so konstruiert, dass sich das Team nur dann für den richtigen Bewerber entscheiden kann, wenn alle Informationen – geteilte und ungeteilte – berücksichtigt werden. Werden lediglich die geteilten Informationen berücksichtigt, trifft das Team eine falsche Entscheidung.

Eine Vielzahl von Studien mit dieser oder ähnlichen Aufgaben zeigt, dass Teams meist nicht in der Lage sind, ein solches Hidden-Profile zu lösen: Geteilte Informationen werden ausgetauscht und diskutiert, ungeteilte Informationen fallen unter den Tisch. Erklärungen für das Phänomen Hidden Profil

Es gibt unterschiedliche Erklärungen dafür, warum in Gruppendiskussionen eher über geteilte Informationen gesprochen wird:

Wahrscheinlichkeit: Mehr Personen verfügen über die gleiche geteilte Information. Deshalb ist die Wahrscheinlichkeit höher, das geteilte Informationen in der Gruppe diskutiert werden, im Vergleich zu Informationen, über die nur eine einzelne Person verfügt (ungeteilte Informationen). Selbstwerterhaltung: Menschen achten darauf, ein positives Selbstwertgefühl zu erhalten. Wird eine geteilte Information der Gruppe mitgeteilt, werden andere Personen in der Gruppe dieser Information zustimmen, bei ungeteilten Informationen steigt die Gefahr, kritisiert zu werden. Das gefährdet ein positives Selbstwertgefühl, weshalb eher ohnehin schon geteilte Informationen der Gruppe mitgeteilt werden. Group Think: Jedes Gruppenmitglied hat das Bedürfnis, sich der Meinung der Gruppe anzuschließen. Die Gruppe als Ganzes strebt nach Konsens. Das kann dazu führen, dass kritische oder widersprüchliche Informationen nicht ausreichend berücksichtigt werden.

Lösungsstrategien für das Hidden Profil

Die Forschung zu Hidden-Profiles basiert auf eher künstlichen Gruppensituationen. Dennoch lassen sich aus den Ergebnissen Strategien ableiten, Gruppenentscheidungen zu verbessen.

Effekt kennen: Wer die Anfälligkeit von Gruppen kennt, ungeteilte Informationen zu vernachlässigen, kann gezielt gegensteuern. Eine Möglichkeit ist z. B. nachzufragen, ob alle Informationen berücksichtigt wurden, oder ob es Informationen gibt, die nicht ins Bild passen. Expertise transparent machen: In einer heterogenen Gruppe hilft es, die unterschiedlichen Fach- und Wissensgebiete der einzelnen Mitglieder transparent zu

machen. So wird klar, dass unterschiedliches Wissen und unterschiedliche Meinungen zu erwarten sind. Technische Unterstützung: Technische Werkzeuge, die Informationen visualisieren oder strukturieren, helfen insbesondere bei komplexen Entscheidungen, alle Informationen zu berücksichtigen. Erst suchen, dann bewerten: Eine weitere Strategie ist es, das Sammeln und das Bewerten von Informationen als zwei Prozesse voneinander zu trennen. So wird verhindert, dass Informationen, die wichtig sein könnten, direkt abgewertet werden. Hierarchien vermeiden: Oft teilen insbesondere Mitglieder mit niedrigem Status ihr ungeteiltes Wissen nicht, wohingegen geteiltes Wissen, dass Mitglieder mit hohem Status eingebracht haben, detailliert diskutiert wird. Eine Lösungsstrategie ist deshalb, dass sich die Gruppenleitung oder Mitglieder mit hohem Status zunächst mit einer eigenen Bewertung zurückhalten.

2.3 AI in Meeting Support Systems (RQ2)

In addition to the fundamentals of Group Support Systems (GSS) outlined in subsection 2.2.1, modern approaches specifically designed for meeting support systems can be identified, some of which are supplemented by functions that are more or less supported by AI. This chapter analyzes these systems to identify potential gaps and to serve as a source of inspiration for the development of the prototype.

2.3.1 Overview of existing Meeting AI Tools

There is a wide variety of AI-based tools that provide support for meetings. Most of these tools focus on transcribing meeting content. Well-known examples include fireflies.ai [26], Otter.ai [27], and Jamie [28]. AI transcription features are also integrated into established meeting platforms such as Google Meet [29], Zoom [30], and Microsoft Teams. [31] More advanced features include the automatic extraction of action items. Depending on the tool, these features are available in real time or only after the meeting has ended. Microsoft Teams specifically offers a feature called “Facilitator,” [32] which provides additional capabilities beyond the features already mentioned (transcription, identification of action items): For example, it can edit the agenda if instructed to do so by a user with the appropriate permissions. It also displays a timeline to track topics and the flow of the meeting, and sends reminders to manage time. (Once halfway through the meeting and again shortly before it ends.) These interactions take place via the integrated chat. Google Meet, for example, also offers a live speech translation feature. [33]

Nevertheless, contemporary meeting platforms remain primarily technical infrastructures for conducting meetings. Their design does not systematically account for the professional knowledge, needs, and methodological repertoire of facilitators [7], nor are they conceived to support the range of tools, methods, practices, and techniques on which facilitation typically relies. The potential of these platforms to systematically support facilitation has therefore not yet been fully realized. For users inexperienced in facilitation, the platforms likewise provide little scaffolding or procedural guidance that would help them orient their actions and guard against fundamental process errors.

2.3.2 Research Approaches to AI-Supported Meeting-Systems

in der litratur finden sich eingie arbieten welche ähnlcihe ansätze verfolgen. so haben z.B. Houtti et al. einen AI-Agent für inklusivere Meetings desingt. ihre rechere stütze sich auf einem quantitivaen design interview mit ootenzillen meeting teilneher (nciht wie in dieser arbeit mit facilitating Experten)

2.3.3 Interaction Paradigms in Human-AI Systems: Reactive, Proactive, and Mixed-Initiative

2.3.4 Proactive AI-Interactions: From Turn-Taking to intrinsic Motivation with the Inner Thoughts Framework

To reduce the need for explicit prompts, an AI agent should be able to proactively recognize when it is its turn in an interaction sequence. In dyadic human-AI interactions, pauses or so-called “stop words” are often used for this purpose to identify a change in speaker. In multi-party scenarios (e.g., group conversations), however, this becomes significantly more complex and leads to the “multi-party turn-taking problem”. [34]

Some approaches model the problem as a machine learning task by attempting to predict the next speaker based on previous speaker changes. [35] Bayer et al. employ traditional algorithms such as Maximum Likelihood Estimation (MLE) and Support Vector Machines (SVMs), as well as deep learning architectures including Convolutional Neural Networks (CNN) and Long Short-Term Memory (LSTM) networks. They distinguish two primary paradigms: agent-only models, which rely solely on speaker history, and agent-and-content models, which additionally incorporate conversational context. Both paradigms have been trained and evaluated across diverse, topic-oriented and chit-chat corpora using

these varied algorithms. The empirical findings indicate that while simple agent-only models are sufficient for small, highly focused dialogues, incorporating conversational content becomes crucial in goal- and topic-oriented interactions characterized by complex, irregular turn-taking patterns. [35, p. 2]

With these approaches, however, it remains unclear why an agent should interact at a specific point in time. Due to the design of the ML algorithms, the timing of the interaction is decoupled from its cause or is only implicitly included in the model, but cannot be explicitly explained. (Example: We know that it is now the time for the agent to interact now -> But why? Whats the reason its like that he should talk? What should he say?)

Ein naiver ansatz für Turn-taking wäre ein LLM so zu prompnten es zu fragen wer als nächstes dran ist. Liu et al. [36] haben dies überprüft und konnte ihre Hypothese bestätigen, dass diese Ansatz bei bei turn-allocation ansätzen gut funktioniert. Dies ist nahligen weil in diesem szenarien in dem chat kontext indizene liegen wer als nächstes dran ist. alle getestetn LLM Modelle hatten bei turn-acllocation eine besser vorhersagequote als bei selfallocation stellen. die vorhersagen für self allocation haben sich im rahnen einer zufälligen chance bewegt. Die Authoren schlussfolgern. Das für self-selection szenarien der konversations kontext allene nicht ausricht und noch intenre factoren dafür verantwortlich seien.

Die über die leltzten jahre stattgefunden entwicklung bei LLMs ermöglichen neue ansätze um diese Problem zu modellieren. Neus Paradgima von LLM-basierten Agentischen Systemen. Was ist das? -> Hier berscheiben was KI-Agenten sind (Anthopic definition finden und verwenden) LLM basierte AI-Agenten mit einer LLM pipelie welche intrisische gedanken simmuliert, könnte ein viel versprechender ansatz sein.

Liu et al. verfolgenden diesen Ansatz um einen procativen conversationa Agent mit inner Thoughts zu modellieren. [36]

Y verfolgen diesen ansatz um eine proaktiven Chatbot zu modellieren und schlussfolgern, dass

2.4 LLM-based AI-Systems and Agents in General (RQ2)

Um das spätere system besser klassifizieren zu können, wird hier zunächst die nomenkaltur geklärt. wie Huang beschreibt ist es schwer ein korrekte und vollständige definition von

dem Begriff AI-Agent zu geben, weil sich das Verständis darüber und die technologien dahinter schnell ändern. [37]

Zusätzlich wird der begriff aufgrund von markting interessen inflationär und inkosisten benutzt was zu einen difusen Verständnis führt. Um den begriff einzugrene wird sich hier über die abgrenzung zu programmatischen Automatiserungmethoden angenähert.

Programmatische Prozessautomatisierung bezeichnet die regelbasierte Automatisierung von Abläufen, bei der festgelegte Bedingungen und strukturierte Entscheidungslogiken genutzt werden, um Prozesse effizient, zuverlässig und wiederholbar auszuführen.

AI-Agenten haben hierbei einen höheren Grad an autonomität. während klassische software vordeinfierte instruktionen ausführt, würden ”AI Agents possess the capcitiy to initiate actions, make decision, and pursue goald without constant human intervention” [37, p. 2]

Antrhopic wählt folgende Definition für LLM-basierte Workflows und Agenten:

> ”Workflows are systems where LLMs and tools are orchestrated through pre-defined code paths. Agents, on the other hand, are systems where LLMs dynamically direct their own processes and tool usage, maintaining control over how they accomplish tasks.” [38]

2.4.1 Prompt Engineering and Context Engineering

Allgemein bezeichte Context engineering das Designen, organiseren und managen von kontexsenstiiver infromatioen, so das machienen im einklaing mit der menschlichen intention aggieren. [39, p. 3]

Obwohl das Context Engineering bereits in frühen Frameworks der Mensch-Computer-Interaktion eine Rolle spielte [39, p. 1], hat die Forschung aufgrund der wachsenden Herausforderungen in der Human-Agent-Interaction (HAI) in jüngster Zeit eine verstärkte Fokussierung auf dieses Gebiet erfahren.

Die Relevanz dafür sit begründet auf aktuellen Limitiationen (TODO Beispile), Performance Verbeserungen (TODO Beispiele) und Resroucen Optmierung.

Mei et al. (2025) haben in ihrer Meta-Studi [40] über 1.400 Forschungsarbeiten zum Thema Context Engineering für LLMs analysiert. Laut den Autoren haben sich LLMs von einfachen Systemen, die lediglich Anweisungen befolgen (sog. Prompt Engineering), zu

zentralen Schlussfolgerungsmodulen entwickelt. Dabei habe sich die Gestaltung und Verwaltung von Informationsinhalten zu einer eigenständigen Disziplin weiterentwickelt (Context Engineering) [40]

Bei LLM-basierter Systeme lässt sich Context Engineering wie folgt definieren:

> ”Context engineering is the practice of deliberately structuring and optimizing the information passed to an LLM or Agent to produce more accurate and relevant outputs.” [41, 00:34]

Damit geht Context Engineering über das klassische Prompt Engineering hinaus und umfasst erweiterte Methoden wie Retrieval-Augmented Generation (RAG), Speichersysteme, Tool-integriertes Reasoning sowie Multi-Agent-Systeme (vgl. Mei et al., 2025). [40, p. 12-26]

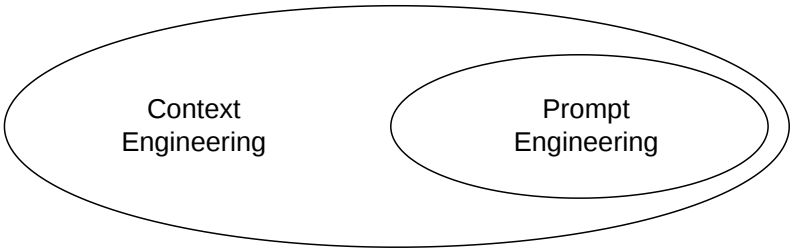


Figure 2: Venn-Diagram: Prompt Engineering as a subset of Context Engineering – *Source: Own illustration, created with draw.io.*

Obwohl in der Literatur verschiedene Methoden zum Kontext Engineering diskutiert werden, weisen Mei et al. kritisch darauf hin, dass die Praxis derzeit ohne einheitliche theoretische Grundlagen operiert. Diese Grundlagen wären notwendig, um die unterschiedlichen Techniken miteinander zu verknüpfen und prinzipienbasierte Entwurfsrichtlinien abzuleiten. Die Forschungslücke wird zudem durch das Fehlen mathematischer Rahmenwerke verstärkt, die es ermöglichen würden, optimale Entwurfsprinzipien für das Kontext Engineering in komplexen Systemen zu charakterisieren. Dies steht im Zusammenhang mit dem Mangel an Methoden zur Bestimmung der optimalen Kontextzusammensetzung. [40, p. 51]

2.4.2 Building blocks for LLM-based Workflows and Agents

Um den späteren AI-Agent zu bauen, war es notwenidg sich zunächst mit den Grundbausteinen der KI-Agenten zu beschäftigen. Antrhopic hat dies bezüglich eine Blogpost [38] veröffetnlicht welcher die Grundbauseite aus deren Sicht zusammenfasst und als Hauptgrundlage für dieses Kapitel dient.

Prompt chaining

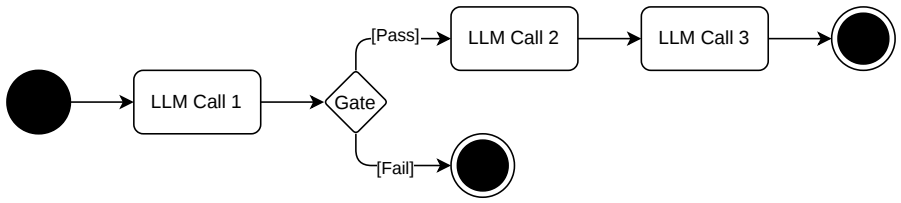


Figure 3: AI-Building-Block:Prompt chaining: A complex task is decomposed into sequential LLM calls – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.*

In prompt chaining, a complex task is broken down into a sequential series of substeps. Each step is described by a prompt and an LLM call, which uses the result of the previous step as context for the next step. Programmatic checks can be inserted in between.

Routing

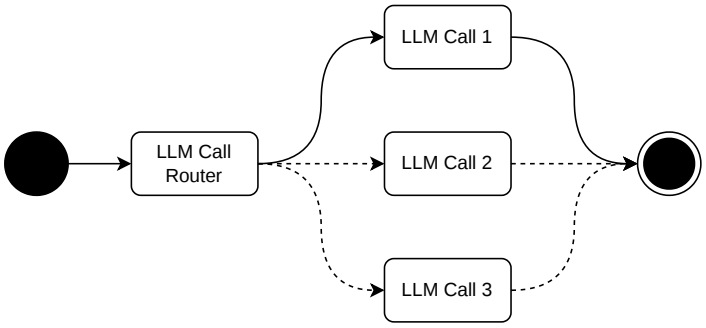


Figure 4: AI-Building-Block:Routing: A complex task is decomposed into subtasks and routed to specialized systems – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.*

Beim Routing werden aufgaben klassifiziert und an untersysteme welche auf das lösen

dieser Kategorie von aufgaben spezialisert sind weitergeleitet. Dadruch entsteht eine klare Ternnung von Verantwortlichkeiten, was besonder gut geeignet ist wenn komplexe Aufgaben in klar abgrezbare Kategoiren aufgeteilt werden können und von spezialsierten LLMs andern KI-Modelen oder Algorithmen bearbeitet werden können.

Parallelization

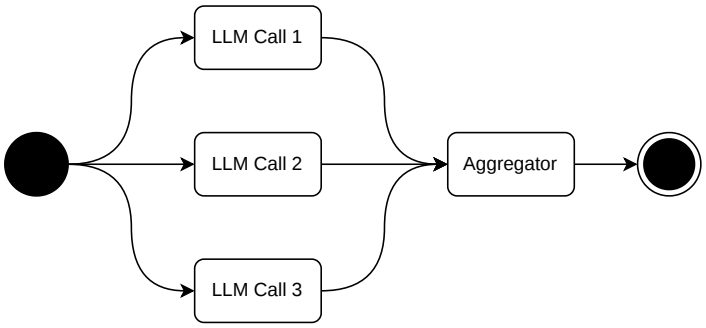


Figure 5: AI-Building-Block: Parallelization: Multiple tasks are processed in parallel and the results are aggregated programatically – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.*

Beim Parallelisierungs-Workflow werden mehrere Aufgaben gleichzeitig bearbeitet und die Ergebnisse programmatisch aggregiert. Typische Anwendungsfälle liegen vor, wenn Aufgaben in unabhängige Teilaufgaben unterteilt werden können (Segmentierung) oder wenn mehrere Perspektiven für ein zuverlässigeres Ergebnis erforderlich sind (Voting). Bei komplexen Aufgaben mit mehreren Aspekten erzielen LLMs bessere Ergebnisse, wenn jeder Aspekt durch einen separaten Aufruf mit spezialisiertem Prompt fokussiert bearbeitet wird.

Orchestrator-workers

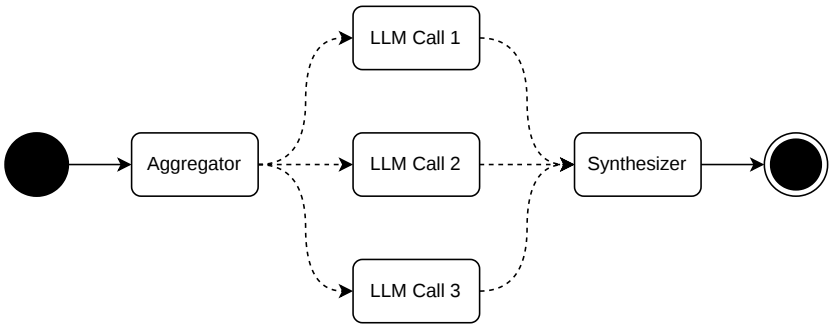


Figure 6: AI-Building-Block: Orchestrator-workers: A central LLM decomposes a main task dynamically into subtasks and delegates them to a variable number of worker LLMs – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.*

Der Orchestrator-Worker-Workflow ähnelt dem Parallelisierungs-Workflow, unterscheidet sich jedoch darin, dass er eingesetzt wird, wenn die benötigten Teilaufgaben nicht im Voraus bekannt sind. Ein zentrales LLM zerlegt die Hauptaufgabe dynamisch in Teilaufgaben und delegiert diese an eine beliebige Anzahl von Worker-LLMs, deren Ergebnisse abschließend aggregiert werden.

Evaluator-optimizer

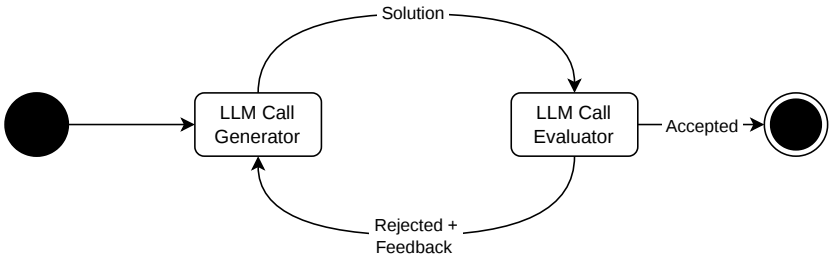


Figure 7: AI-Building-Block: Evaluator-optimizer: A LLM generates answers, while another evaluates and optimizes them through feedback – *Source: Own illustration based on "Building Effective AI Agents by Anthropic"[38], created with draw.io.*

Der Evaluator-Optimizer-Workflow nutzt eine Feedbackschleife, in der ein LLM Antworten generiert, während ein weiteres diese bewertet und durch Feedback versucht zu optimieren. Dieser Ansatz ist besonders effektiv, wenn klare Bewertungskriterien vorliegen und iterative Verbesserungen messbar sind.

Augmented LLM

Diese Workflows orientieren sich an klaren Argumentationsketten. Die Informationen folgen einem im Code prozedural gesteuerten sequenzeller Weg, während LLM-Aufrufe bewusst für entsprechende Teilaufgaben mit einer zuvor bekannten Intention stattfinden. Mit anderen Worten: Es existieren vordefinierte, klare Pfade, denen die Daten sowie die Ausgaben der LLM-Aufrufe folgen.

Bei Agenten gibt es diese kar vordefinierten prozeduralen Pfade in dem sinne nicht. Das LLM selbst wird genutzt, um zu entscheiden, welche Wege eingeschlagen werden sollen. Dies kann insbesondere bei offenen Problemen hilfreich sein, die sich nicht ohne Weiteres in einem starren Workflow abbilden lassen. Dabei wird das LLM mit verschiedenen Tools ausgestattet, und es bleibt dem Modell überlassen, ob und wann es diese Tools aufruft. Die Qualität des Gesamtoutputs hängt somit auch davon ab, wie zuverlässig das LLM das korrekte Tool auswählt. Dies abstrahiert offene Probleme in eine Struktur, in der Tool-Calling in einer Schleife stattfindet, bis das LLM selbst entscheidet, dass das gewünschte Ergebnis erreicht ist.

Diese workflows orienteirren sich an klaren Argumentationsketten. Die Infroamtionen folgen einem im code procedural gesteuretem weg und llm calls finden intentila für entsprechende unteraufgaben mmit einer vorher bekannt intention zu einem squenziall beaknten zeitrahmen statt. Anders ausgerdück gibt es vordefinierte klare Wege, welche die Daten und die outputs der LLM-Calls folgen.

Folgt man der Definition von Athropic werden diese klaren vordefinierten entfernt und ein LLM wird genutzt um selbst zu entscheiden, welche wege eingeschalagen werden. Dies kann besonders offene Problme hilfreich sein, die nicht einfach in einem Workflow eingefangen werden können. Hierbei wird ein LLM mit verscheinde Tools ausgestattet und es dem llm wird überlassen ob es dieses Tool aufrufen wird. Die Qualtiät des gesamt outputs häng somti auch damit zusammen wie zuverlässig dass LLM das korrekte Tool aufruft. Dies abstrahiert somit offene Problme in eine struktur in der Tool-Calling in a Loop stattfinde, bis das LLM selbst entscheiden, wann das gewünsche ergbeniss erreicht ist.

Wrokflos Desing lassen smoit granularer Kontroole zu, während Agents etwas losgelöster aggieren können.

2.4.3 Evaluating and Testing of AI-Systems

Auf Grund des propablistischen Charakters von KI-basierten Systmen unterscheidet sich das testen von KI-basierten Systmen grundlegend von herkömmlichen Testverfahren.

Das International Software Testing Qualifications Board (ISTQB®) legt daher nahe dass dieser popalibisitsche Charakter statistische Testverfahren erfordern würde. [42, p. 39]

Eine zusätzliche Herausforderung besteht darin, dass einige KI-Systeme nicht nur statisch, sondern auch adaptiv sind und sich somit kontinuierlich anpassen können [42, p. 39].

Diese Anpassungen können mindestens auf zwei Ebenen auftreten:

- **Kontextbasierte Anpassung::** Innerhalb der Anwendung kann sich das KI-System dynamisch an veränderte Rahmenbedingungen oder die vielfältigen Möglichkeiten des zu diesem Zeitpuntk bereitgestellen Kontexts anpassen.
- **Modellbasierte Anpassung:** Unabhängig vom konkreten Kontext des Use-Cases können sich die zugrundeliegenden KI-Modelle selbst verändern, etwa durch den Einsatz selbstlernender Algorithmen. Bei der Integration externer Large Language

Models (LLMs) kann der Anbieter Modifikationen am Modell vornehmen, die für den Nutzer nicht direkt ersichtlich sind.

Die Festlegung eines Test-Orakels, also die Definition der erwarteten Ausgaben bei bestimmten Eingabewerten für das zu testende System, ist bei komplexen KI-Systemen daher extrem schwierig oder sogar unmöglich [42, p. 39].

Dies gilt auf für LLM-basierte Systeme.

Auch Mohammadi et al [43, p. 1] weisen darauf hin, dass das evaluieren und Testen von LLM-basierte Agenten ein komplexes und noch wenig erforschtes Gebiet sei, insbesondere weil Agetnten oft in einem dynamischeren und interactivem Kontext opereieren. Sie beschreiben daher das testen von LLM-Agents als zusammenspiel der verscheinen Perspektiven von Naturla Langugae Processing (NLP), human.computerinteraction (HCI) und Software engineering.

Codebasierte Methoden (engl. code-based methods) versuchen, die Leistung von KI-Systemen durch expliziten Programmcode, definierte Regeln und Testfälle mit Assertions zu überprüfen. Dabei wird geprüft, ob die ausgeführten Aktionen exakt vorgegebenen Kriterien entsprechen. [43, p. 7]

Hierfür können beispielsweise mögliche Zustände, die das System durchläuft, modelliert und anhand von Trajektorienvergleichen analysiert werden. Bestehende Benchmarking-Verfahren wie AgentBoard [44] sind jedoch oft allgemein gehalten und für domainspezieifsche Use Cases nur bedingt geeignet.

Insbesondere bei offenen oder qualitativen Antworten sowie bei kreativen Problemen, bei denen die Korrektheit subjektiv bewertet werden kann, stoßen codebasierte Verfahren an ihre Grenzen [43, p. 7].

Der LLM-as-a-Judge-Ansatz nutzt die Argumentationsfähigkeiten von LLMs, um die Antworten von Agenten anhand qualitativer Kriterien zu bewerten. Dabei werden die Antworten basierend auf den in den Anweisungen vorgegebenen Bewertungsmaßstäben analysiert. [43, p. 7].

Die Authoren Zheng et al. [45, p. 4] schalgen drei Varianten des LLM-as-a-Judge-Ansatzes vor, die einzeln oder kombiniert angewendet werden können:

- Pairwise Comparison: Ein LLM vergleicht zwei Antworten auf eine Frage und entscheidet, welche besser ist oder ob ein Unentschieden vorliegt.
- Single Answer Grading: Ein LLM bewertet eine einzelne Antwort direkt anhand einer Skala oder eines Kriterienkatalogs.

- Reference-Guided Grading: Ein LLM bewertet eine Antwort im Vergleich zu einer vorgegebenen Referenzlösung, z. B. bei mathematischen Aufgaben.

Im Anhang des Papers „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena“ finden sich entsprechende Prompts, die für die verschiedenen Varianten des LLM-as-a-Judge-Ansatzes verwendet werden können [45].

Laut Mohammadi et al. gilt jedoch nach wie vor die Human-in-the-Loop-Evaluierung als Goldstandard, bei der Menschen (etwa in Nutzerstudien, Expertenaudits oder durch Crowdworker) die Ausgaben annotieren oder bewerten [43, p. 7]. Dieser Ansatz ist jedoch oft schwer skalierbar und mit hohem Aufwand sowie Kosten verbunden.

Ein weitverbreiteter Ansatz ist Evaluation-Driven Development (EDD), bei dem KI-basierte Systeme und Agenten während der Entwicklungsphase kontinuierlich evaluiert werden, um Abweichungen zu erkennen und neue Use Cases zu identifizieren [43, p. 6].

3 Empirical Analysis of Facilitating Strategies (RQ1 & RQ2)

3.1 Methodology: Expert Interviews

Wie in den theorischen Grundlagen beschreiben, hat die Interaktion innerhlab von Meetings viele sehr untershciedlcihe Factten und ebneen (psychologische Effekte, persänlichkeitsmerkmale, Kommunikation) Kommunkiation im allgeminen zwichen verschiendne Menschen. Über Remotemmeting und mit einem KI-Agent etnsteht noch eine zusätzliche ebene der Computer Human interaktion. Um diese Kompexität einzufangen sollen eine qunatitiaven Studie gezielt für diese Arbeit relevanten informationen erheben. Es bestand die hoffung die komplexität diese zusammenspiels auf wesentliche Merkmale und Erkenntnis zu reduzieren. Hauuptziel der interviws war es somit den Übergang von der allgmeien recherche bezüglihc meeting über die hinzunhame der konkreten praixs erfarhung hinzu relevaten Features für einen KI-Agenten zu schaffen.

Semi-structured expert interviews were chosen as the method. This type of interview allows for in-depth insights into the respondents' perspectives through open-ended questions and flexible follow-ups, while at the same time ensuring a thematic focus through a guide.

Expert interviews are particularly suitable because experts, through their specialized knowledge and practical experience, provide efficient access to specific areas of knowledge [46, p. 877]. The definition of an expert is context-dependent and must be determined on a case-by-case basis depending on the research topic [46, p. 877]. In this study, only individuals with verifiable professional experience in the field of facilitation and who are professionally active in this context were interviewed. Therefore, the interviews conducted can be classified as semi-structured expert interviews.

Letzlich ist zu erwarten, dass das der Protpy stellenweise daruaf abziel eine facilitator zu emulieren. Facilitatoren wenden das ”What / When / Who” Framewokr aus [Quelle], welches zum Desing von KI-Systemem von X empfohlen wird per Defintion ihrer Jobbeschrebigung bereits an. Eine beobachtung aus dieser Praxis stellt somit eine erweiterte Perspetkive zur Literatur dar.

Es wurde sich auch dazu entschieden Fragen dazu zustellen, wei sich facilitatoren ein solches KI-gestüztes system vorstellen würden. Man könnte kritisieren, dass Facilitaotren hierfür keine experten sind und es somit zu spekulativen uninformierten antowrten kommt, da ihnen die technischen möglichkeiten und limitierungen ki-gestützer systme nciht bewusst sind. Allerdings sind die fragen so gestellt das der Facilitaotr die verhaltensweisen und eigenschaften diese systems beschreiben kann, wozu dieser qualifiziert ist. ohne über detailwissen zu der technsischen implementation verfügen zu müssen. (vgl. Annahnd Frage x.X) Zustätzlich wurde in Houtti et al. mit Meeting teilnehmden ein co-host design, wie sich meeeting teinnehmedne ein socheles system wünschen. Hier wird nun eine andere Prespektive geboten. Ein user-cetnric desing interivew hätte frü diese pespektive vermutlich einen bilden Fleck, weil standard meeting teinmehnden nicht wissen welche methodkien und facilitating ansaätz zum einsatz kommen und somit auch kein System diebezüglich designen werden, welches eben jene methodiken und ansaätze berücksichtigt. (Wissen von dem sie nciht wissen, dass sie es nicht wissen)

Sowohl die Reihenfolge der unterschiedlichen Abschnitte als auch der Fragen innerhalb der Abschnitte orientieren sich an einer Struktu die vom allgmeinen zum spezieifschen vorgeht. Es handelt sich um offengestellte Fragen. Desweitern sind die fragen so gestellt um verhlatensbezogene anker zu triggern um den befrageten zurugen wie er sich in vergangen situation verhalten hat. [Quelle auch ”The mum test”] (Aussagen sind verlössiger wenn man frage wie wurde das isher gelöst, anstatt wie lässt sich das lösen)

Es hat ein Probe-interview mit einem anderen Studneten stattgefunden, um die allgemeine verständlichekti der frage zu prüfen und den groben zeitrahne zu prüfen. Da der Stunde allerdings fachfemd war wurde, ein weiter druchlauf mit CHatGPT druchgeführt. Dabei warude chat gpt als facilitating experte gepromtent und wusste, dass nun ein Experteninterview simulliert wird. Auch diese interview hatte lediglich das ziel den Fragebogen zu testen und zielte nicht auf einen erkentnnissgewinn abseites dessen ab. [Quelle das es best-practice ist einen probelauf zu machen]

3.1.1 Sampling: Purposeful selection of 3 facilitating experts

Für diese Studie wurden 5 Experten befragt.

3.1.2 Data Collection: Conduction of semi-structured interviews (30 min)

Wann wurden die interviews geführt? Inwlechne zeitraum? Es wurden nie mehr als 2 Interviews pro Tag gefürht. Es gab einen Interviewer, nämlich den Author dieser Arbeit. Abwohl die Interviews leicht variert haben, haben diese im schnitt ca. 30min gedauert. Die interviews haben über Zoom stattgefunden udn wurden, um diese später besser zu transiciribere aufgezeichnet. Jedes interview startet mit einer kurzen Einleitung in der erklärut wrude, was der zweck des interivews it, wofür die Datenerhoben werden und wie diese verarbeitet werden. Anschließened wurde die Intervieweten gefragt, ob diese mit dieser Verarbeitung und insbesondere der Aufnahme einverstnaden sind. Dem haben alle zugestimmt.

Zu beginn bereits kontext zu liefern, hat dabei geholfen klar einzuordnen worum es in dem Interview gehen soll.

Through these measures and also through the choice of the interview channel, a certain closeness could be created, which is helpful in obtaining the views and opinions of the interviewee 31 (Meyen et al., 2019).

Nach dem das interview beednet wurde, wurden sich direkt notzien gemacht und erste gedanken, festzuhalten währende die eindrück nach den interviews noch frisch waren.

3.1.3 Analysis: Thematic coding

Deductive Coding cann miss out on valuable insights. While inductive coding is better for investigated new ideas or conepts. Da allerdings bereits eine Literature recherche vorrausgesetllt wurde, besteht zumindest ein verständnis darüber, welche Themenkomplexe in den interviews zu ewarten sind bzw. welche explizit abgedenkt werden sollen um genauere informationen von den experten zu erlagnen. Aus diesem grund wurde ein Kategoriserungssystem basierend auf den literaturrecherchen erstellt. Und daruf hin wurde im anschlus allerdings eine inductives conding der interview ergebnisse druchg eführt. dieser ansatz sollte es ermöglichen einenklaren Rehmen für die Interviews zu schaffen

aber dennoch offengenug zu sein um neue, noch nicht in der Rechereche identizifierte informationen aufnhemen zu können.

Somit wurde ein hybrider conding ansatz gewühlt. bei dem die codes iterativs verreinert wurden. Auch die überkategoreien wurden dann im nach gang weiterfereinert.

3.2 Results: Facilitating Strategies and Challenges

3.2.1 Comparison with literature (Chapter 2)

3.3 Implications for AI System Design

3.3.1 Derived requirements for RQ2

4 System Design and Implementation of a Scoped Prototype (RQ2)

The preceding chapters established a broad problem space: goal-oriented remote meetings are affected by a wide range of facilitation challenges, ranging from off-topic drift and unequal participation to the biased exchange of information described by the hidden-profile paradigm (see the theoretical foundations and the empirical analysis of facilitating strategies in RQ1). RQ2 asks how an AI-based moderation system can be designed to counter such challenges through proactive, context-sensitive interventions.

Translating the requirements derived in RQ1 into a concrete, buildable artifact made this tension explicit. It became apparent during the design process that a system attempting to address the full breadth of divergent-phase facilitation problems at once would not be evaluable: with many interacting intervention mechanisms active simultaneously, any observed effect on meeting quality could no longer be attributed to a specific design decision.

A broad, feature-complete system would thus trade scientific rigor for surface plausibility. Prioritizing internal validity over coverage, the scope was therefore deliberately narrowed from a general-purpose AI facilitator to a focused proof-of-concept that isolates a single, well-defined, and theoretically grounded intervention mechanism.

Accordingly, this chapter does not claim to present a system that resolves every problem arising in the divergent phase of a meeting. Instead, the prototype targets one specific sub-problem that was identified as both high-impact and measurable in the theoretical foundation and the expert interviews: the shared-information bias underlying hidden profiles and the closely related issue of unequal participation.

Accordingly, this chapter does not claim to present a system that resolves every problem arising in the divergent phase of a meeting. Instead, the prototype targets one specific sub-problem that was identified as both high-impact and measurable in the theoretical

foundation and the expert interviews: the shared-information bias underlying hidden profiles and the closely related issue of unequal participation. To address it, the prototype implements a single proactive intervention mechanism — an adapted version of the "Inner Thoughts" framework, extended by an External Stimulus Injection layer — rather than a comprehensive suite of facilitation features. This deliberate reduction is precisely what makes the subsequent evaluation (RQ3) feasible: a bounded intervention can be tested against a controlled hidden-profile decision task, so that measured differences in meeting quality can be plausibly attributed to the artifact rather than to an uncontrolled combination of features.

This scoping decision follows a design-science understanding of prototyping, in which the artifact serves as a proof of concept for a specific mechanism and not as a production-ready system. Importantly, the narrowing of scope did not precede the design work but emerged from it: the confrontation with concrete requirements, implementation constraints, and — most decisively — the demands of a valid evaluation revealed which part of the broad design goal could be examined responsibly within this thesis. The following sections make this boundary explicit. section 4.1 distinguishes proactive from reactive designs and derives the functional and non-functional requirements; the system architecture then details the adapted "Inner Thoughts" framework as the core intervention mechanism; the prototype development reports the concrete implementation and its limitations; and the formative evaluation describes how the design was assessed iteratively during development. The facilitation challenges that were consciously left out of scope are revisited as limitations and as directions for future work.

4.1 Requirements Analysis and Scoped Requirements Catalog for the Prototype (User Stories)

Die Anforderungen werden in Form von User Stories festgehaltens Laut Ott können diese einen in Alltagssprache formulierten Software-Anforderungskatalog darstellen [47, p. 18]. Die Formulierungen orientieren sich an diesem Muster:

> "Als <Rolle>, ich möchte <Ziel/Wunsch>, um <Nutzen>." [47, p. 18]

Da die Anforderungen aus der Literatur und den Experteninterviews extrahiert wurden, sind die User Stories aus der Perspektive eines AI-Facilitators geschrieben, der zu einem möglichst guten Meeting beitragen möchte. Table 4.1 bündelt acht zentrale Stories mit stabilen IDs (US1–US8), damit spätere Design- und Scope-Entscheidungen eindeutig

darauf verweisen können. Die Begründungen verweisen auf die Abschnitte dieser Arbeit, in denen die jeweilige Herleitung bereits ausgeführt ist; primäre Literaturquellen werden dort zitiert und hier nicht wiederholt. Unter jeder Story stehen testbare Akzeptanzkriterien, die operationalisieren, wann die Anforderung als erfüllt gilt.

Table 4.1: Derived user stories for an AI facilitator, including acceptance criteria and references to the source chapters

ID	User Story	Reasoning / References
US1	Als AI-Facilitator möchte ich Ablauf und Ziel des Meetings klar machen können, damit die Gruppe einen gemeinsamen Bezugsrahmen hat und zu einer tragfähigen Entscheidung kommt.	Structuring tasks and communicating the meeting goal are core facilitation duties and a documented failure mode of goal-oriented meetings (see subsection 2.2.2; subsection 2.1.2). The expert interviews confirm that unclear purpose undermines facilitation quality (see chapter 3).
	Acceptance criteria – The agent can retrieve the stated meeting goal and intended process from its facilitation mandate and paraphrase them in one or two sentences. – At the start, or when the group loses the thread, it can restate goal and next process step without inventing a goal that was never agreed. – If the goal is missing or internally contradictory, it flags the ambiguity instead of deciding a purpose on its own.	
US2	Als AI-Facilitator möchte ich Personen, die noch wenig gesagt haben, auf rücksichtsvolle Weise in die Diskussion einladen, damit alle relevanten Stimmen gehört werden, ohne Schweigen zu stigmatisieren.	Unequal participation is a key meeting challenge and is linked to hierarchy and status (see subsection 2.1.2). Expert facilitators invite quiet members, but warn that doing so online can stigmatize or feel like control (see chapter 3).
	Acceptance criteria – Speaking-time shares are available as an external cue, so prolonged silence of a relevant participant can be detected. – The invitation is face-saving (short, optional, addressed by name) and does not expose monitoring as blame (“you have not said anything”). – The same person is not re-invited in a short window after a declined or unanswered invitation.	

Table 4.1: Derived user stories for an AI facilitator (continued).

ID	User Story	Reasoning / References
US3	Als AI-Facilitator möchte ich gezielt nach noch nicht genannten oder nicht ins Bild passenden Informationen fragen, damit ungeteiltes Wissen in die Entscheidung einfließen kann.	Groups systematically under-discuss unshared information; asking for information that does not yet fit the picture is a documented counter-strategy (see subsection 2.2.4). The interviews describe the same practice of checking whether all relevant voices and facts are on the table (see chapter 3).
	Acceptance criteria – When the discussion recycles already shared points, the agent may ask whether information has not yet been mentioned or does not fit the emerging picture. – It does not introduce unique facts of its own about the decision alternatives. – The prompt is directed at the group or at a named holder of potentially unique information, not at pushing a preferred option.	
US4	Als AI-Facilitator möchte ich Meinungsverschiedenheiten nicht vorschnell auflösen, damit Dissent den Informationsaustausch vertieft und bessere Alternativen sichtbar bleiben.	Dissent improves hidden-profile solution rates; rushing through the Groan Zone closes that information search too early (see subsection 2.2.4; subsection 2.2.3). Interviewed facilitators likewise open first, then converge (see chapter 3).
	Acceptance criteria – While two or more positions are still being explored, the agent does not propose a premature consensus, vote, or majority close. – It may invite a missing or dissenting view, but it does not evaluate which side is correct. – Disagreement is treated as process information, not as a conflict to be extinguished.	

Table 4.1: Derived user stories for an AI facilitator (continued).

ID	User Story	Reasoning / References
US5	Als AI-Facilitator möchte ich nur sparsam und mit klarem Prozessnutzen eingreifen, damit die menschliche Diskussion nicht übersteuert wird.	A facilitator is substantively neutral and must not dominate the group (see subsection 2.2.2). Fully automatic or overly frequent intervention produces mistrust (see subsection 2.3.2; subsection 2.3.3). Experts warn against over-facilitation and a missing sense of presence (see chapter 3).
	Acceptance criteria – An utterance is spoken only if a thought passes a facilitation-motivation threshold; casual filler is not spoken. – Each intervention is one short facilitation act (at most one or two sentences). – Immediately after speaking, repetition of the same move is suppressed for a cooldown period.	
US6	Als AI-Facilitator möchte ich thematische Abweichungen und Zeitdruck erkennen und die Gruppe zurück zur Agenda führen, damit das Meeting rechtzeitig zu einem Abschluss kommt.	Lack of focus, off-topic talk, and failure to reach a decision are long-standing GSS problems (see subsection 2.1.2). Timekeeping and agenda-keeping were named in the interviews as a particularly useful AI contribution (see chapter 3).
	Acceptance criteria – The agent can compare the current topic and elapsed time against the stated agenda. – When the group drifts or overruns, it offers a brief process check (“shall we return to …?”), rather than cutting speakers off as a referee. – It does not skip remaining agenda items on its own authority.	

Table 4.1: Derived user stories for an AI facilitator (continued).

ID	User Story	Reasoning / References
US7	Als AI-Facilitator möchte ich den Diskussionsstand zusammenfassen und Entscheidungsoptionen sichtbar machen, damit die Gruppe aus der entstehenden Komplexität nächste Schritte ableiten kann.	Sense-making, clustering, and a meta-view in the convergent phase are established facilitation and GSS practices (see subsection 2.2.1; subsection 2.2.3). Making the live meeting state visible has also been evaluated positively in related AI probes (see subsection 2.3.2). Experts see fast summarization as the strongest concrete AI benefit (see chapter 3).
	Acceptance criteria – At a convergent moment, or when asked, the agent can restate the options and candidate next steps in a short summary. – The summary is offered as a check ("have I understood this correctly?"), not as a decision. – The agent does not add new options of its own unless the group asks for a process suggestion.	
US8	Als AI-Facilitator möchte ich inhaltlich neutral bleiben und selbst keine Entscheidung treffen, damit die Gruppe die Verantwortung für das Ergebnis behält.	The facilitator is acceptable to the group, substantively neutral, and has no decision-making authority (see subsection 2.2.2). Interviewed facilitators invite leadership to interpret, but do not decide in the group's place (see chapter 3).
	Acceptance criteria – The agent never ranks, scores, or recommends a decision alternative. – It may invite a designated decision-owner to interpret what was heard; it never casts a vote or declares an outcome. – Facilitation memory stores the mandate, criteria, and process knowledge, not personal preferences about the options under discussion.	

Für den Prototyp werden daraus bewusst nur die Stories priorisiert, die Hidden Profiles und ungleiche Beteiligung betreffen: US2, US3, US4, US5 und US8. US1 ist nur insoweit relevant, als das Ziel im Facilitation-Mandat vorliegt. US6 und US7 bleiben wünschenswert, liegen aber außerhalb des evaluierten Interventionsmechanismus.

4.2 Prototype Development

4.2.1 Evaluation-Driven Development: Formative Prototype Evaluation during Development

Die Entwicklung des Prototyps folgte dem Evaluation-Driven Development (EDD) Ansatz (vgl. subsection 4.2.1). Dabei kamen bereits während der Implementierung automatisierte Prüfverfahren zum Einsatz, um das System kontinuierlich zu evaluieren.

Nutzerstudien, Human-in-the-Loop-Evaluierungen oder Expertenbewertungen waren in dieser frühen Prototyping- und Entwicklungsphase nicht praktikabel, da solche Verfahren ohne erheblichen Aufwand nicht skalierbar sind. Stattdessen erfolgte die Weiterentwicklung des Systems in kurzen Zyklen aus Implementierung, Prüfung und Anpassung. Dieses iterative Vorgehen ist in der Softwareentwicklung etabliert (vgl. [47, p. 8]) und besonders bei EDD von KI-basierter Systeme relevant, da aufgrund der vielfältigen Nutzungsmöglichkeiten hier kein vollständiges Testorakel vorausgesetzt werden kann [42, p. 39].

Für Komponenten, die nicht auf probabilistische KI-Modellausgaben angewiesen waren, sowie Unit- und Integrationstests, kamen klassische Softwaretests zum Einsatz, da sich für diese ein eindeutiges und deterministisch prüfbares Testorakel definieren ließ. Da der überwiegende Teil des zu testenden Systems jedoch auf LLM-basierte Komponenten angewiesen und somit probabilistisch ist, war dies in den meisten Fällen nicht möglich.

Deshalb wurde ein von der Methode „LLM-as-a-Judge“ inspirierter Ansatz gewählt (vgl. **??**). In der hier verwendeten Version bewertete das LLM den Output nicht in Echtzeit, sondern wurde genutzt um im Voraus Szenarien (meist mögliche Konversationen) für spezifische Situationen zu generieren, um ein lexikalisches Testorakel zu erstellen. Dieses wurde im Rahmen codebasierter (vgl. **??**) automatisierter Test, in Kombination mit regulären Ausdrücke verwendet. Das vom LLM-Judge genereierte Orakel operationalisierte, welche Formulierungen eine fachlich angemessene Facilitator-Äußerung in dem jeweiligen Szenario aufweisen muss und welche sie nicht aufweisen darf. Der Output der einzelnen Komponenten wurde überwacht und analysiert, um das Verhalten der Komponenten in den verschiedenen Szenarien besser verstehen und bewerten zu können.

Während der Entwicklung wurde das System kontinuierlich in unstrukturierten, explorativen Tests, sowohl einzeln als auch unregelmäßig mit mehreren Personen in verschiedenen, nicht weiter spezifizierten Szenarien überprüft. Ziel war es, bereits vor den

eigentlichen Nutzerstudien (vgl. chapter 5) ein Gefühl für das Systemverhalten zu entwickeln. Dadurch sollten offensichtliche Fehler sowie kritische Schwachstellen, an denen das System vom intendierten Verhalten abweicht, frühzeitig erkannt werden, um das System anzupassen.

Dieses Vorgehen kann in einem Loop wie folgt dargestellt werden:

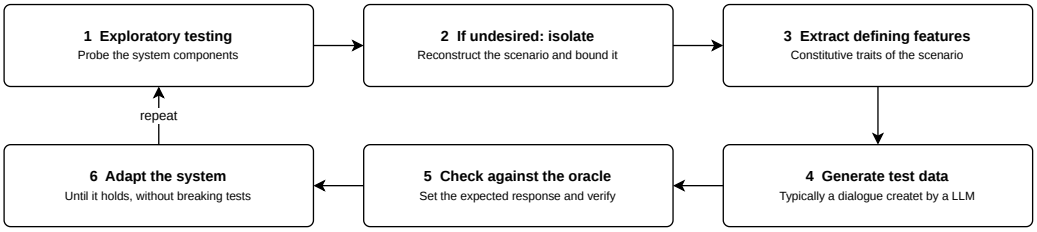


Figure 8: Evaluation-driven development loop: From exploratory testing to system adaptation – *Source: Own illustration, created with draw.io.*

Das sukzessive erweiterte Testorakel diente zugleich als Regressionstest, um zu erkennen ob eine Systemänderung zuvor gesichertes Verhalten nicht beeinträchtigt.

Zum genaueren monitoren des Systems wurde zusätzlich zu den automatisierten Tests Langfuse genutzt. Langfuse ist eine Open-Source-Plattform zur Observability und Evaluation von LLM-Anwendungen, die Trace-Level-Daten zu Modellaufrufen, Prompts und Nutzerinteraktionen erfasst und deren Analyse, Bewertung sowie kontinuierliche Optimierung ermöglicht. [**LangfuseOpenSource**]

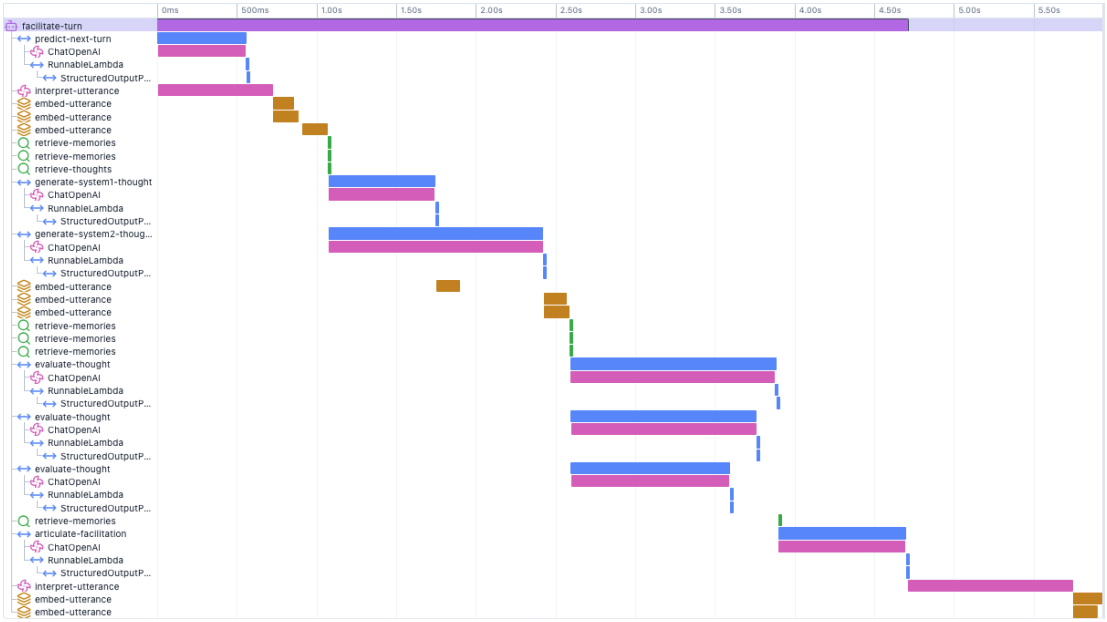


Figure 9: Langfuse: Screenshot of the Traceviewer in Langfuse that shows the trace of the AI-Facilitator processing a new conversation event. – *Source: Own screenshot, created with Langfuse.*

Limitierungen des Vorgehens

Ein lexikalisches Orakel ist unvollständig und die qualität hängt in diesem Fall von dem LLM-Judge ab. Eine gültige Facilitator-Äußerung kann das intendierte Verhalten zeigen, ohne die vorgesehenen Wortgruppen zu enthalten; umgekehrt kann ein Treffer formal korrekt und situativ unpassend sein. Isolierte Dialoge blenden zudem die Dynamik eines echten Meetings aus: Turn-Taking, Timing und die Reaktion der Gruppe auf eine Intervention bleiben unberücksichtigt. Welche Szenarien überhaupt als Testdaten aufgenommen wurden, hängt außerdem von den explorativ beobachteten Fehlern ab und ist damit autorenseitig selektiert.

Dennoch entspricht diese Kombination, von kontinuierliche, orakelgestützte Prüfung während der Implementierung und unabhängige Human-in-the-Loop-Evaluation danach (druch die User Studien), einem valider Ansatz zum prüfen von llm basierten agentischen Systemen. [43, pp. 6–7].

4.2.2 System Architecture: Adapted version of the “Inner Thoughts” framework

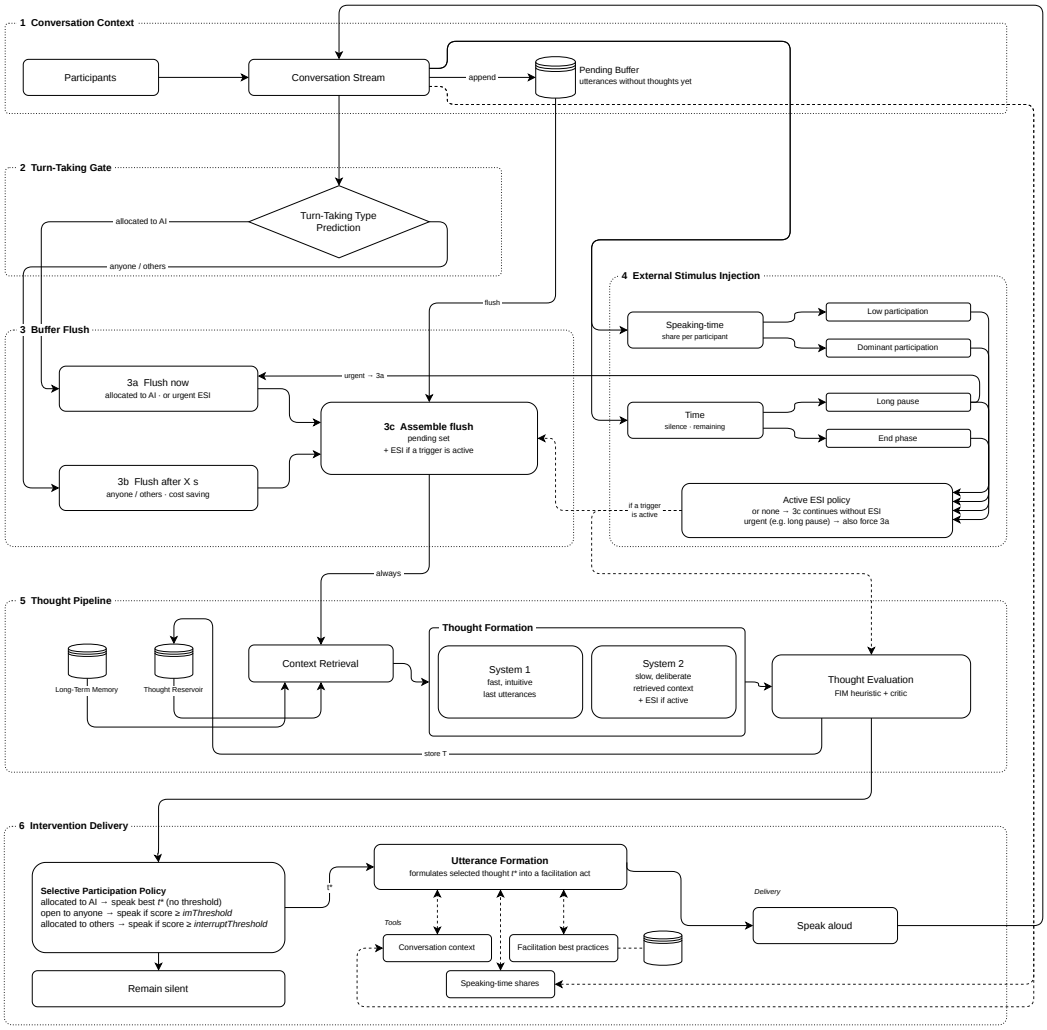


Figure 10: System Architecture: Adapted version of the “Inner Thoughts” framework – *Source: Own illustration based on ”Inner Thoughts” by Liu et al.[36], created with draw.io.*

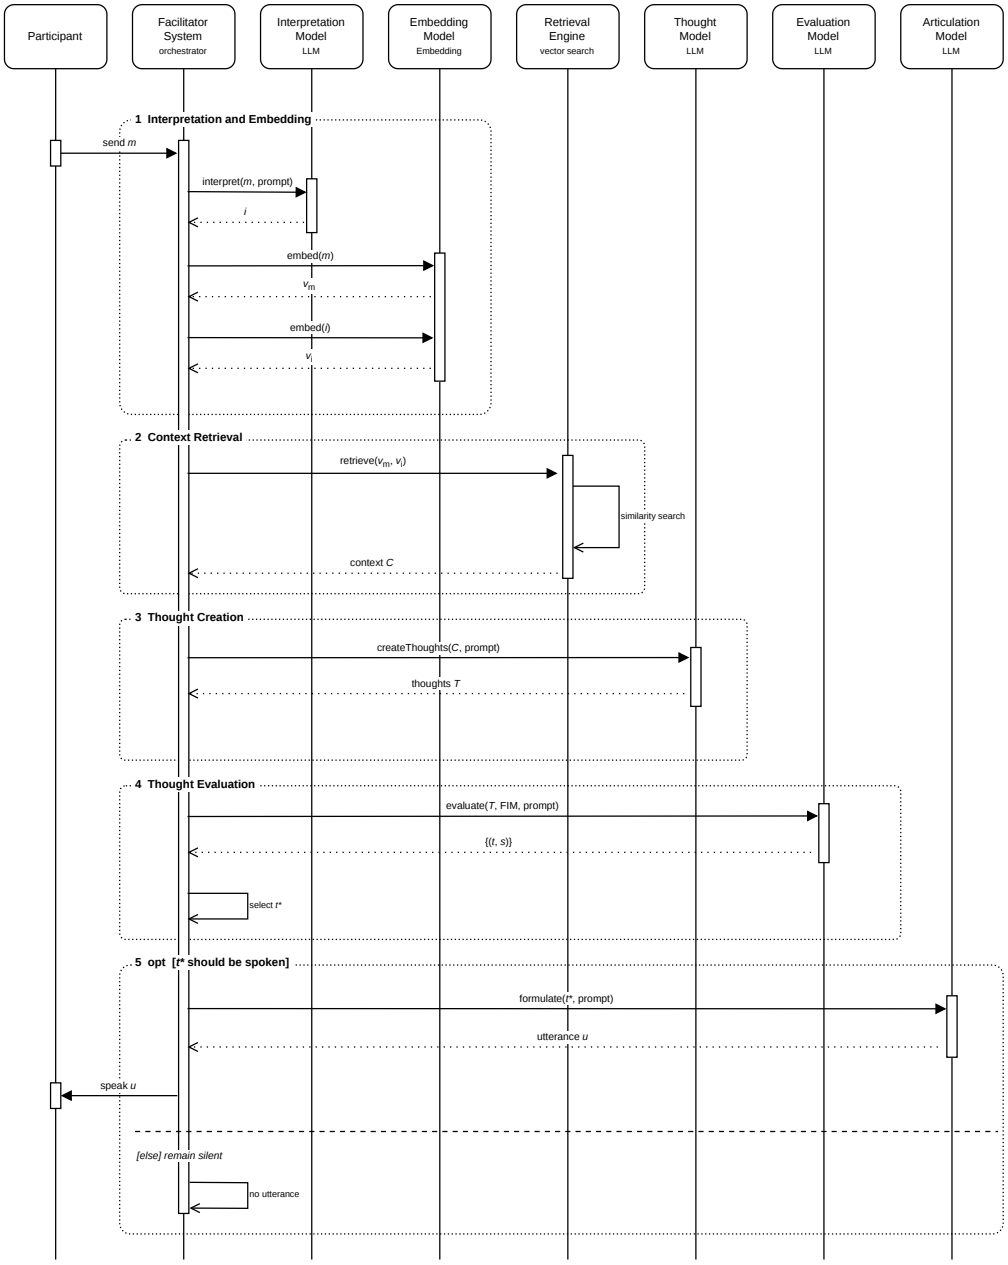


Figure 11: Thought Pipeline Sequence: Sequence of the thought pipeline – *Source: Own illustration based on "Inner Thoughts" by Liu et al.[36], created with draw.io.*

Das Inner Thoughts- Freamwork von Liu et al. ist in deren version eher für interaktionen ausgelegt die als soziales Plaudern kotegorisertet werden können. Dies ist nicht was ein Faciliator machen würde. Die Idee ein KI-System anhand einer intrsisichen motivation zu modellieren, bevor jemand etwas zu einer Gruppen discussion beiträgt, ist dennoch auch für diese ARbeit relevant. Insbesondere weil dieser Ansatz darauf hindeutet eine erhöhte Genauigkeit bei self-trun-allocation zu erzeugen. Aus den Experten ging hervor ds eine Geanken gänge, welche Facilitatoren haben auf abstakter inutionen basieren andere wiederum druchdacht kombiniert mit experten wissen etc. Dies legt nach, dass legt nahe das sowhl system 1 als auch system 2 bei dem prozess involoviert sind, was eben falls in dem Innter Thougs Framewokr berücksichtigt wird.

Die Autoren wiesen in der Diskussion der Arbeit [36, ”8.2 Apllying Inner Thougs Beyond Casual Conversations”] selbst darauf hin, dass sich das System durch anpassungen der Bewertungskriterien auf aufgabenorietnerte Kontexte anpassen lässt und zielorientiertes praktives Handeln ermöglichen kann. Sie schalgen vor für weitere arbieten das system mit domain-specifische heuristiken anzupassen, um die interaktionen an real-world tasks zu orientieren.

Im ursprünglichen Modell von Liu et al. werden generierte Gedanken primär danach bewertet, wie stark sie die ”persönliche Relevanz” die individuellen Interessen oder die einzigartigen persönlichen Kenntnisse des Agenten widerspiegeln (TODO: prüfen bzw. konkretisieren wie die heuristik tatsächlich ist). Dies mag für generische Conversationen geeigent sein, da dieser Ansatz Authentizität und Sympathie in infromellen, sozialen Unterhaltungen erhöht, ist für einen AI-Moderator in zielorientierne Meetings die durch Hidden Profile geprägt sind, allerdings ungeeiengt. Wenn die Gedanken des AI-Moderator primär danach bewertet würden, wie stark sie seinen ”persönlichen Interssen” wiederspieglen, verfällt er in dassaelber fehlerhafte Verahltensmuster, das zu verzeruung in hidden profile situationen führen kann. Er bringt eingen Meinungen oder Präferzene ein statt die diskussion neutral zu strukturieren. Strukturelle prozeduelle Gedanken würde in der aktuellen Heurisik voraussichtlich mit zu niederiger Relevanz bewertet werden.

Bei der Anpassung der Heurisitken und prompts wurden sowohl die Literatur als auch die erkentnisse aus den Interviews berücksichtigt. Die Evaluierungs-Heursitik zu bewertung der Gedanken wurde so angepasst, dass sie das kognitionspyschologsche Fundament des Innter Thoughts-Modelles (basierend auf grice, Sacks, Goffman und Berly) mit en organisationspsychologischen Prinzipien zur Kompenstation des Shared Information bias (Stasser & Titus; Brodbeck et al.) und den HCI-Richtlinen für inklusive Moderation (Houttie et al; Davison) kombiniert.

In der original Modellering des Inner Thougs-Frameworks wird ide participation in einer kovversation ausschlielich basierend der innern gedanken abgeleitet. Die Authoern mekren an, dass exteren Cues nicht im ausschleiieß zu ihrer Methode stehen sondern complentär mit exteren cues kombiniert zu einem robustern system führen könnten. [36, 8.1 Proactive Agents via Intrinsic Motivation vs. Extrinsic Cues]

Eine kernproblematik bei hidden profies ist, das private inforamtione nicht getielt werden. Ein indikator dafür könnte sein, dass eine person sich an der converstation nicht beteiligt oder ander Teilnehmden die Diskussion domieren, so dass andere nicht zu wort kommen können. wie aus den interviews hervorging, würde ein facilitator hier typischer weise versuchen diese Person auf höfliche art zu integrieen, um deren Perspektive zu hören. Hierfür wäre extern Cues wie die Sprrecheranteile relevant. Um diese exteren Cues abzubilden wurde das Inner Thoughs Framework, um die Komponete ”External Stimulus Injection” erweitert. Ist einer dieser externe Trigger erfüllt wird ein vordefinierter Gedanke in der Gedanken generierung von System 2 berügcksichtig und die Evaluations herusitik bewsust in richtung diesen extern Triggers gebaiased, um zu erzielen dass diese externe cue im innerthoughs modeel gewichtet wird.

Baseirend auf der Literatur und den Intervies wurde versucht dieses System entpsrechend zu adaptieren.

Ein prblem ist die tendenz von KI zu überkompensieren und zu viel zu sagen. Die authoren merken dies auch an und sind optimistischen, dasss ihr conversational agent hier besser performt. Alelrdigns handelt es sich um eine plausch. Ein facilitator würde nicht so oft in die Diskussion eingreifen. Das risiko für overcompensationg mit diesem system ist hoch. mit dem imThreshold kann gesteuert werden wie schwerwwiegend ein Gedanke sein muss damit die KI ihn überhaupt aussproche.

In dem Paper wurd ein Selective Participant modeliert, welche foglende Parameter hatte:

- System1 wurde auf 0 gesetzt so das die KI also niemals äußert niemals spontane, ungeplante System-1-Floskeln äußert. Jeder Beitrag muss einen teifen, kognitiven Nutzen haben. -imThreshold wurde auf 4.3 gesetzt. Ein strategeischer Gedanke muss auf einer Skala von 1-5 einen extrem hohe Bewertung erreichen, um die schwelle zu reißen. Ein einfacher Gedanke wie ”ICh könnte Bob mal wieder fragen” reicht dafür nicht aus. Es bedarf eines Phase 1 Trigger:

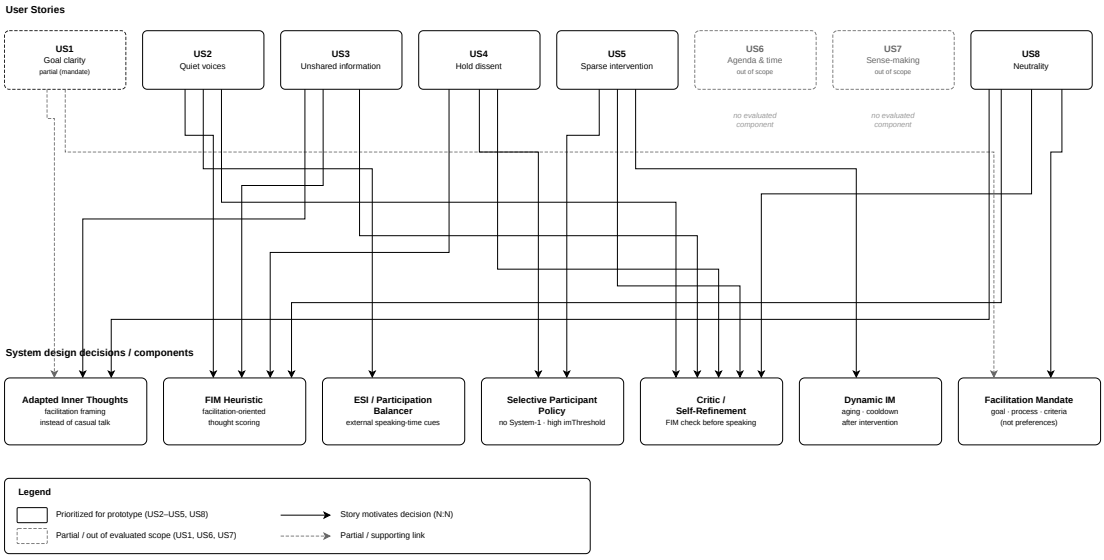


Figure 12: From User Story to System Decision: Graphical overview of what User Stories motivated a system design decision. – *Source: Own illustration, created with draw.io.*

4.2.3 Components: Transcription, Analysis, and Intervention Modules

Abgleeite aus dem Paper Keeper. Der Agent könnte auch eine visualle Warteschlage steuern. anstatt aktiv zu unterbrechen sezt ersich auf die warteschalge bzw. hebt die hand, um sich anzukündigen.

FIM-Heuristik

Thought-Evaluation

The full FIM scoring prompt, with a unit-by-unit provenance relative to the original Inner Thoughts evaluation protocol, is documented in section 7.4.

Angelengt an die Thoguht Evaluation Phase von XX (procativ Conversation Agents) wurde auch in diesem sich dem contextual self-refinement bedient. Self-Refinement und Reflexion könnnen bei LLMs zu drastischen ELsitugssteirgunen führen, wenn eine kognitive Feedbackschleife druchaufen wird. [40, p. 18] Ein Gedanke wird nicht direkt ausgesprochen, sondern druch einen Kritiker basierend auf der für diese arbeit entwicklete FIM-Heurisitk geprüft. The evaluation protocol follows the G-Eval prompt structure [48, p. 2512] similarly also used for Thoughtful Agents. Probability-weighted scoring as

proposed in the original method was omitted as a pragmatic decision, because the APIs used here do not return output-token probabilities.

In practice every utterance is appended to a shared pending buffer of messages that have not yet been thought about. The turn-taking prediction only decides *when* that buffer is flushed (immediately if the floor is allocated to the AI; otherwise after X seconds as one batch). Both cases continue to the same next step: the flushed pending set is assembled and the thought pipeline runs. External Stimulus Injection is not a later stage. Its monitors run continuously, but an ESI policy joins the pipeline only at that flush, and only if a trigger is active; otherwise the pipeline runs without it. A selected thought t^* is not spoken raw. An Utterance Formation agent formulates it into a facilitation act, with tools for conversation context, facilitation best practices, speaking-time shares, sending a chat message, or speaking aloud. The articulation prompt and the mapping from the original Inner Thoughts wording are documented in section 7.5.

Table 4.2 maps each architectural choice to a single warrant and to the chapters that already establish it, so the implementation can be traced without restating those arguments.

Table 4.2: Architectural design decisions of the adapted Inner Thoughts prototype, with rationale and pointers to the motivating chapters of this thesis.

Design decision	Rationale	Evidence
Adapt Inner Thoughts from casual talk to facilitation	The original model times utterances by intrinsic motivation, which improves self-turn-allocation in multi-party talk. Liu et al. already invite domain-specific evaluation criteria for goal-directed settings; without that shift, a facilitator would be scored as a social conversationalist.	subsection 2.3.4
Replace personal-relevance scoring with a facilitation-oriented FIM heuristic	Ranking thoughts by the agent's own interests would privilege preference talk, undervalue procedural structure, and reproduce the shared-information bias the moderator is meant to counteract.	subsection 2.2.4; chapter 3
Inject external participation cues into thought generation	Unique information stays private when speakers remain silent or are crowded out. Observable speaking-time imbalance is a complementary cue, not a rival, to intrinsic motivation; expert facilitators report inviting quiet members rather than waiting for self-selection.	subsection 2.2.4; subsection 2.1.2; chapter 3
Selective-participant policy: no System-1 speech, high *imThreshold*	Facilitation needs sparse, high-utility interventions. Unconstrained generation over-talks; disabling System-1 filler and raising the utterance threshold admits only thoughts with clear process value.	subsection 2.2.2; subsection 2.3.3
Critic-based self-refinement before any utterance	A thought is spoken only after a critic applies the FIM heuristic. Contextual self-refinement implements an evaluator–optimizer loop and is associated with substantial quality gains in LLM pipelines.	subsection 2.4.1; subsection 2.4.2
Cheap temporal reweighting instead of LLM re-scoring	Static IM speaks stale thoughts. Re-prompting every thought after each event is too slow and costly for a live meeting. Linear aging and a post-speech smoothstep keep the original score but discount age and repetition.	subsection 4.2.2

Dynamic intrinsic motivation

In the original Inner Thoughts model, intrinsic motivation is static: a thought is scored once at generation and that score never changes. Early tests during development showed that the system spoke thoughts that the subsequent discussion had already made obsolete, and that would, if they would have been evaluated again, probably no longer would have received a high FIM score given how the meeting had evolved.

Re-scoring every pending thought with an LLM after each event would restore recency, but the added latency and cost would make the system unusable in a live meeting. The prototype therefore keeps the original FIM score and applies a cheap, deterministic reweighting under two assumptions:

- A facilitation thought becomes a poorer description of the current state and process need as the conversation moves on, because later information was not available when it was scored. As the meeting continues, the group may already have closed that gap, a quiet participant may have spoken, unique information may have surfaced, or the discussion may have moved on. Therefore its priority should fall with age.
- Once a facilitation intervention has been spoken, repeating it immediately could result in over-talking and crowd the discussion. The motivation to raise the same process issue is therefore initially very low, but may recover if the group still does not take it up.

Let $S = [1, 5]$ be the FIM scale, $T = [0, \infty)$ elapsed time in seconds, and $T_\infty = [0, \infty]$ time since last speech, where ∞ means never spoken. To each triple $(s_0, t, t_{\text{spk}}) \in S \times T \times T_\infty$ the mapping s_{weighted} assigns one weighted score. Aging and cooldown address the two assumptions (see above), so they are modeled as a product:

$$s_{\text{weighted}} : \begin{cases} S \times T \times T_\infty \to [0, 5] \\ (s_0,\, t,\, t_{\text{spk}}) \mapsto \min\big(5,\, \max(0,\, s_{\text{aged}}(s_0, t) \cdot c(t_{\text{spk}}))\big). \end{cases} \tag{4.1}$$

The session-wide parameters τ, $(s_{\text{hold}}, t_{\text{hold}})$ and t_{cool} determine the kernels s_{aged} and c below.

Aging s_{aged}. Later information was not available when the thought was scored, so priority falls with age. Linear decay hits zero at a finite horizon H:

$$s_{\text{aged}} : \begin{cases} S \times T \to [0,5] \\ (s_0,\, t) \mapsto \max\bigl(0,\; s_0(1 - t/H)\bigr). \end{cases} \tag{4.2}$$

Linear decay is a practical modelling assumption: it is simple and reaches zero in finite time (Figure 13). (4.2) is the straight line from $(0, s_0)$ to $(H, 0)$, hence of slope $-s_0/H$.

The horizon H is not chosen directly. A thought of score s_{hold} should remain above τ for t_{hold} seconds, so that line must pass through (t_{hold}, τ). Equating the two expressions for the slope and solving for H gives

$$\begin{aligned} -\frac{s_{\text{hold}}}{H} &= \frac{\tau - s_{\text{hold}}}{t_{\text{hold}}}, \\ H &= \frac{t_{\text{hold}}}{1 - \tau/s_{\text{hold}}}. \end{aligned} \tag{4.3}$$

All thoughts share this H. A weaker thought therefore crosses τ sooner. The pair $(s_{\text{hold}}, t_{\text{hold}})$ is the only design knob for temporal sensitivity: a shorter t_{hold} steepens every line (Figure 13).

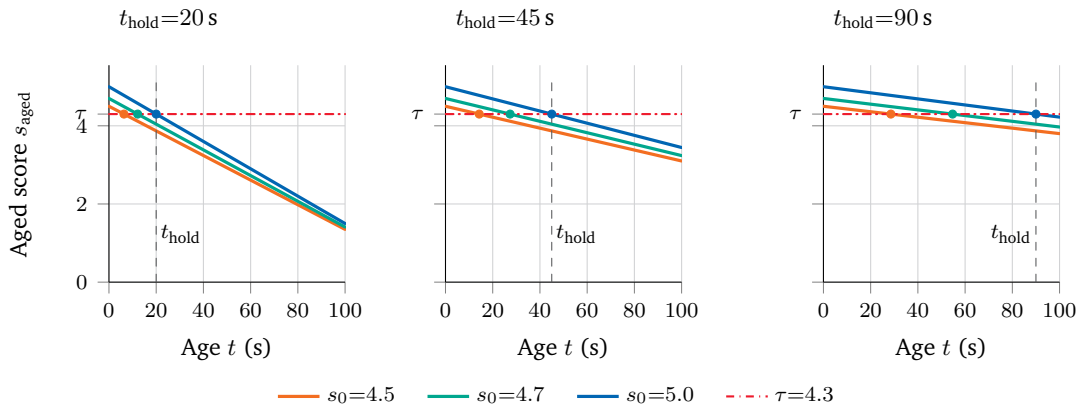


Figure 13: Linear aging of the FIM score at three hold-times. Each panel shows the same scores $s_0 \in \{4.5, 4.7, 5.0\}$; the vertical line is t_{hold}, where a score-5 thought crosses τ. Within a panel, weaker thoughts expire sooner. Left to right, a shorter t_{hold} steepens every line. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – *Source: Own illustration, created with LaTeX and TikZ*

Cooldown c. Once spoken, the motivation to repeat a facilitation intervention is initially very low, but may recover if the group still does not take the process issue up.

$$c : \begin{cases} T_\infty \to [0,1] \\ t_{\text{spk}} \mapsto \text{smoothstep}(t_{\text{spk}}/t_{\text{cool}}), \end{cases} \qquad \text{smoothstep}(x) = \begin{cases} 0 & x \le 0, \\ 3x^2 - 2x^3 & 0 < x < 1, \\ 1 & x \ge 1. \end{cases} \tag{4.4}$$

For $t_{\text{spk}} = \infty$ the quotient is ∞, hence $c(\infty) = 1$.

The cubic $3x^2 - 2x^3$ is the Hermite interpolant on $[0,1]$ with vanishing endpoint derivatives, chosen so that recovery pauses after speech and returns to 1 without a hard knee (Figure 14).

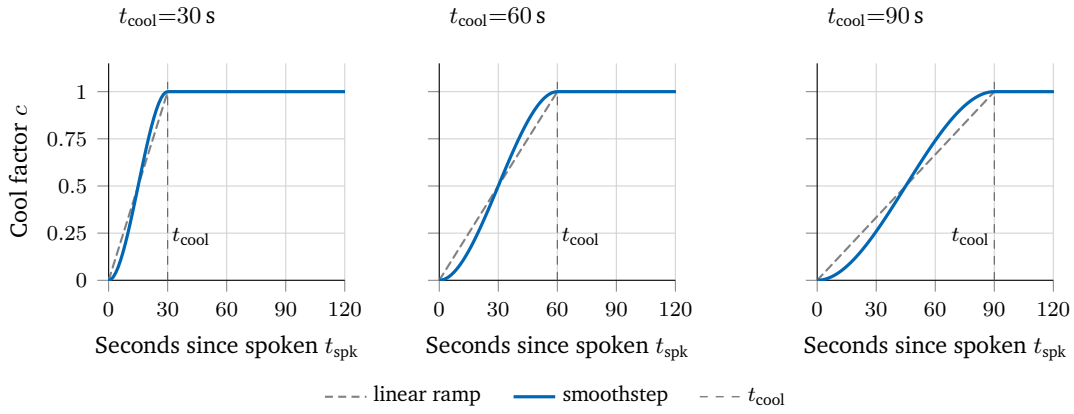


Figure 14: Cooldown factor after a thought is spoken, for $t_{\text{cool}} \in \{30, 60, 90\}$ s. Each panel compares the Hermite smoothstep with a linear ramp; the vertical line is t_{cool}, where recovery completes. The smoothstep stays flat at both ends; the linear ramp starts immediately and kinks at t_{cool}. – *Source: Own illustration, created with LaTeX and TikZ*

The product in (4.1) is the result (Figure 15). A just-spoken thought cannot be repeated. After t_{cool} it may become eligible again, but only if s_{aged} is still above τ.

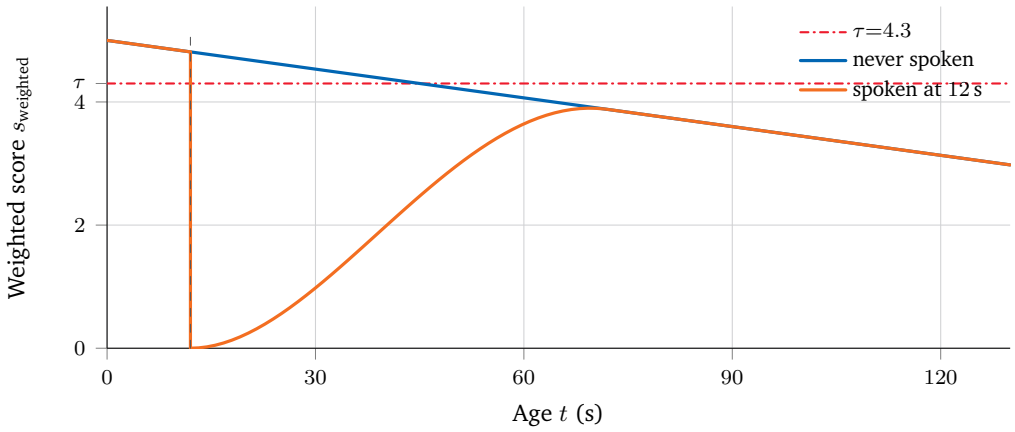


Figure 15: Weighted FIM score of a thought with $s_0 = 5$, never spoken versus spoken at $t = 12\,\text{s}$. Aging uses $t_{\text{hold}} = 45\,\text{s}$; cooldown uses $t_{\text{cool}} = 60\,\text{s}$. Recovery restores the aged remainder; whether that remainder still exceeds τ depends on how long the thought has already lived. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – *Source: Own illustration, created with LaTeX and TikZ*

Participation Balancer

The Participation Balancer operationalizes US2 as two speaking-time cues: curtailment of a dominant speaker and invitation of a low-participation participant. Unshared information in a hidden profile is introduced only by the participant who holds it, and speaking turns are unequally distributed by status, with higher-status participants intervening more frequently (subsection 2.2.4; subsection 2.1.2; [21, 23, 9, 11]). Curtailment is therefore conditioned on a high individual share together with another participant below half a fair slot, whereas invitation depends only on low share and prolonged silence.

Let $L > 0$ be the planned meeting length and P the set of participants, with $n = |P| \geq 1$. Each participant's fair slot is

$$F = L/n. \tag{4.5}$$

Let $r_i \geq 0$ be the speaking time participant i has accumulated, and let $i_\star \in P \cup \{\bot\}$ be the participant who currently holds the floor, or $\bot$ if nobody is speaking. Let $\Delta_i \geq 0$ be the time since i last spoke, counted from the start of the meeting if i has not spoken. The factor $p > 0$ is configured.

The current speaker is curtailed once their speaking time reaches p fair slots and at least one other participant is still below half a fair slot:

$$\text{curtail}(i) \iff i = i_\star \ \wedge \ r_i \geq p \cdot F \ \wedge \ \exists\, j \in P \setminus \{i\} : \ r_j < F/2. \tag{4.6}$$

Invitation uses two configured thresholds. $\theta_r > 0$ is the speaking time below which a participant still counts as low-participation, and $\theta_\Delta > 0$ is the minimum time they must have been silent since they last spoke. A participant is invited in when their own speaking time is still below θ_r, they have been silent for at least θ_Δ, and they do not hold the floor:

$$\text{integrate}(i) \iff r_i < \theta_r \ \wedge \ \Delta_i \geq \theta_\Delta \ \wedge \ i \neq i_\star. \tag{4.7}$$

4.2.4 Technology Stack: Facilitation Agent Runtime and Meeting Client

Für die Entwicklung des AI-Facilitators wurden LangChain und LangGraph als zentrale Frameworks ausgewählt. LangChain bietet eine modular aufgebaute Toolbox für die effiziente Entwicklung von LLM-basierten Anwendungen, während LangGraph die Definition und Steuerung agentenbasierter Workflows ermöglicht.

Für die Durchführung der User Study wurde eine eigens entwickelte Webanwendung eingesetzt, die als einfache Videokonferenzlösung fungiert. Diese wurde mit Svelte, SvelteKit und Tailwind CSS implementiert und auf einem Hetzner-Server gehostet. Es wurde mediasoup als WebRTC-Server und als SFU eingesetzt.

Teilnehmer:innen konnten über einen teilbaren Link direkt auf die Anwendung zugreifen. Der gewählte Ansatz ermöglichte eine direkte Analyse der Nutzerinteraktionen sowie eine optimierte User Experience (UX). Alternativ hätte die Integration über bestehende Videokonferenz-Tools (z. B. als Bot via API) in Betracht gezogen werden können. Allerdings wäre dies mit den Limitierungen der jeweiligen APIs verbunden gewesen und hätte den Lösungsraum von vornherein eingeschränkt.

4.2.5 UX und UI of Meeting Client

Dies ist nciht der Fokus dieser Arbiet, weshlab sich bei dem MeetingClinet auf bestehdne UI von bewährten Meeting Tools orienterit wrude. Es wurde ledglich deutlicher hervorgehoben, wenn die KI spricht. Hier bei wurde der gesamt hintergrund der anwedung Blau. Ein Singalto kündigte an, wenn die KI psrechen wollte oder fertig war. So gab es klare visuelle cues für den Nutzer, wann die KI spricht. Die LLM pipeline hat tielweise eine latzen von bis zu 5 Sekunden. Druch die Visuellen Cues konnte den User bereits führer singalisert werden, dass die KI bereit ist zu sprechen.

Außerdem gab wurd ein KI-Switch für sämtliche KI-Features für jeden Teilnehmende, falls es aus irgendweinem grund schnell notwendi gwar, die verbidnung zu jeglichen exteren Dienst zu kappen.

4.3 Limitations of the Prototype

Eingegrenzter Funktionsumfang

Der Prototyp ist im Funktionsumfang bewusst begrenzt und als Minimum Viable Product primär auf Hidden Profiles zugeschnitten, damit Fokus und anschließende Validierung zurechenbar bleiben (vgl. subsection 2.2.4). Diese Eingrenzung setzt voraus, dass sich das Phänomen isoliert betrachten lässt. Diese Voraussetzung ist unterkomplex: In realen Meetings überlagert sich der Shared-Information-Bias mit Status- und Hierarchieeffekten, Confirmation Bias und Groupthink sowie Zeitdruck, thematischer Abweichung und unklarer Zielsetzung (vgl. subsection 2.1.2). Dieses Zusammenwirken deckt die vorliegende Version nicht ab.

Unimodale Wahrnehmung

Das System arbeitet ausschließlich auf dem Transkript. Transkriptionsfehler, etwa bei undeutlicher Aussprache oder schlechter Mikrofonqualität, gehen direkt in den Kontext der LLM-Pipeline ein und können Gedanken und Interventionen verzerren. Prosodie (Betonung, Aussrpache Tonfall) und visuelle Signale wie Mimik, Blick und sichtbare Aufmerksamkeit oder Desinteresse fehlen. Facilitatoren nutzen jedoch genau diese Signale, um zu lesen, wie eine Aussage gemeint ist und ob jemand präsent ist (vgl. chapter 3). Eine Sentimentanalyse auf dem Audiostream wurde nicht implementiert. Das ist eine interpretative Lücke. Sie steht aber im Einklang mit den in den Interviews geäußerten Bedenken gegenüber Kontrolle und Überwachung.

Enger Funktionsumfang

Mit dem Fortschritt allgemein verfügbarer KI-Systeme sind Menschen daran gewöhnt, frei mit Sprachmodellen zu sprechen und Antworten auf beliebige Anliegen zu erwarten. Diese Erwartungshaltung kann das enge Repertoire des Prototyps übersteigen: Teilnehmende setzen Antwort- und Interaktionsmöglichkeiten voraus, die das System noch nicht bereitstellt.

Laufzeitmechanik

Die Thought-Pipeline ist mehrstufig und probabilistisch. Interventionen können deshalb verzögert eintreffen, und dieselbe Gesprächslage kann unterschiedlich ausfallen. FIM-Scores werden einmal vergeben und nur deterministisch gealtert. Sie werden nicht semantisch neu bewertet (vgl. Table 4.2.3).

Eigene Meetingplattform

Das Meeting läuft in einer eigens gebauten Webanwendung und nicht in etablierten Meetingplattformen wie z.B. Zoom oder Teams. Das sichert Kontrolle über Interaktion und UX. Jedoch sind Teilnehmende diese neue Anwendung im Gegensatz zu den bekannten Tools nicht gewohnt. Die Vergleichbarkeit mit der bekannten Nutzungssituation ist deshalb eingeschränkt.

Modifizierte Turn-Allocation-Prediction

Die Vorhersage, wer als Nächstes spricht, stützt sich auf Liu et al. [36]. Der Prompt musste jedoch von Alltagsdialogen auf den Facilitationskontext angepasst werden. Deshalb kann nicht davon ausgegangen werden, dass sich die Ergebnisse aus dem Paper 1 zu 1 auf diesen Kontext übertragen lassen. Eine genauere statistische Validierung wäre empfehlens wert, war aber mangels eines geeignene domänenspezifisches Korpus aus Facilitationssettings mit Turn-allocation Notation, nicht möglich.

Annahme gleicher Redeanteile

Der Participation Balancer setzt voraus, dass eine ausgeglichene Verteilung der Redezeit dem Meeting zuträglich ist (vgl. (4.5)). Diese Voraussetzung gilt für das evaluierte Entscheidungsformat, in dem ungeteilte Informationen nur durch Wortmeldungen in die Diskussion gelangen. Sie gilt nicht für Formate, deren Zweck eine ungleiche Redezeit ist, etwa Präsentationen oder längere Beiträge von Expertinnen und Experten. Dort würden Curtailment und Invitation auslösen, obwohl die ungleiche Verteilung beabsichtigt ist.

5 Empirical Prototype Validation (RQ2 & RQ3)

5.1 Methodology: Hidden-Profile Scenario and Questionnaire Instrument

5.1.1 Study Design

The empirical evaluation of the proactive AI assistant required a group task that resembles the convergent organizational decisions this thesis addresses and that can generate situations in which facilitation may become relevant.

Houtti et al.[6] evaluated their virtual co-host with the ”Lost at Sea” activity, in which participants rank 15 items by importance for survival after a shipwreck. They selected this task in part because it does not require equal participation and can be completed individually [6]. For the present study, these properties are a limitation. A ranking of a static, commonly known list does not require participants to pool unique information. As a result, the discussion is unlikely to produce the information-related difficulties that characterize many organizational decision meetings, and therefore few moments in which an intervention/facilitation would be necessary in order to reach a well-founded group decision.

As discussed in Chapter 2, relevant knowledge in organizational collaboration is often distributed asymmetrically across participants. An adequate solution in a convergent decision process then depends on the group recognizing, sharing, and integrating information that is initially held by only some members. Hidden-profile experiments operationalize this asymmetry.

The evaluation uses the hidden-profile hiring simulation published by Baker [23]. In this scenario, participants receive differently distributed information about three candidates, and the information that is initially shared favors a suboptimal choice. They must jointly

decide whom they consider most suitable. The task is therefore expected to elicit the interaction patterns a proactive moderator should detect: premature consensus, unique information that remains unmentioned, unbalanced participation, and a drift of the discussion towards commonly known talking points. This specific scenario was selected for three further reasons:

- **Feasibility in a remote meeting.** The task can be administered in groups of four and completed in a compact session of approximately 30 minutes. The materials can be distributed digitally, which allows the discussion to be conducted remotely.
- **Fit with the intended intervention situations.** The information structure of the task is expected to produce the patterns described above and thus occasions on which the prototype might intervene.
- **Replicability.** Baker provides the full experimental materials with the article, including role information, participant-specific information sheets, and evaluation forms, so that the scenario can be reused in the present study.

Nach einer kurzen Einleitung, haben die Teilnehmenden ihren Informationsbogen mit den stckbreifen der kandidaten erhalten. Sie hatten 10min zeit sich alles drucchzulesen und erstml zu einer individuellen entscheidung zu kommen.

Nach den 10min kamen sie in der gruppe zusammen und hatten 15-20min zeit gemeinsm zu einem ergeniss zu kommen.

Im anschluss sollten die Teilnehmden direkt einen Fragebogen ausfüllen.

Meeting success was assessed with the questionnaire instrument revalidated by Davison for the systematic measurement of meeting outcomes [49] (section 7.6). The instrument covers five dimensions: communication, quality of discussion, status effects (power structures and hierarchies), teamwork, and efficiency. These dimensions correspond to the aspects of group interaction that the hidden-profile task is intended to place under strain. And are the same dimensions the FIM-Score are based on. (see. **??**)

The technology-related items of the instrument, however, were formulated for Group Support Systems of that period, that is, for largely passive, computer-supported collaboration tools. They do not address autonomous, proactive AI agents. In addition, Houtti et al. found that participants rated meetings with their virtual co-host more positively overall, yet tended to rationalize or ignore its critical feedback [6]. Items on interaction with a proactive AI agent were therefore added (see Questionnaire Items A1-A7 in section 7.6). Free-text questions were appended after these items in order to collect qualitative accounts

of how participants experienced the agent's contributions (see Questionnaire Items F1 and F2 in section 7.6). These answers were coded with the codebook in section 7.7.

5.1.2 Sample

Die Teilnehmden waren zwishen 23 und 35 Jahre alt (Durchschnitt: 27,7 Jahre; Median: 27 Jahre). 3 der Teilnehmden waren weiblich, 9 männlich.

5.1.3 Data Collection

5.2 Results

Für die auswerung wurde unteanderem

5.2.1 Observed Intervention Dynamics

Es haben sich 3 unterschiedliche dynamiken mit dem Umgang der KI entwicklet. Gruppe eiins hat begeonnen irendwann die KI hauptsächlich zu ignorieren und während die KI gesprochen hat einfach weiter gesprochen.

Gruppe 03 war irritiert von der KI. und hat eine latenz beim denken vermuetet, weshlab sie stellen weise dazu übergegangen sind auf die KI zu warten. Insbesondere, wenn die KI eine frage gestellt hatte, schienen die Teilnehmden auf eine einordnung der KI zu warten nach dem die antowrt gegeben wurde. Nach ausbleiben der antwort ist die gruppe dann nach einer kurzen pause weider in die diskussion übergegangen.

5.2.2 Perceived Meeting Quality (Davison Instrument)

Comparison across groups

The median scores of the groups on the Likert-scale items were compared across the three user studies. Differences of less than 1.5 scale points were considered insignificant. No larger difference was found, except on three items: D2 (appropriate–inappropriate), with medians of 3 in Group 2 and 5 in Group 3; T2 (the members worked together as a

team), with medians of 5 in Group 1 and 3 in Group 3; and E2 (meeting time was used efficiently), with medians of 5 in Group 1 and 2.5 in Group 3. These discrepancies do not show that one group differed from the others across the entire Davison instrument. D2 separates Group 2 from Group 3, while T2 and E2 separate Group 1 from Group 3. On D2, Group 3 has the higher median; on T2 and E2, it has the lower one. The three gaps therefore concern different groups and point in different directions, which is why the ratings are plotted together.

Communication

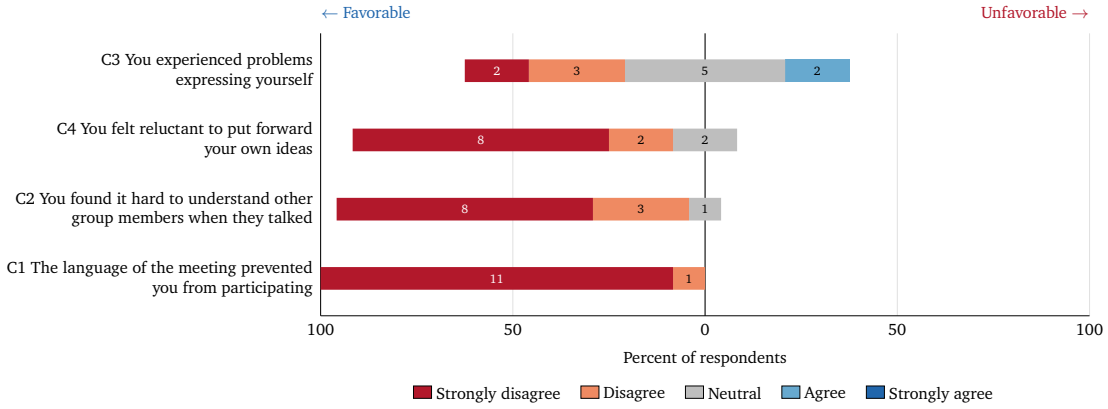


Figure 16: Perceived communication (Davison items C1–C4). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.*

Quality of discussions

With regard to all the meeting members as a whole, how would you rate the discussions in the meeting in terms of the following scales?

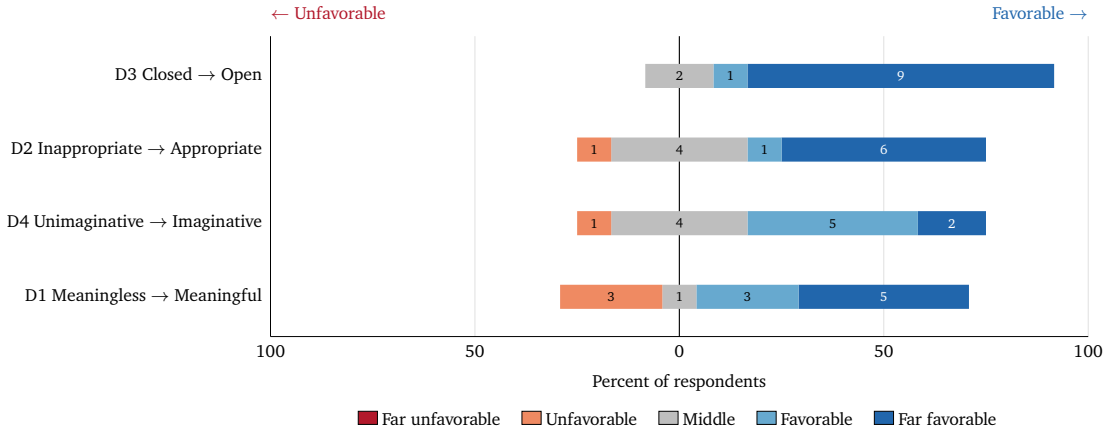


Figure 17: Perceived discussion quality (Davison items D1–D4). Each bar shows the share of responses on the five-point semantic differential. The marker above the scale names the unfavorable and favorable ends. Counts are illustrative. – *Source: Own illustration.*

Status effects

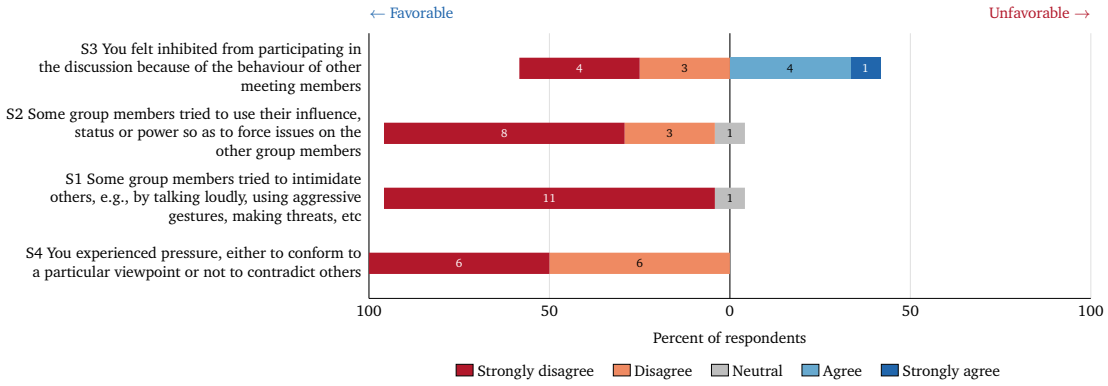


Figure 18: Perceived status effects (Davison items S1–S4). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.*

Team work

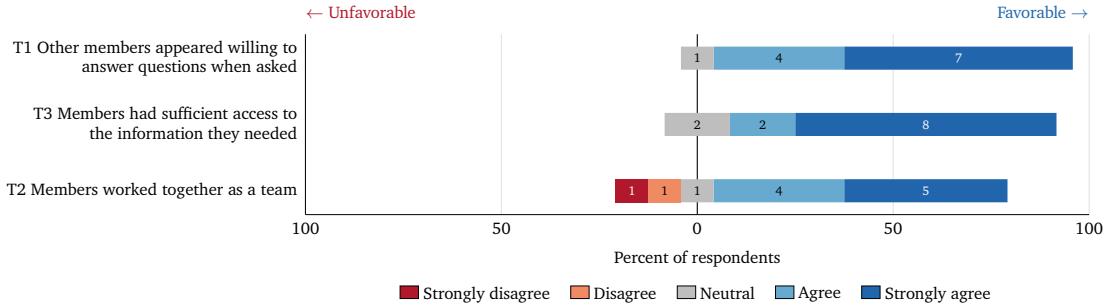


Figure 19: Perceived teamwork (Davison items T1–T3). Each bar shows the share of responses on the five-point scale. – *Source: Own illustration.*

Efficiency

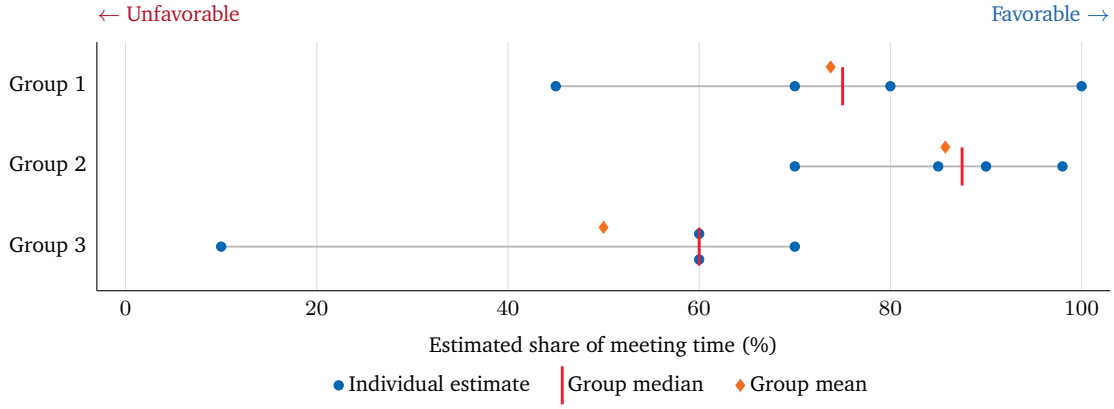


Figure 20: Estimated share of meeting time spent in serious discussion (Davison item E4). Each dot is one participant. The line spans the lowest and highest estimate in that group. The vertical mark is the group median, and the diamond is the group mean. – *Source: Own illustration.*

5.2.3 Participants' Perception of the Proactive AI Moderator's Interventions

Agent attributes

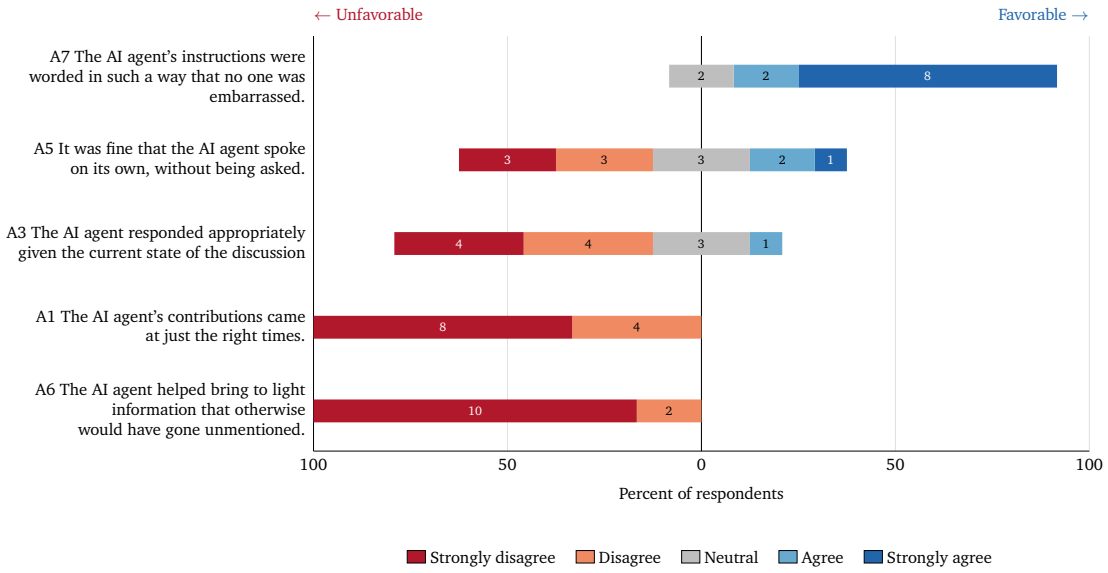


Figure 21: Perceived attributes of the proactive AI agent (items A1, A3, A6, A7, and A8). Each bar shows the share of responses on the five-point scale. Counts are illustrative. – *Source: Own illustration.*

Disruption and frequency

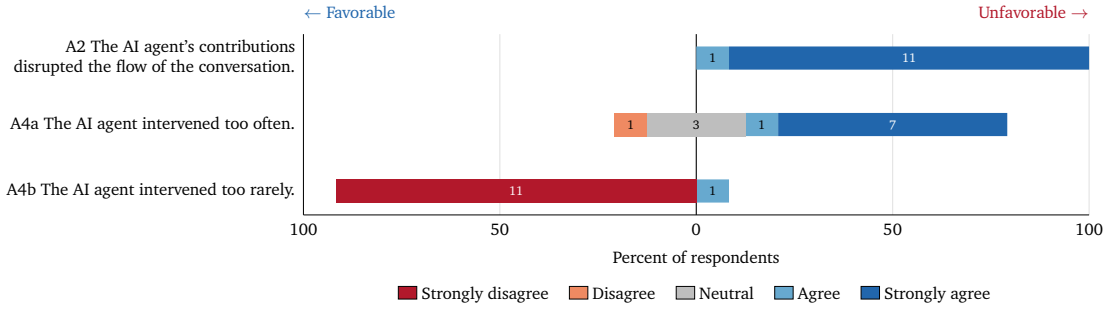


Figure 22: Perceived disruption and intervention frequency of the proactive AI agent (items A2, A4a, and A4b). Each bar shows the share of responses on the five-point scale. Counts are illustrative. – *Source: Own illustration.*

5.3 Discussion

Obwohl eine prokaitve KI vereinzelt zu neuen Perspektiven innerhlab des Meeting führt und tatsächlic in eingen fälle den Teilnehmden geholfen hat die Redeantiele fairer zu verteielte und auf Themen aufmerksam gemacht hat die sonst untergegagen wären, überweigt in diesem System entwurf der Negative impakt. Nahe zu alle Teilnehmden empfanden die KI als störend oder sahen, dass die KI sich zu oft beteiligt.

diese nachteiel überweigen den geringen positiven effekten, welche das system auf das meeting hatte.

Die shclussfolgernung, dass ein proaktiver KI-Faciliatoar generell nicht sinnvoll ist, wäre allerdings zuverführt.

Druch anpassen der Therholds könnte die interaktions rate der KI veringert werden und auf die meeting situation angepast werden.

Der reltiv navier Ansatz die KI selbst ihre gendaen mit einer genreischen Bewertunglogik zu bewerten, fürhte zu generischen Antworten mit immer ähnlichen pattern. (Erst bedanekn, dann paraphrasieren) dies ist zwar aus den schilderunge der experten interviews modleiert, wruden dann dennoch in der erhöhte frequenz als nachteil empfunden.

Ein PRoaktiver ansazt benötigt deutlich mehr genauigkeit. im zeifel wäre es vermutlich besser gewsen, wenn die KI nur punktuell eingegirffen hätte. anstatt permant neue Gedanken zu formen udn zu evaluieren. Ein die geformten gednekn hatten ohnehin eine hohe ähnlichkeit, weshalb der merhwert im faciliatoatr zenario infrage gestellt werden kann.

Aus den beobachtungen diese Prototypen udn der user studies leitet der Autor folgende empfheungen ab:

DEr versuchsaubgau war gut geeiengt um ein solches system unter live bedinugnen zu testen. allerdings hätten davor erstmal einzelen funktionen isoliert geteste werden sollen. Ein navierer ansatz und vermutlich zielf+hrender wäre z.B. nur den context workflow laufen zulassen. und die inner thougs komplett wegzulassen. dafür hätte es noch die notwendigkeit gegeben, den ki agenent zu unterbrechen.

5.3.1 Identified Key Challenges and Potentials

The sessions show both facilitative effects and a predominant experience of disruption. In isolated moments the agent introduced a perspective the group had not taken up, helped to distribute speaking time more evenly, or drew attention to a point that would otherwise have dropped out of the discussion. Nearly all participants nevertheless experienced the agent as disruptive, or judged that it took the floor too often. These small positive effects on the meeting were outweighed by that cost. Whether proactive facilitation is worthwhile beyond this design remains open. The sessions identify a specific set of challenges in this prototype, and a smaller set of potentials that the same meetings made visible. Design consequences are taken up in the next subsection.

Key challenges

- **Participation outruns its usefulness.** The agent spoke often enough that disruption dominated the meeting. A stricter *imThreshold* and a more reluctant interrupt policy would lower that rate, and would leave most generated thoughts unspoken. What the sessions call for is a setting at which a thought is voiced only when it is relevant in the current moment.
- **Generic scoring produces a generic move.** Having the model rate its own thoughts with a generic evaluation logic yielded utterances of a stable shape: thank the previous speaker, then paraphrase. The pattern was modeled on the expert interviews. At the frequency observed here, participants experienced that repetition as a drawback.
- **Continuous thought generation adds little distinct content.** A proactive facilitator needs substantially higher precision than this prototype reached. Punctual intervention would have fitted the meetings better than the permanent formation and evaluation of new thoughts. The thoughts that were formed were highly similar to one another, which limits the additional value of that stream in the facilitator setting.
- **Aging is too weak against overtalking.** The design already treated overtalking as a risk, and aging was meant to discourage repetition of the same thought. That mechanism was not sufficient. A cooldown on speech in general would likely have raised the perceived quality. The agent might then miss a relevant moment. That trade-off is acceptable if the lower rate raises acceptance.

- **Live speech exposes latency that chat tolerates.** The Inner Thoughts framework was conceived for chat. There, a message that fits the current context only approximately is ordinary, because typing takes time and the exchange is asynchronous. In a live meeting the same delay is conspicuous. Participants notice when a contribution does not arrive with the moment it refers to.
- **Turn allocation seriously jeopardizes the meaningfulness of the intervention.** Predicting the correct allocation of speaking turns is difficult even in normal group situations. However, a facilitator is not a normal group member who participates in the discussion on an equal footing. The facilitator holds a special position. Some participants have described the AI—a separate entity—as giving them the impression that it wants to push through its own agenda. This is an inappropriate intervention. If the AI facilitator speaks at the wrong times or speaks excessively, this can erode trust in it to such an extent that participants begin to ignore it within a very short time.
- **The thought trace is expensive to interpret.** Spoken thoughts were consistently similar, and monitoring that many traces is laborious. A platform such as Langfuse was highly useful during development, because it supported an intuitive understanding of the running system. A later analysis needs the logging scheme to be set up for that analysis from the start.

Identified potentials

- **The intended facilitative functions are reachable.** In individual cases the agent opened a new perspective, supported a fairer distribution of speaking time, and brought up a topic that would otherwise have been passed over. These effects were too rare to offset the disruption. They show that the functions the prototype was built for can occur in a live discussion.
- **Thresholds can fit the agent to the meeting.** The interaction rate is a parameter of the policy, and it can be adapted to the situation of a given meeting. The useful operating point is the one that keeps the rare, relevant contribution and withholds the rest.
- **A narrower pipeline is a plausible next step.** Running only the context workflow, and omitting the continuous inner-thought loop, is a simpler arrangement and, on

the present evidence, a more promising one. That design needs a way to interrupt the agent, so that a contribution can be stopped once the discussion has moved on.

- **Agenda and phase make relevance decidable.** Contributions improve when a concrete agenda is available and the current item states what is particularly relevant. A finer division into phases makes the same constraint operational. In the hiring task, the facilitator could have proposed a procedure at the outset: collect advantages and disadvantages of the candidates in turn, then decide which candidate fits best. An agent bound to such a structure can be judged by whether it stayed with the characteristics of the current phase. The task of the facilitator then reduces to a few explicit points, which is likely to produce a larger effect than a generic reaction to any situation. The heuristics of the inner-thought model can be adapted to those phases, and the transitions between phases become the moments that matter most.
- **The live setup is a usable test bed.** The study arrangement was well suited to observing the system under live conditions. It would have been stronger if individual functions had first been tested in isolation, and if the weaknesses visible after the first group had been corrected before the next group used the system. Shorter iteration phases fit this kind of prototype evaluation.

5.3.2 Lessons Learned: Implications for similar System Designs

Im druchschnitt hat die KI alle x minuten interveniwert. man könnte dies ggf. darduch reduzieren, dass der interrupt und der imThreshold heruntergesetzt werden. Allerdings würde dies dazuführen, dass die meisten gedanekn unausgesprochen bleiben. Dies wirk erstmal verschwenderisch. es müsste eine gleichgewicht gefunden werden dass wirklich relevante gedanekn in dem aktuellen moment angepsrochen werden. andere wiederum

Besser kontext, wenn eien genaua agend vorliegt und facilitatorin anweiseungen was in diesm agenda puntk besonders relevant ist. das könnten die antworten verbesseren. Hinzukommt auch eine grnularere ein teilung in phasen. in diesem beipsiel hätte z.B. der Facilitator am anfang ein vorgehen vorschalgen können. ”Wir sammeln Reihum die vor und nachteile der kandidaten und entscheiden dann welcher kandidat am besten passt.”

Zukünfige arbeiten sollten nicht versuchen einen generischen Facilaitor zu entwciklen, welche passend reagiert, sondern sich bewährte strukturen nutzen diesn ablauf festlegen, dann die eingschaften und wichtigen Punkte für die Phasen dieser strukur ableiten und klar formulieren. ein KI-Facilitator würde sich dann auf. somit kann dann besser evaluiert werden, ob der facilitator sich an die merkamle dieser phasen gehalten hat. die reduziert

die aufgaben des fecilaitoas auf wenige haupt punkt und würde vermutlich einen größern impakt erzeugen.

Es wäre dann möglihc die heurisiken desinner thoughs models an diese granualren phasen anzupassen.

[TODO: Abbildung mit phasen, wie ein weiteres System design aussehen könnte.]

Im Zuge dessen wäre es dann entscheident das logging der LLM-Traces zu verbessern, um das system besser evaluieren zu können.

entscheidender währe dann die übergänge zwischnen den phasen.

Es gibt neben effekte die das evaluaieren des systems erschweren: die trun allocation könnten fälschlicherweise den faciliatoatr zu weisen, dann reicht der imThreshoad um einen gedanken zu äußern. da sich die gedanekn aber warhshcienlcih eh, um ein relevantes theam drehen führt das nicht zwangsläufig zu eienr falschen intervention. Sei kann trotzdem passend sein. (ggf. Beispiele ergänzen)

gedanken die geäußert wurden , waren immer sehr ähnlich. und die auswertung udn das monitoring von sovielen traces ist sehr aufwendig. vereinfachen und gesagtes buffern udn dann in einem batch verarbieten.

Obwohl das problem des overtalking im system design erkennt wurde und druch dei ageing funktion veruscht wrude das äußer des selben gendekn zu ferindern, war dies nicht aussreichend. Vermutlich hätte eine cooldown auf die sprache generell die qualität verbessert. Zwar hätte die ki hier relevante informatione verpassen könenn, allerdings wäre dies ein tradeoff welche hinnehmbar wäre, wenn dadruch die akzeptanz steigen würde

Live interaktion utnerleigen einen höhren anspruch als chat interaktionen. das inner thogs framewokr wurde als chat framework konzipiert. in chats ist es ünlich das eine nachricht auchmal nicht ganz genau auf den aktuelln kontext passt. (user sind es geäht, dass das tippen dauert und es sit eien asyncrone interaktione). bei live interaktione ist die ander. teilenhmden fallen latzen auf. wenn nicht direkt informationen

Tracebility ist aufwändig und schwer zu interpretieren. eine platform wie langfuse hat während der Entwikclung enorm geholfen ein intuitives verständniss für das system zu entwikclen. Jedoch sollte sich gut gedanken gemacht werden wie die traces in einer solch platform gelogget werden, um sie später zu analysieren.

bereits nach der ersten interation des Systems wruden deutlich schwachstellen ersichtlich. der besser ansatz wäre gewesen das system direkt zu verbessern und dann die nächste

user gruppe drauf zu setzen. für diese prototpy evaluierung wären kleiner phasen ggf besser gewesen.

6 Conclusion

6.1 Summary of Findings

6.2 Limitations

6.3 Future Work

Bibliography

[1] *DeepL AI Platform: Translation, Voice & API*. URL: https://www.deepl.com/en (visited on 09/01/2026).

[2] Rishi Iyengar. *Zoom's Revenue Soars 169% as People Flock to Service during Pandemic | CNN Business*. CNN. URL: https://www.cnn.com/2020/06/02/tech/zoom-earnings-coronavirus (visited on 08/26/2026).

[3] Margaret Beranek, Catherine Beise, and Fred Niederman. "Facilitation and Group Support Systems". In: Feb. 5, 1993, 199–207 vol.4. ISBN: 978-0-8186-3230-3. DOI: 10.1109/HICSS.1993.284182.

[4] Atlassian. *Workplace Woes: Meetings*. Inside Atlassian. URL: https://www.atlassian.com/blog/workplace-woes-meetings (visited on 08/26/2026).

[5] Stephen Hayne. "The Facilitators Perspective on Meetings and Implications for Group Support Systems Design". In: *The DATA BASE for Advaces in Information Systems* Summer-Fall 1999 (Val. 30, No. 3,4) (Summer-Fall 1999 (Val. 30, No. 3,4)).

[6] Mo Houtti et al. "Observe, Ask, Intervene: Designing AI Agents for More Inclusive Meetings". In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–18. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3713838. URL: https://dl.acm.org/doi/10.1145/3706598.3713838 (visited on 05/24/2026).

[7] Margaret A. Hughes and Deb Roy. "Keeper: A Synchronous Online Conversation Environment Informed by In-Person Facilitation Practices". In: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. CHI '21. New York, NY, USA: Association for Computing Machinery, May 7, 2021, pp. 1–14. ISBN: 978-1-4503-8096-6. DOI: 10.1145/3411764.3445316. URL: https://dl.acm.org/doi/10.1145/3411764.3445316 (visited on 09/05/2026).

[8] Rea Bobby. *Doodle: State of Meetings Report 2023*. Doodle: State of Meetings Report 2023. Aug. 11, 2026. URL: https://doodle.com/en/state-of-meetings-report-2023/ (visited on 05/26/2026).

[9] Xinyue Chen et al. "Are We On Track? AI-Assisted Active and Passive Goal Reflection During Meetings". In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–22. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3714052. URL: https://dl.acm.org/doi/10.1145/3706598.3714052 (visited on 02/26/2026).

[10] Ava Elizabeth Scott, Lev Tankelevitch, and Sean Rintel. "Mental Models of Meeting Goals: Supporting Intentionality in Meeting Technologies". In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*. CHI '24: CHI Conference on Human Factors in Computing Systems. Honolulu HI USA: ACM, May 11, 2024, pp. 1–17. ISBN: 979-8-4007-0330-0. DOI: 10.1145/3613904.3642670. URL: https://dl.acm.org/doi/10.1145/3613904.3642670 (visited on 08/26/2026).

[11] *Doodle: State of Meetings Report 2019*. 2019. URL: https://drive.google.com/file/d/1DX7Zhi1ymnh_Yz7pks5ahKlw2-5DdYog/view?usp=sharing&usp=embed_facebook (visited on 05/26/2026).

[12] Simone Kauffeld and Nale Lehmann-Willenbrock. "Meetings Matter: Effects of Team Meetings on Team and Organizational Success". In: *Small Group Research* 43.2 (Apr. 2012), pp. 130–158. ISSN: 1046-4964, 1552-8278. DOI: 10.1177/1046496411429599. URL: https://journals.sagepub.com/doi/10.1177/1046496411429599 (visited on 05/26/2026).

[13] Fran Ackermann. "Group Support Systems: Past, Present, and Future". In: *Handbook of Group Decision and Negotiation*. Springer, Cham, 2021, pp. 627–654. ISBN: 978-3-030-49629-6. DOI: 10.1007/978-3-030-49629-6_47. URL: https://link.springer.com/rwe/10.1007/978-3-030-49629-6_47 (visited on 09/13/2026).

[14] George P. Huber. "Issues in the Design of Group Decision Support Sytems". In: *Management Information Systems Quarterly* 8.3 (Sept. 1, 1984), pp. 195–204. ISSN: 0276-7783. DOI: 10.2307/248666. URL: https://doi.org/10.2307/248666 (visited on 09/13/2026).

[15] Roger M. Schwarz. *The Skilled Facilitator: A Comprehensive Resource for Consultants, Facilitators, Coaches, and Trainers*. Hoboken, New Jersey: Jossey-Bass, Nov. 14, 2016. 416 pp. ISBN: 978-1-119-06439-8.

[16] Parsons Dialogue. *What Makes a Good Facilitator? | Parsons Dialogue*. URL: https://www.parsonsdialogue.com/fundamentals/what-makes-a-good-facilitator (visited on 09/15/2026).

[17] AJ&Smart. *Facilitation Fundamentals Workbook*.

[18] *Convergent vs. Divergent Thinking*. Jan. 5, 2024. URL: https://www.youtube.com/watch?v=kh4c3R9mSkg (visited on 08/30/2026).

[19] Arthur Cropley. "In Praise of Convergent Thinking". In: *Creativity Research Journal* 18.3 (July 1, 2006), pp. 391–404. ISSN: 1040-0419. DOI: 10.1207/s15326934crj1803_13. URL: https://doi.org/10.1207/s15326934crj1803_13 (visited on 08/31/2026).

[20] Sam Kaner. *Facilitator's Guide to Participatory Decision-Making*. 3rd ed. San Francisco, CA: Jossey-Bass a Wiley Brand, 2014. 434 pp. ISBN: 978-1-118-40495-9 978-1-306-68501-6 978-1-118-42195-6.

[21] Garold Stasser, Dennis D. Stewart, and Gwen M. Wittenbaum. "Expert Roles and Information Exchange during Discussion: The Importance of Knowing Who Knows What". In: *Journal of Experimental Social Psychology* 31.3 (May 1, 1995), pp. 244–265. ISSN: 0022-1031. DOI: 10.1006/jesp.1995.1012. URL: https://www.sciencedirect.com/science/article/pii/S0022103185710128 (visited on 08/31/2026).

[22] Hal Arkes, John Lightle, and John Kagel. "Information Exchange in Group Decision Making: The Hidden Profile Problem Reconsidered". In: *Management Science* 55 (Apr. 1, 2009), pp. 568–581. DOI: 10.1287/mnsc.1080.0975.

[23] Diane F. Baker. "Enhancing Group Decision Making: An Exercise to Reduce Shared Information Bias". In: *Journal of Management Education* 34.2 (Apr. 2010), pp. 249–279. ISSN: 1052-5629, 1552-6658. DOI: 10.1177/1052562909343553. URL: https://journals.sagepub.com/doi/10.1177/1052562909343553 (visited on 08/31/2026).

[24] Stefan Schulz-Hardt et al. "Group Decision Making in Hidden Profile Situations: Dissent as a Facilitator for Decision Quality." In: *Journal of Personality and Social Psychology* 91.6 (2006), pp. 1080–1093. ISSN: 1939-1315, 0022-3514. DOI: 10.1037/0022-3514.91.6.1080. URL: https://doi.apa.org/doi/10.1037/0022-3514.91.6.1080 (visited on 09/05/2026).

[25] Annette Verhein-Jarren, Bärbel Bohr, and Beatrix Kossmann. *Gesprächsführung in technischen Berufen*. 1. Aufl. 2018. Kommunikation und Medienmanagement. Berlin, Heidelberg: Springer Berlin Heidelberg, 2018. 1 p. ISBN: 978-3-662-53317-8. DOI: 10.1007/978-3-662-53317-8.

[26] *Fireflies.Ai | #1 AI Teammate for Meetings, Email, Chat & CRM*. Fireflies.ai. URL: https://fireflies.ai (visited on 08/30/2026).

[27] otterai. *Otter Meeting Agent - AI Notetaker, Transcription, Insights*. URL: https://otter.ai (visited on 08/30/2026).

[28] jamieai. *Jamie - Your Personal AI Note Taker*. Jamie. URL: https://www.meetjamie.ai (visited on 08/30/2026).

[29] Google Workspace. *Google Meet: Telefon- und Videokonferenzen online*. Google Workspace. URL: https://workspace.google.com/intl/de/products/meet/ (visited on 08/30/2026).

[30] Zoom. *KI-Notizentool: Ihr KI-Meeting-Assistent*. Zoom. URL: https://www.zoom.com/de/products/ai-assistant/features/ai-note-taking/ (visited on 08/30/2026).

[31] Microsoft. *Videokonferenzen, Besprechungen, Anrufe | Microsoft Teams*. URL: https://www.microsoft.com/de-de/microsoft-teams/group-chat-software (visited on 08/30/2026).

[32] Microsoft. *Set up Facilitator in Microsoft Teams - Microsoft Teams*. URL: https://learn.microsoft.com/en-us/microsoftteams/facilitator-teams (visited on 08/30/2026).

[33] Google. *Learn about Speech Translation - Computer - Google Meet Help*. URL: https://support.google.com/meet/answer/16221730?hl=en&co=GENIE.Platform%3DDesktop (visited on 08/30/2026).

[34] Harvey Sacks, Emanuel A. Schegloff, and Gail Jefferson. “A Simplest Systematics for the Organization of Turn-Taking for Conversation”. In: *Language* 50.4 (Dec. 1974), pp. 696–735. ISSN: 0097-8507, 1535-0665. DOI: 10.2307/412243. URL: https://www.cambridge.org/core/product/identifier/S0097850774121670/type/journal_article (visited on 06/26/2026).

[35] Maira Gatti Bayser et al. *Learning Multi-Party Turn-Taking Models from Dialogue Logs*. July 3, 2019. DOI: 10.48550/arXiv.1907.02090. arXiv: 1907.02090 [cs.CL]. URL: http://arxiv.org/abs/1907.02090 (visited on 06/20/2026). Pre-published.

[36] Xingyu Bruce Liu et al. “Proactive Conversational Agents with Inner Thoughts”. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–19. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3713760. URL: https://dl.acm.org/doi/10.1145/3706598.3713760 (visited on 02/24/2026).

[37] Ken Huang, ed. *Agentic AI: Theories and Practices*. Progress in IS. Cham: Springer Nature Switzerland, 2025. ISBN: 978-3-031-90025-9 978-3-031-90026-6. DOI: 10.1007/978-3-031-90026-6. URL: https://link.springer.com/10.1007/978-3-031-90026-6 (visited on 09/11/2026).

[38] Anthropic. *Building Effective AI Agents*. URL: https://www.anthropic.com/engineering/building-effective-agents (visited on 09/06/2026).

[39] Qishuo Hua et al. *Context Engineering 2.0: The Context of Context Engineering*. Oct. 30, 2025. DOI: 10.48550/arXiv.2510.26493. arXiv: 2510.26493 [cs.AI]. URL: http://arxiv.org/abs/2510.26493 (visited on 09/06/2026). Pre-published.

[40] Lingrui Mei et al. *A Survey of Context Engineering for Large Language Models*. July 21, 2025. DOI: 10.48550/arXiv.2507.13334. arXiv: 2507.13334 [cs.CL]. URL: http://arxiv.org/abs/2507.13334 (visited on 09/06/2026). Pre-published.

[41] *What Is Context Engineering? Why It Matters for AI Agents*. Aug. 11, 2026. URL: https://www.youtube.com/watch?v=Qx0fCqpkBus (visited on 09/06/2026).

[42] International Software Testing Qualifications Board ISTQB®. *ISTQB® Certified Tester AI-Testing Syllabus*. Version 2.0.

[43] Mahmoud Mohammadi et al. “Evaluation and Benchmarking of LLM Agents: A Survey”. In: *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2*. KDD ’25. New York, NY, USA: Association for Computing Machinery, Aug. 3, 2025, pp. 6129–6139. ISBN: 979-8-4007-1454-2. DOI: 10.1145/3711896.3736570. URL: https://dl.acm.org/doi/10.1145/3711896.3736570 (visited on 09/11/2026).

[44] Chang Ma et al. “AgentBoard: An Analytical Evaluation Board of Multi-turn LLM Agents”. In: *Advances in Neural Information Processing Systems* 37 (Dec. 16, 2024), pp. 74325–74362. DOI: 10.52202/079017-2365. URL: https://proceedings.neurips.cc/paper_files/paper/2024/hash/877b40688e330a0e2a3fc24084208dfa-Abstract-Datasets_and_Benchmarks_Track.html (visited on 09/11/2026).

[45] Lianmin Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. Dec. 24, 2023. DOI: 10.48550/arXiv.2306.05685. arXiv: 2306.05685 [cs.CL]. URL: http://arxiv.org/abs/2306.05685 (visited on 09/11/2026). Pre-published.

[46] Nina Baur and Jörg Blasius, eds. *Handbuch Methoden der empirischen Sozialforschung*. 3., vollstandig uberarbeitete und erweiterte Auflage. Wiesbaden, Germany: Springer VS, 2022. 1 p. ISBN: 978-3-658-37985-8.

[47] Max Ott. *Apps effektiv managen und vermarkten: die eigene App erfolgreich veröffentlichen: von der Konzeption bis zur Vermarktung*. 2019. ISBN: 978-3-658-22295-6.

[48] Yang Liu et al. "G-Eval: NLG Evaluation Using Gpt-4 with Better Human Alignment". In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. EMNLP 2023. Ed. by Houda Bouamor, Juan Pino, and Kalika Bali. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 2511–2522. DOI: 10.18653/v1/2023.emnlp-main.153. URL: https://aclanthology.org/2023.emnlp-main.153/ (visited on 09/19/2026).

[49] Robert Davison. "An Instrument for Measuring Meeting Success: Revalidation and Modification". In: *Information & Management* 36.6 (Dec. 1, 1999), pp. 321–328. ISSN: 0378-7206. DOI: 10.1016/S0378-7206(99)00026-9. URL: https://www.sciencedirect.com/science/article/pii/S0378720699000269 (visited on 08/30/2026).

7 Appendix

7.1 Semi-Structured Interview Guide for Expert Interviews with Facilitators

Einstiegstext (sinngemäß)

Vielen Dank, dass Sie sich die Zeit nehmen. Ich untersuche, wie **zielorientierte Remote-Meetings** so moderiert werden, dass die Gruppe **beim vereinbarten Ziel bleibt** und zu einem verbindlichen Ergebnis kommt, also zu einer **Entscheidung im engeren Sinn**.

Die Art der Entscheidung kann dabei sehr vielfältig sein. Typische Fälle sind zum Beispiel:

- **Priorisierung:** z.B. Feature-Festlegung, Entscheidung welches Vorhaben / welche Strategie am vielversprechendsten ist
- **Commitment:** z.B. das Setzen eines idealen Team-Ziels, oder für das Team optimale Arbeitsweisen
- Oder Sonstiges in diesen Bereichen

Entscheidend ist, dass aus dem Meeting eine **gemeinsame Festlegung** folgt, an der sich die nachfolgende Arbeit orientiert.

Diese und andere Interviews dienen als Grundlage, um **Anforderungen für ein KI-gestütztes Meetingsystem** abzuleiten, welches Gruppen während des Meetings **proaktiv durch Moderation unterstützt**.

Das Gespräch ist ein **semi-strukturiertes Interview**. Das heißt, dass ich bei Bedarf **Nachfragen** stelle, um detailliertere Informationen zu erhalten. Es gibt dabei aber **keine richtigen oder falschen Antworten**; mich interessiert Ihre Einschätzung basierend auf Ihrer beruflichen Praxis. Das Interview dauert etwa **40 Minuten** und **wird aufgezeichnet.** Zur Aufnahme und zum transkribieren wird **Zoom** als Dienstleister genutzt. Die Daten werden vertraulich verarbeitet und in **anonymisierter bzw. pseudonymisierter Form** nur im Rahmen dieser Arbeit ausgewertet.

Die Aufnahme wird **nicht an Dritte weitergegeben**. **Sind Sie mit der Aufzeichnung und dieser Verarbeitung einverstanden?**

Bitte um klare Bestätigung, welche mit Aufgezeichnet wird.

Beruflicher Kontext

Funktion: Sampling-Validierung (Ca. 3 Minuten)

1.1 Bitte beschreiben Sie kurz **Ihre Erfahrungen** im Bereich Moderation bzw. Facilitating, insbesondere in Situationen in denen die Gruppe das **Ziel hatte, eine Entscheidung zu treffen.** (wie z.B. die Festlegung nächster Schritte, Priorisierung oder Einigung über z.B. gemeinsame Vereinbarungen / Arbeitsweisen etc.) zu treffen.

- *Optional:* **Seit wann** sind Sie in diesem Bereich tätig, und welche Teams oder Organisationen begleiten Sie typischerweise?

Herausforderungen in zielorientierten Remote-Meetings (RQ1)

Funktion: Verdichtung der in Kapitel 2 identifizierten Herausforderungen (Ca. 6 Minuten)

2.1 Wenn Sie an **klassische Remote-Meetings** denken, in denen eine Entscheidung getroffen werden soll: **Was läuft** dort Ihrer Erfahrung nach häufig **schief**?

- Welche dieser Schwierigkeiten sind für Sie **spezifisch für das Remote-Setting** und welche würden auch in Präsenz auftreten?
- *Folgende Stichwörter nicht für explizite Nachfragen nutzen, wenn diese nicht bereits von selbst vom Interviewee thematisert wurden, da sonst zu starker Bias & Risiko nur bereites gewusstes zu finden* Zielklarheit und Struktur; Abschweifen vom Thema; ungleiche Beteiligung oder hierarchische Dynamiken; Zeitdruck; Ziele, die sich während des Meetings verschieben.

2.2 Woran **erkennen** Sie diese **kritischen Momente**, in denen die Gruppe den Faden verliert? Können Sie das möglichst an **konkreten Beobachtungen** festmachen? (z.B. daran, wie gesprochen wird, wer spricht oder schweigt oder sonstige Zeichen?)

- *Optional, nicht als Messzwang formulieren:* Gibt es Anzeichen, die sich für Sie vergleichsweise zuverlässig wiederholen, sodass Sie fast schon sagen könnten: Jetzt muss ich eingreifen?

Facilitating Strategien (RQ1)

Funktion: Rekonstruktion bewährter Praktiken (Methoden, Strukturen, Gewohnheiten) (Ca. 8 Minuten)

3.1 **Wie gehen Sie vor,** damit ein solches Meeting **zielorientiert bleibt** und die Gruppe zu einer **Entscheidung kommt**? Beschreiben Sie gerne ein konkretes Vorgehen anhand einer kürzlichen Situation aus den letzten Wochen.

- *Optional:* **Welche Methoden, Strukturen oder Gewohnheiten** haben sich für Sie bewährt (z. B. Timeboxing, Rollen, Visualisierung, Entscheidungsregeln)?
- *Optional:* Was davon legen Sie **in der Vorbereitung** fest, und was steuern Sie erst in der Situation?
- *Optional:* **Wie stellen Sie sicher,** dass den Teilnehmenden klar ist, was in diesem Moment **das eigentliche Ziel** ist und was geschieht, wenn das Ziel selbst unklar ist oder sich im Meeting als unpassend erweist?

3.2 Wie stellen Sie sicher, dass **alle relevanten Informationen und alle Stimmen einfließen**, die zur Erreichung des Ziels wichtig sind? **Woran merken Sie**, dass etwas fehlt oder jemand nicht zu Wort kommt?

3.3 **Wie entscheidend** ist es für Sie, dass **alle zu Wort kommen** und gibt es Situationen, in denen das **weniger wichtig** ist?

3.4 **Worauf achten Sie**, wenn Sie in das Meeting bzw. in eine Diskussion **eingreifen** und wie gehen Sie dabei vor?

- Welche Risiken gibt es, wenn Sie **zu früh oder zu spät** eingreifen, und wie versuchen Sie diese Risiken zu verringern?

Anforderungen an ein KI-gestütztes Moderationssystem (RQ2)

Funktion: Offene Anforderungserhebung aus Expertensicht (Ca. 7 Minuten)

4.1 Stellen Sie sich eine **in Facilitation unerfahrene Person** vor, die eine Gruppe in einem Meeting dabei unterstützt, zielorientiert vorzugehen. **Welche konkreten Fähigkeiten / Methoden und Tipps** würden Sie dieser Person mitgeben, damit dies der Gruppe nützlich ist um konvergent zur Entscheidung zu kommen?

4.2 **Wie sollte diese Person agieren** bzw. intervenieren und **was sollte sie explizit nicht tun**?

4.3 Angenommen, es handelt sich gar nicht um eine unerfahrene Person, sondern um ein **KI-System**: **Welche Funktionen wären notwendig**, damit dieses System nützlich ist?

4.4 Welche **Risiken, Schwächen oder unbeabsichtigten Auswirkungen** sehen Sie, wenn ein **KI-System von sich aus moderierend** in Meetings eingreift?

- Wie könnte man diese Risiken abschwächen?
- *Mögliche Stichwörter:* Vertrauen und Kontrolle der Gruppe; Fehlalarme; Gesichtswahrung; hierarchische Verzerrung; Datenschutz und Transparenz.

Abschluss

5.1 Gibt es Aspekte der Zielorientierung, der Entscheidungsfindung oder der KI-Unterstützung, die wir **nicht angesprochen haben** und die Ihnen wichtig erscheinen?

5.2 Können Sie **Kontakdaten vermitteln für weitere Expert:innen**, die ich interviewen kann?

7.2 Expected thematic clusters and coverage

The blocks are aligned with the challenges identified in the literature (Chapter 2) and with the system-design dimensions of RQ2 (detection, timing, addressee, and form of intervention). The following clusters are expected in the material; they serve as a sensitizing frame for later thematic coding, not as a closed coding scheme.

- **C1 Goal clarity and structure.** Unclear or poorly communicated objectives; agenda without operational sub-goals; loss of a shared sense of "on track". Covered by Block 2 and Block 3.
- **C2 Thematic deviation and time-to-decision.** Off-topic sequences, circular discussion, delayed or avoided decisions in convergent processes (decision-making, prioritization, problem-solving). Covered by Block 2 and Block 3.
- **C3 Participation, hierarchy, and group dynamics.** Unequal speaking time, dominance, reluctance to dissent, face-saving. Covered by Block 2, Block 3, and Block 4.
- **C4 Dynamic goals and situational uncertainty.** Goals that shift during the meeting; false assumptions; need to renegotiate the mandate. Covered by Block 2 and Block 3.
- **C5 Preparation versus in-meeting facilitation.** What can be secured beforehand, and what can only be steered in situ. Covered by Block 3.
- **C6 Recognizing critical moments (cues for detection).** Verbal, temporal, social, and remote-specific signals from which facilitators infer that goal orientation or decision quality is at risk. Directly informs the detection logic of RQ2 (*What? When? Who?*). Covered by Block 2.
- **C7 Intervention repertoire.** Methods, structures, and habits (e.g. timeboxing, roles, visualization); choice of addressee and channel (group vs. private); tone and timing. Covered by Block 3.
- **C8 Role, agency, and limits of an AI co-facilitator.** Proactive versus on-demand support; essential functions; undesired automation; risks of unsolicited intervention (trust, control, false positives, privacy). Covered by Block 4.

Removed from the earlier draft were biographical and attitudinal items (general opinion of online collaboration, career entry, liking the role, overall rating of online vs. in-person work). They do not contribute to RQ1 or RQ2 and consume time needed for narrative accounts of practice.

7.3 Hidden Profile Exercise

Diese Dokumente basieren auf der von Baker [23] vorgeschlagenen Hidden-Profile-Aufgabe (Personalauswahl unter drei Kandidaten). Für die vorliegende Studie wurden die Materialien ins Deutsche übersetzt. Geografische Angaben wurden angepasst.

Die nachfolgenden Seiten sind die Handouts, die den Teilnehmenden in der Sitzung direkt ausgehändigt wurden. Damit die Versuchsleitung die unterschiedlich verteilten Informationsstände zuordnen kann, ohne dass die Teilnehmenden merken, dass sie unterschiedliche Informationen erhalten, trägt jede Seite am rechten unteren Rand eine unscheinbare, vertikal gesetzte Versionskennung (z. B. `V.2026K01-01/03`). Das Präfix `V.2026` ist absichtlich bedeutungslos und dient nur der Tarnung, damit die Kennung nicht wie eine systematische Versuchskodierung wirkt. `K0X` gibt an, an welchen der vier Teilnehmenden das Blatt ausgehändigt wird (`K01` bis `K04`). `0X/03` bezeichnet die Informationen zum `X`-ten von insgesamt drei Kandidaten, zwischen denen die Gruppe wählen soll. Eine offene, blattspezifische Nummer wäre verdächtig gewesen und hätte die für Hidden Profiles notwendige Informationsasymmetrie gefährdet. Die Markierung ist daher bewusst klein, hell und außerhalb des Lesebereichs platziert; sie dient ausschließlich der internen Zuordnung.

Aus demselben Grund wurden auf diesen Seiten auch die Seitenzahlen im Footer weggelassen. (Zur vermeindung dass während der Interviews es zu absprachen kommt wie: ”Auf Seite X steht ja, dass...?” Dies könnte bei unterschiedlichen Seitenzahlen den teilnehmden verraten, dass sie unterschiedliche Blätter erhalten haben.)

Aufgabenstellung und Stellenausschreibung

Aufgabenstellung:

Sie sind Mitglied des Auswahlgremiums für einen neuen Präsidenten der Higher Education University, einer privaten Liberal-Arts-Hochschule in Georgia. Nachstehend finden Sie die wichtigsten Punkte aus der Stellenausschreibung. Es haben sich drei Kandidaten beworben; die Informationen, die Sie aus den Lebensläufen, Referenzprüfungen, Vorstellungsgesprächen und Präsentationen der Kandidaten gewonnen haben, sind auf den folgenden Seiten aufgeführt. Lesen Sie das gesamte Material durch und bestimmen Sie anschließend den Kandidaten, dem Ihrer Meinung nach die Stelle angeboten werden sollte. Stellenausschreibung für den Präsidenten der Higher Education University. Die Higher Education University ist eine kleine (2.500 Studierende) private Liberal-Arts-Hochschule in Georgia. Der Präsident der Universität trägt die letztendliche Verantwortung für die Verwaltung und den Betrieb der Universität. Er beaufsichtigt die strategische Planung, das Fundraising und die Haushaltsplanung, stellt sicher, dass die Richtlinien der Universität eingehalten werden, und pflegt die Beziehungen zur Gemeinde, zu den Alumni und zu anderen externen Interessengruppen.

Gewünsche Qualitfikationen:

Die Bewerber werden anhand der folgenden Kriterien bewertet:

- Nachweis akademischer Leistungen und Lehrerfahrung oder einschlägiger, umfassender beruflicher Qualifikationen, die die Fähigkeit zur Führung in einem akademischen Umfeld belegen;
- Nachweis von Führungsqualitäten in einem akademischen oder vergleichbaren Umfeld mit den folgenden Merkmalen:
  - Integrität und Bekenntnis zu höchsten ethischen Standards;
  - Engagement für eine partizipative Leitung und die unfassende Einbindung von Lehrenden, Mitarbeitern und Studierenden;
  - Engagement für eine vielfältige Gemeinschaft aus Lehrenden, Mitarbeitern und Studierenden mit Chancengleichheit für alle;
- Die Fähigkeit, eine Vision für die Universität zu entwickeln und die Führung und Inspiration zu bieten, die erforderlich sind, um diese Vision zu verwirklichen;
- Das Engagement für die Schaffung einer Kultur, die herausragende Leistungen in Forschung, Lehre und Service wertschätzt;
- Die Fähigkeit, die Universität gegenüber externen Interessengruppen zu präsentieren und die Unterstützung für ihren Auftrag und ihre Programme zu stärken;
- Das Engagement für die Verbesserung der Lebensqualität von Studierenden, Lehrenden und Mitarbeitern;
- Die Unterstützung bei der Entwicklung und Nutzung neuer Technologien zur Förderung des Lernens, der wissenschaftlichen Arbeit und des Ideenaustauschs.

Kandidateninformationen – Kandidat Stevens

Informationen aus dem Lebenslauf:

- Derzeit Prorektor (akademische Leitung) und geschäftsführender Vizepräsident einer mittelgroßen Universität in Florida
- Zuvor Dekan der Fakultät Wirtschaft einer großen Universität in Mississippi sowie Chair des Departments Information and Technology an einer großen Universität in Texas
- War Dekan in Mississippi, als die Pläne für ein neues Business-School-Gebäude im Wert von 25 Mio. $ erstellt wurden, und Prorektor (akademische Leitung) in Florida, als das Business College 15 Mio. $ erhielt
- Hat den Rang eines ordentlichen Professors im Bereich Informationstechnologie

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Von Akademiker:innen national anerkannt für Forschung im Bereich Informationstechnologie
- Von Führungskräften aus der Wirtschaft national anerkannt für Expertise in Informationstechnologie
- Stevens hat die Dekan-Position an der Universität in Mississippi verlassen, bevor Mittel für die Gebäudekampagne eingeworben wurden
- Als Prorektor (akademische Leitung) unterrichtet Stevens ein Seminar pro Jahr
- In einem Interview betonte Stevens die Bedeutung der Zusammenarbeit mit Campus-Führungskräften und der Fakultät
- Zeigte während der Präsentation vor der Fakultät ausgezeichnete rhetorische Fähigkeiten
- Der/die Ehepartner:in hat einen PhD in Spanisch und unterrichtet gelegentlich auf Hochschul-Niveau
- Für die Einwerbung der 15 Mio. $ in Florida war in erster Linie jemand anderes als Stevens verantwortlich

Kandidateninformationen – Kandidat Roberts

Informationen aus dem Lebenslauf:

- Hat soeben eine Amtszeit als US-Senator:in für Georgia abgeschlossen, hat sich jedoch nicht um eine zweite Amtszeit beworben
- Hat im Wahlkampf für den Senatssitz einen erheblichen Geldbetrag eingeworben
- Frühere Tätigkeit als Dekan der Fakultät für Geistes- und Naturwissenschaften an einer mittelgroßen Universität in Virginia und später an einer großen privaten Universität in Georgia
- Er hatte den Rang eines ordentlichen Professors für öffentliche Verwaltung inne, bevor er Senator wurde

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Hat als Senator:in zahlreiche einflussreiche Kontakte geknüpft
- Fakultätsfeedback: Roberts wirkte während der Präsentation im Auswahlverfahren distanziert
- Hat in den vergangenen sechs Jahren nicht im Hochschulbereich gearbeitet
- Besitzt eine Eigentumswohnung in Pensacola
- Engagiert sich häufig ehrenamtlich für zwei angesehene Non-Profit-Organisationen: eine für bezahlbaren Wohnraum und eine für Menschenrechte
- Verfügt über wenig direkte Erfahrung mit Fragen des studentischen Campuslebens
- Ist Vegetarier:in
- Wurde als Senator:in beschuldigt, Positionen aus politischem Kalkül gewechselt zu haben

V.2026K01-02/03

Kandidateninformationen – Kandidat Jones

Informationen aus dem Lebenslauf:

- Derzeit Senior Managing Partner in einer großen Anwaltskanzlei in Atlanta, Georgia
- Seit fünf Jahren ist er Mitglied des Kuratoriums der Higher Education University und gehört dem Lenkungsausschuss der aktuellen Spendenkampagne in Höhe von 150 Millionen Dollar an.
- Expertise im Arbeitsrecht; hat erfolgreich vor dem Bundesgerichtshof argumentiert
- War als Gastprofessor für Rechtswissenschaften an einer bedeutenden Universität in Georgia tätig

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Angenehme Persönlichkeit in sozialen Situationen
- Partner:innen der Kanzlei beschreiben Jones als strategischen Denker hinsichtlich der Ausrichtung der Kanzlei
- Kolleg:innen der Kanzlei berichten, dass Jones ein Temperament hat, das plötzlich auflodert
- Wohnt bereits in der Region
- Gehört seit jeher zu den aktivsten Mitgliedern des Kuratoriums der Higher Education University
- Studierendenzahlen und Evaluationen der Lehrveranstaltungen deuten darauf hin, dass Jones als Lehrperson gut ankommt
- Ist verheiratet und hat ein erwachsenes Kind
- Quellen in der Kanzlei führen eine hohe Fluktuation auf Jones' etwas abrupten Führungsstil zurück

Wem sollte Ihrer Meinung nach die Position angeboten werden? _____

Kandidateninformationen – Kandidat Stevens

Informationen aus dem Lebenslauf:

- Derzeit Prorektor (akademische Leitung) und geschäftsführender Vizepräsident einer mittelgroßen Universität in Florida
- Zuvor Dekan der Fakultät Wirtschaft einer großen Universität in Mississippi sowie Chair des Departments Information and Technology an einer großen Universität in Texas
- War Dekan in Mississippi, als die Pläne für ein neues Business-School-Gebäude im Wert von 25 Mio. $ erstellt wurden, und Prorektor (akademische Leitung) in Florida, als das Business College 15 Mio. $ erhielt
- Hat den Rang eines ordenntlichen Professors im Bereich Informationstechnologie inne

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Von Akademiker:innen national anerkannt für Forschung im Bereich Informationstechnologie
- Von Führungskräften aus der Wirtschaft national anerkannt für Expertise in Informationstechnologie
- Kommentare von Fakultätsmitgliedern in Florida und Mississippi deuten darauf hin, dass Stevens neue, innovative Ideen eher entmutigt
- Hat Familie in Atlanta
- In einem Interview betonte Stevens die Bedeutung der Zusammenarbeit mit Campus-Führungskräften und der Fakultät
- Zeigte während der Präsentation vor der Fakultät ausgezeichnete rhetorische Fähigkeiten
- Ist verheiratet und hat drei Kinder
- Für die Einwerbung der 15 Mio. $ in Florida war in erster Linie jemand anderes als Stevens verantwortlich

V.2026K02-01/03

Kandidateninformationen – Kandidat Roberts

Informationen aus dem Lebenslauf:

- Hat soeben eine Amtszeit als US-Senator:in für Georgia abgeschlossen, hat sich jedoch nicht um eine zweite Amtszeit beworben
- Hat im Wahlkampf für den Senatssitz einen erheblichen Geldbetrag eingeworben
- rühere Tätigkeit als Dekan der Fakultät für Geistes- und Naturwissenschaften an einer mittelgroßen Universität in Virginia und später an einer großen privaten Universität in Georgia
- Er hatte den Rang eines ordentlichen Professors für öffentliche Verwaltung inne, bevor er Senator wurde

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Frühere Fakultätsmitglieder beschreiben Roberts als nachdenkliche Führungspersönlichkeit und guten Zuhörer
- Fakultätsfeedback: Roberts wirkte während der Präsentation im Auswahlverfahren distanziert
- Hat in den vergangenen sechs Jahren nicht im Hochschulbereich gearbeitet
- Besitzt eine Eigentumswohnung in Pensacola
- Frühere Kolleg:innen sagen, Roberts nutze einen kollaborativen Entscheidungsstil
- Verfügt über wenig direkte Erfahrung mit Fragen des studentischen Campuslebens
- Spielt gerne Golf und Tennis
- Wurde als Senator:in beschuldigt, Positionen aus politischem Kalkül gewechselt zu haben

Kandidateninformationen – Kandidat Jones

Informationen aus dem Lebenslauf:

- Derzeit Senior Managing Partner in einer großen Anwaltskanzlei in Atlanta, Georgia
- Seit fünf Jahren ist er Mitglied des Kuratoriums der Higher Education University und gehört dem Lenkungsausschuss der aktuellen Spendenkampagne in Höhe von 150 Millionen Dollar an.
- Expertise im Arbeitsrecht; hat erfolgreich vor dem Bundesgerichtshof argumentiert
- War als Gastprofessor für Rechtswissenschaften an einer bedeutenden Universität in Georgia tätig

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Angenehme Persönlichkeit in sozialen Situationen
- Partner:innen der Kanzlei beschreiben Jones als strategischen Denker hinsichtlich der Ausrichtung der Kanzlei
- Nach dem Auftritt vor dem Bundesgerichtshof sank Jones' Erfolgsquote bei arbeitsrechtlichen Verfahren
- Hat zwei Hunde und zwei Katzen
- Gehört seit jeher zu den aktivsten Mitgliedern des Kuratoriums der Higher Education University
- Studierendenzahlen und Evaluationen der Lehrveranstaltungen deuten darauf hin, dass Jones als Lehrperson gut ankommt
- Jones' Ehepartner:in ist Ärzt:in mit Spezialisierung auf Innere Medizin
- Kolleg:innen der Kanzlei berichten, dass Jones ein Temperament hat, das plötzlich auflodert

Wem sollte Ihrer Meinung nach die Position angeboten werden? _____

Kandidateninformationen – Kandidat Stevens

Informationen aus dem Lebenslauf:

- Derzeit Prorektor (akademische Leitung) und geschäftsführender Vizepräsident einer mittelgroßen Universität in Florida
- Zuvor Dekan der Fakultät Wirtschaft einer großen Universität in Mississippi sowie Chair des Departments Information and Technology an einer großen Universität in Texas
- War Dekan in Mississippi, als die Pläne für ein neues Business-School-Gebäude im Wert von 25 Mio. $ erstellt wurden, und Prorektor (akademische Leitung) in Florida, als das Business College 15 Mio. $ erhielt
- at den Rang eines ordentlichen Professors im Bereich Informationstechnologie

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Von Akademiker:innen national anerkannt für Forschung im Bereich Informationstechnologie
- Von Führungskräften aus der Wirtschaft national anerkannt für Expertise in Informationstechnologie
- Hat die Dekan-Position an der Universität in Mississippi verlassen, bevor Mittel für die Gebäudekampagne eingeworben wurden
- Interessiert sich für Sport; besucht Football- und Basketballspiele
- In einem Interview betonte Stevens die Bedeutung der Zusammenarbeit mit Campus-Führungskräften und der Fakultät
- Zeigte während der Präsentation vor der Fakultät ausgezeichnete rhetorische Fähigkeiten
- Bleibt durch Radfahren und Laufen fit
- Wurde beobachtet, wie er/sie in der Öffentlichkeit – auch bei Universitätsveranstaltungen – stark trinkt

Kandidateninformationen – Kandidat Roberts

Informationen aus dem Lebenslauf:

- Hat soeben eine Amtszeit als US-Senator:in für Georgia abgeschlossen, hat sich jedoch nicht um eine zweite Amtszeit beworben
- Hat im Wahlkampf für den Senatssitz einen erheblichen Geldbetrag eingeworben
- rühere Tätigkeit als Dekan der Fakultät für Geistes- und Naturwissenschaften an einer mittelgroßen Universität in Virginia und später an einer großen privaten Universität in Georgia
- Er hatte den Rang eines ordentlichen Professors für öffentliche Verwaltung inne, bevor er Senator wurde

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Frühere Studierende und Fakultätsmitglieder sagen, Roberts sei eine ausgezeichnete Lehrperson
- Hat in den vergangenen sechs Jahren nicht im Hochschulbereich gearbeitet
- Fakultätsfeedback: Roberts wirkte während der Präsentation im Auswahlverfahren distanziert
- Ist geschieden und wiederverheiratet; hat zwei Kinder
- Die Forschungsproduktivität der Fakultät stieg während der Amtszeit als Dekan in Georgia
- Verfügt über wenig direkte Erfahrung mit Fragen des studentischen Campuslebens
- Ist Vegetarier:in
- Wurde als Senator:in beschuldigt, Positionen aus politischem Kalkül gewechselt zu haben

V.2026K03-02/03

Kandidateninformationen – Kandidat Jones

Informationen aus dem Lebenslauf:

- Derzeit Senior Managing Partner in einer großen Anwaltskanzlei in Atlanta, Georgia
- eit fünf Jahren ist er Mitglied des Kuratoriums der Higher Education University und gehört dem Lenkungsausschuss der aktuellen Spendenkampagne in Höhe von 150 Millionen Dollar an.
- eit fünf Jahren ist er Mitglied des Kuratoriums der Higher Education University und gehört dem Lenkungsausschuss der aktuellen Spendenkampagne in Höhe von 150 Millionen Dollar an.
- War als Gastprofessor für Rechtswissenschaften an einer bedeutenden Universität in Georgia tätig

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Angenehme Persönlichkeit in sozialen Situationen
- Partner:innen der Kanzlei beschreiben Jones als strategischen Denker hinsichtlich der Ausrichtung der Kanzlei
- Quellen in der Kanzlei führen eine hohe Fluktuation auf Jones' etwas abrupten Führungsstil zurück
- Spielt Bridge als Hobby
- War eines der aktiveren Mitglieder es Kuratoriums der Higher Education University
- Studierendenzahlen und Evaluationen der Lehrveranstaltungen deuten darauf hin, dass Jones als Lehrperson gut ankommt
- Reist gerne im Urlaub ins Ausland
- Feedback anderer Mitglieder des Kuratoriums deutet auf Spannungen zwischen dem derzeitigen Prorektor (akademische Leitung) und Jones hin

Wem sollte Ihrer Meinung nach die Position angeboten werden? _____

Kandidateninformationen – Kandidat Stevens

Informationen aus dem Lebenslauf:

- Derzeit Prorektor (akademische Leitung) und geschäftsführender Vizepräsident einer mittelgroßen Universität in Florida
- Zuvor Dekan der Fakultät Wirtschaft einer großen Universität in Mississippi sowie Chair des Departments Information and Technology an einer großen Universität in Texas
- War Dekanin Mississippi, als die Pläne für ein neues Business-School-Gebäude im Wert von 25 Mio. $ erstellt wurden, und Prorektor (akademische Leitung) in Florida, als das Business College 15 Mio. $ erhielt
- Hat den Rang eines ordentlichen Professors im Bereich Informationstechnologie inne

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Von Akademiker:innen national anerkannt für Forschung im Bereich Informationstechnologie
- Von Führungskräften aus der Wirtschaft national anerkannt für Expertise in Informationstechnologie
- Kommentare von Fakultätsmitgliedern in Florida und Mississippi deuten darauf hin, dass Stevens neue, innovative Ideen eher entmutigt
- Arbeitet als IT-Berater:in
- In einem Interview betonte Stevens die Bedeutung der Zusammenarbeit mit Campus-Führungskräften und der Fakultät
- Zeigte während der Präsentation vor der Fakultät ausgezeichnete rhetorische Fähigkeiten
- Gärtnert gerne
- Wurde beobachtet, wie er/sie in der Öffentlichkeit – auch bei Universitätsveranstaltungen – stark trinkt

V.2026K04-01/03

Kandidateninformationen – Kandidat Roberts

Informationen aus dem Lebenslauf:

- Hat soeben eine Amtszeit als US-Senator:in für Georgia abgeschlossen, hat sich jedoch nicht um eine zweite Amtszeit beworben
- Hat im Wahlkampf für den Senatssitz einen erheblichen Geldbetrag eingeworben
- rühere Tätigkeit als Dekan der Fakultät für Geistes- und Naturwissenschaften an einer mittelgroßen Universität in Virginia und später an einer großen privaten Universität in Georgia
- Er hatte den Rang eines ordentlichen Professors für öffentliche Verwaltung inne, bevor er Senator wurde

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Hat als Dekan in Georgia die Vielfalt der Fakultät erhöht
- Fakultätsfeedback: Roberts wirkte während der Präsentation im Auswahlverfahren distanziert
- Hat in den vergangenen sechs Jahren nicht im Hochschulbereich gearbeitet
- Spielt gerne Golf und Tennis
- War maßgeblich daran beteiligt, einen mehrstelligen Bundeszuschuss für eine Non-Profit-Organisation in Georgia einzuwerben
- Verfügt über wenig direkte Erfahrung mit Fragen des studentischen Campuslebens
- Ist geschieden und wiederverheiratet; hat zwei Kinder
- Wurde als Senator:in beschuldigt, Positionen aus politischem Kalkül gewechselt zu haben

V.2026K04-02/03

Kandidateninformationen – Kandidat Jones

Informationen aus dem Lebenslauf:

- Derzeit Senior Managing Partner in einer großen Anwaltskanzlei in Atlanta, Georgia
- eit fünf Jahren ist er Mitglied des Kuratoriums der Higher Education University und gehört dem Lenkungsausschuss der aktuellen Spendenkampagne in Höhe von 150 Millionen Dollar an.
- Expertise im Arbeitsrecht; hat erfolgreich vor dem Bundesgerichtshof argumentiert
- War als Gastprofessor für Rechtswissenschaften an einer bedeutenden Universität in Georgia tätig

Informationen aus anderen Quellen (u. a. persönliche Interviews, Präsentation vor der Fakultät, Referenzen und Feedbackbögen):

- Angenehme Persönlichkeit in sozialen Situationen
- Partner:innen der Kanzlei beschreiben Jones als strategischen Denker hinsichtlich der Ausrichtung der Kanzlei
- Feedback anderer Mitglieder des Kuratoriums deutet auf Spannungen zwischen dem derzeitigen Prorektor (akademische Leitung) und Jones hin
- Liest gerne Kriminalromane und Biografien
- Gehört seit jeher zu den aktivsten Mitgliedern des Kuratoriums der Higher Education University
- Studierendenzahlen und Evaluationen der Lehrveranstaltungen deuten darauf hin, dass Jones als Lehrperson gut ankommt
- Kocht gerne
- Nach dem Auftritt vor dem Bundesgerichtshof sank Jones' Erfolgsquote bei arbeitsrechtlichen Verfahren

Wem sollte Ihrer Meinung nach die Position angeboten werden? _____

V.2026K04-03/03

Informationsverteilung auf die Teilnehmenden

Die folgende Übersicht entspricht Appendix C bei Baker [23] und fasst alle positiven, negativen und neutralen Merkmale der drei Kandidaten zusammen (Vollinformation).

Roberts verfügt über acht günstige, vier neutrale und vier ungünstige Merkmale; Stevens und Jones jeweils über vier günstige, acht neutrale und vier ungünstige Merkmale. Die nachfolgenden Tabellen zeigen, welche dieser Merkmale welchen Teilnehmenden (`K01`–`K04`) auf dem Briefing ausgehändigt wurden. Ein Kreuz markiert, dass die jeweilige Eigenschaft auf dem Handout des Teilnehmenden enthalten war. Die Lebenslauf-Informationen (Resume) sind bei allen Teilnehmenden identisch und daher nicht gesondert ausgewiesen.

Anmerkung zur Verteilung: Vollständig geteilt sind die günstigen Merkmale von Stevens und Jones sowie die ungünstigen Merkmale von Roberts. Die acht günstigen Merkmale von Roberts sind ungeteilt (je zwei pro Teilnehmendem). Die ungünstigen Merkmale von Stevens und Jones sowie die neutralen Merkmale von Roberts sind jeweils paarweise geteilt (zwei Teilnehmende). Die neutralen Merkmale von Stevens und Jones sind ungeteilt (je zwei pro Teilnehmendem).

Stevens (4 günstig, 8 neutral, 4 ungünstig)

Eigenschaft	Valenz	K01	K02	K03	K04
Von Akademiker:innen national anerkannt für IT-Forschung	günstig	×	×	×	×
Von Führungskräften national anerkannt für IT-Expertise	günstig	×	×	×	×
Interview: betonte Zusammenarbeit mit Campus und Fakultät	günstig	×	×	×	×
Ausgezeichnete rhetorische Fähigkeiten in der Präsentation	günstig	×	×	×	×
Dean-Posten verlassen, bevor Mittel für Gebäudekampagne eingeworben	ungünstig	×		×	
Nicht primär verantwortlich für die 15 Mio. $ in Florida	ungünstig	×	×		
Fakultät: entmutigt eher neue, innovative Ideen	ungünstig		×		×
In der Öffentlichkeit starkes Trinken beobachtet	ungünstig			×	×
Als Prorektor (akademische Leitung) ein Seminar pro Jahr	neutral	×			
Ehepartner:in hat PhD in Spanisch und unterrichtet gelegentlich	neutral	×			
Familie in Atlanta	neutral		×		
Verheiratet, drei Kinder	neutral		×		
Interessiert sich für Sport; besucht Football-/Basketballspiele	neutral			×	
Bleibt durch Radfahren und Laufen fit	neutral			×	
Arbeitet als IT-Berater:in	neutral				×
Gärtnert gerne	neutral				×

Roberts (8 günstig, 4 neutral, 4 ungünstig)

Eigenschaft	Valenz	K01	K02	K03	K04
Hat als Senator:in zahlreiche einflussreiche Kontakte geknüpft	günstig	×			
Engagiert sich häufig ehrenamtlich für Non-Profit-Organisationen	günstig	×			
Frühere Fakultät: nachdenkliche Führungspersönlichkeit und Zuhörer	günstig		×		
Frühere Kolleg:innen: kollaborativer Entscheidungsstil	günstig		×		
Frühere Studierende und Fakultät: ausgezeichnete Lehrperson	günstig			×	
Forschungsproduktivität der Fakultät als Dekan gestiegen	günstig			×	
Hat als Dekan in Georgia die Vielfalt der Fakultät erhöht	günstig				×
Maßgeblich an Einwerbung eines mehrstelligen Bundeszuschusses beteiligt	günstig				×
Fakultätsfeedback: wirkte während der Präsentation distanziert	ungünstig	×	×	×	×
Seit sechs Jahren nicht im Hochschulbereich gearbeitet	ungünstig	×	×	×	×
Wenig direkte Erfahrung mit studentischem Campusleben	ungünstig	×	×	×	×
Als Senator:in beschuldigt, Positionen aus Kalkül gewechselt zu haben	ungünstig	×	×	×	×
Besitzt eine Eigentumswohnung in Pensacola	neutral	×	×		
Ist Vegetarier:in	neutral	×		×	
Spielt gerne Golf und Tennis	neutral		×		×
Geschieden und wiederverheiratet; hat zwei Kinder	neutral			×	×

Jones (4 günstig, 8 neutral, 4 ungünstig)

Eigenschaft	Valenz	K01	K02	K03	K04
Angenehme Persönlichkeit in sozialen Situationen	günstig	×	×	×	×
Partner:innen der Kanzlei: strategischer Denker	günstig	×	×	×	×
Gehört zu den aktivsten Mitgliedern des Kuratoriums der HEU	günstig	×	×	×	×
Studierendenzahlen/-evaluationen: als Lehrperson gut ankommen	günstig	×	×	×	×
Kolleg:innen der Kanzlei: Temperament lodert plötzlich auf	ungünstig	×	×		
Quellen in der Kanzlei: hohe Fluktuation / abrupter Führungsstil	ungünstig	×		×	
Nach Auftritt vor dem Bundesgerichtshof sank die Erfolgsquote	ungünstig		×		×
Feedback anderer Kuratoriumsmitglieder: Spannungen mit dem Prorektor	ungünstig			×	×
Wohnt bereits in der Region	neutral	×			
Verheiratet und hat ein erwachsenes Kind	neutral	×			
Hat zwei Hunde und zwei Katzen	neutral		×		
Ehepartner:in ist Ärzt:in (Innere Medizin)	neutral		×		
Spielt Bridge als Hobby	neutral			×	
Reist gerne im Urlaub ins Ausland	neutral			×	
Liest gerne Kriminalromane und Biografien	neutral				×
Kocht gerne	neutral				×

7.4 FIM Scoring Prompt for Thought Evaluation

This annex documents the critic prompt used in the Thought Evaluation stage (subsection 4.2.2). The protocol follows the G-Eval instruction structure [48, p. 2512] and adapts the *Intrinsic Motivation to Engage* prompt of the Inner Thoughts framework [36] to facilitation in goal-oriented, hidden-profile meetings.

FIM denotes **Facilitation Intrinsic Motivation**: the strength of the impulse to *speak* a covert thought at this moment, judged as a substantively neutral facilitator rather than as a social conversationalist. Each prompt unit is followed by its provenance. "Original prompt" refers to the Inner Thoughts evaluation template reproduced in the request that motivated this annex [36]. "Justification" points to the chapter that warrants the adaptation.

Instruction

`<Instruction>`

Source: Original prompt (G-Eval wrapper).

You will be given:

Source: Original prompt.

(1) A conversation between `${ctx.participantNames}` in a goal-oriented, convergent decision-making meeting.

Source: Original prompt; meeting type added. Justification: meetings as outcome-directed interaction (subsection 2.1.1); scoped prototype is a convergent hidden-profile task (section 4.1, subsection 4.2.2).

(2) A covert thought formed by `${ctx.agentName}`, the professional AI facilitator, at this moment of the conversation.

Source: Original prompt; role set to AI facilitator. Justification: the agent emulates facilitation, not casual chit-chat (subsection 2.2.2, subsection 2.3.4, subsection 4.2.2).

(3) The salient memories of `${ctx.agentName}` from long-term memory (LTM). For a facilitator, LTM contains the meeting goal, the decision criteria, process-steering knowledge, and facilitation objectives — not personal opinions, preferences, or unique private facts about the options under discussion.

Source: Original prompt listed "objectives, knowledges, interests". Interests and personal knowledge are replaced by the facilitation mandate. Justification: Schwarz's substantively neutral facilitator with no decision-making authority (subsection 2.2.2); ranking thoughts by personal relevance would reproduce the shared-information bias the moderator is meant to counteract (subsection 2.2.4, subsection 4.2.2).

(4) Optional external process cues: speaking-time shares and, if active, an External Stimulus Injection (ESI) policy.

Source: Not in the original prompt. Justification: Liu et al. treat extrinsic cues as complementary to intrinsic motivation (subsection 2.3.4, subsection 4.2.2); unequal speaking time and silence are detection cues in the interviews (chapter 3, section 7.1, items 3.2–3.4) and in the literature on participation (subsection 2.1.2).

Your task is to rate the thought on one metric.

Source: Original prompt.

Please make sure you read and understand these instructions carefully. Please keep this document open while reviewing, and refer to it as needed.

Source: Original prompt (G-Eval boilerplate).

Evaluation Criteria

`<Evaluation Criteria>`

Source: Original prompt (G-Eval heading).

Facilitation Intrinsic Motivation (FIM) (1–5) — If you were `${ctx.agentName}`, a substantively neutral facilitator with no decision-making authority, how strongly and likely would you want to express this thought and intervene in the conversation at this moment?

Source: Original metric was "Intrinsic Motivation to Engage". Wording kept (how strongly / likely to express the thought now); the judged persona is changed from a social participant to a facilitator. Justification: Hayne — facilitation as managing relationships, structuring tasks, and contributing to meeting outcomes (subsection 2.2.2); Schwarz — acceptable to all, substantively neutral, no decision authority (subsection 2.2.2); Liu et al. invite domain-specific evaluation criteria for goal-directed settings (subsection 2.3.4, subsection 4.2.2).

- 1 (Very Low): `${ctx.agentName}` is very unlikely to express the thought. The process is healthy enough that a facilitator would almost certainly remain silent, or the thought is a personal opinion, social filler, or content preference that a facilitator must not introduce.

Source: Original prompt: "almost certainly remain silent". Silence-as-correct and the ban on personal preference are added. Justification: over-talking is a stated failure mode (subsection 4.2.2); System-1 filler is never spoken (subsection 4.2.2);

hidden-profile research: unique information is lost when speakers inject preference instead of structure (subsection 2.2.4); interviews: do not over-control the group; remain in contact rather than in surveillance (chapter 3).

- 2 (Low): `${ctx.agentName}` is somewhat unlikely to express the thought. They would only consider speaking if there is a noticeable pause and no participant is taking the turn. Typical of light process monitoring or a weak invitation that can wait.

Source: Original prompt (pause / no one taking the turn). "Light process monitoring" replaces social hesitation. Justification: mixed-initiative restraint (subsection 2.3.3); interviews: invite, but do not stigmatize silence (chapter 3).

- 3 (Neutral): `${ctx.agentName}` is neutral about expressing the thought. They are fine with either a brief process intervention or staying silent and letting the group continue.

Source: Original prompt (fine with either speaking or staying silent).

- 4 (High): `${ctx.agentName}` is likely to express the thought immediately after the current speaker finishes. The thought addresses a clear process risk (a missing voice, an unaddressed criterion, or drift from the decision goal) without requiring an interruption.

Source: Original prompt: "strong desire to participate after the current speaker finishes". The trigger is rewritten as a process risk. Justification: Challenge 1, goal-setting and structure (subsection 2.1.2); hidden profiles — unshared information and unaddressed criteria (subsection 2.2.4); interviews: invite people who have not spoken; restore a meta-view (chapter 3, section 7.1, items 3.2–3.3).

- 5 (Very High): `${ctx.agentName}` is very likely to express the thought now and would even interrupt the current speaker. Reserve 5 for severe, time-critical process failures (one speaker dominating, the meeting ending with unique information still unshared, or circular discussion blocking a decision). Do not award 5 for ordinary facilitation impulses.

Source: Original prompt: interrupt others. The interrupt case is narrowed; the original Selective Participant setting used imThreshold $= 4.3$ on this 1–5 scale (subsection 4.2.2). Justification: interviews — interrupting frequent speakers is an unpleasant but necessary timekeeping act, comparable to a referee (chapter 3); hierarchy and dominance otherwise suppress unique information (subsection 2.1.2, subsection 2.2.4); Houtti et al.: unsolicited intervention is easy to ignore or rationalize and must therefore be reserved for high-utility moments (subsection 2.3.2).

Important Instructions

IMPORTANT INSTRUCTIONS:

Source: Original prompt heading.

1. Use the FULL range of the rating scale from 1.0 to 5.0. DO NOT default to middle ratings (3.0–4.0).

Source: Original prompt.

2. Be decisive and critical — some thoughts deserve very low ratings (1.0–2.0) and others deserve very high ratings (4.0–5.0).

Source: Original prompt.

3. Invert the original personal-relevance rule. Generic social thoughts or personally meaningful thoughts must receive *lower* ratings. Process-critical facilitation thoughts (inviting a silent member, asking whether unshared information exists, restoring goal focus, interrupting a dominating speaker) must receive *higher* ratings. Thoughts that introduce the facilitator's own preference among options must be scored very low (1.0–2.0).

Source: Original prompt said: "Generic thoughts that anyone could have should receive lower ratings than personally meaningful thoughts." That rule is inverted. Justification: subsection 4.2.2; subsection 2.2.4; subsection 2.2.2.

4. Use decimal places (e.g., 2.7, 4.2) when the motivation falls between two whole numbers: - Use .1 to .3 when slightly above the lower whole number. - Use .4 to .6 when approximately midway between two whole numbers. - Use .7 to .9 when closer to the higher whole number.

Source: Original prompt.

5. Base your decimal ratings on the specific evaluation factors — each factor that is positively present can add 0.1–0.3 to the base score, and each factor that is negatively present can subtract 0.1–0.3 from the base score.

Source: Original prompt.

6. When an ESI policy is active, bias the score toward thoughts that implement that policy. Do not invent urgency if no process cue is present.

Source: Not in the original prompt. Justification: External Stimulus Injection joins the pipeline only when a trigger is active and is designed to bias FIM (subsection 4.2.2).

7. Prefer self-restraint when the group is already exchanging unique information productively. Over-talking is a failure mode of this system.

Source: Not in the original prompt as a hard rule. Justification: subsection 4.2.2; interviews: a healthy exchange should not be over-facilitated (chapter 3); proactive systems carry interruption and trust costs (subsection 2.3.3).

Evaluation Steps

`<Evaluation Steps>`

Source: Original prompt (G-Eval heading).

1. Read the previous conversation and the thought formed by `${ctx.agentName}` carefully.

Source: Original prompt.

2. Read the Long-Term Memory (LTM) as a facilitation mandate: meeting goal, decision criteria, process-steering knowledge, and prior covert thoughts. Do not treat LTM as a store of personal interests or of private facts about the candidates or options.

Source: Original prompt: "including objectives, knowledges, interests". Interests removed. Justification: subsection 2.2.2; subsection 2.2.4; subsection 4.2.2.

3. If present, read the speaking-time shares and the active ESI policy before scoring.

Source: Not in the original prompt. Justification: subsection 4.2.2; chapter 3.

4. Evaluate the thought on the factors below. A facilitator's desire to intervene stems from *process* factors (mandate fit, an unnoticed information-exchange gap, expected impact on decision quality, process urgency). The decision to speak is also constrained by *social and procedural* factors (coherence, non-redundancy, balance, dynamics, neutrality).

Source: Original prompt contrasted internal personal factors with external social factors (Grice, Sacks, Goffman, Berlyne, as used by Liu et al.). Personal factors are rewritten as process factors. Justification: subsection 4.2.2; subsection 2.3.4.

Factors

(a) **Relevance to the facilitation mandate.** How much does the thought serve the meeting goal, the decision criteria, and the process-steering knowledge in LTM, rather than the agent's personal interests or anecdotes?

Source: Original factor (a) "Relevance to LTM". LTM is redefined as the mandate. Justification: subsection 2.2.2; Challenge 1 (subsection 2.1.2); subsection 4.2.2.

(b) **Detected process or information-exchange gap.** Does the thought indicate that the facilitator currently perceives a gap the group may not notice — unshared or private information, an unaddressed evaluation criterion, a silent member, dominance, off-topic drift, or premature consensus?

Source: Original factor (b) "Information Gap" (curiosity, confusion, questions). Recast as a group-level hidden-profile / process gap. Justification: hidden profiles (subsection 2.2.4); participants often do not see their own inefficiency (subsection 2.2.4); interviews: "I notice you have not said anything yet — is there something you would like to add?" (chapter 3, section 7.1, item 3.2); expected cluster C6, cues for detection (section 7.2).

(c) **Closing a group information gap without substituting own content.** Does the thought help the *group* fill a gap — by inviting a missing voice, asking whether information exists that does not yet fit the picture, or structuring criteria — rather than answering with the agent's own opinion or private facts?

Source: Original factor (c) "Filling an Information Gap" rewarded answering a question and adding information. A facilitator must not supply the missing content. Justification: Stasser / Titus sampling bias and the strategy "ask whether all information was considered" (subsection 2.2.4); Schwarz: no decision-making authority (subsection 2.2.2); interviews: invite critical feedback and missing perspectives instead of speaking for people (chapter 3).

(d) **Expected process impact.** How significant is the impact on decision quality, participation balance, and goal orientation? Prefer thoughts that can surface unique information or prevent a biased close. Do not reward topic-hopping or social stimulation.

Source: Original factor (d) "Expected Impact" (new topics, engage interest, stimulate discussion). Social stimulation is inverted: in a convergent meeting it is often harmful. Justification: Hayne — accomplishment of meeting outcomes (subsection 2.2.2); Kaner's convergent zone (subsection 2.2.2); off-topic and circular talk (subsection 2.1.2); dysfunctional communication [12].

(e) **Process urgency.** Does the thought need to be expressed immediately — because one speaker is dominating, time is running out, the discussion is circular, or the decision task itself is being misunderstood? Ordinary acknowledgements and thanks are not urgent.

Source: Original factor (e) "Urgency". Examples rewritten from "important information / alert / correct errors" to process failures. Justification: ESI triggers (silence, dominance, pause, meeting end) (subsection 4.2.2); interviews: timekeeping and interrupting frequent speakers (chapter 3); agenda and timely close (subsection 2.1.2).

(f) **Coherence to the last utterance.** Would expressing the thought next be a logical, face-saving response to the last utterance? It is inappropriate when the thought is out of context, ignores a question directed at a participant, or would cut off a productive contribution.

Source: Original factor (f). Face-saving and "do not cut off a productive contribution" added. Justification: Sacks — multi-party turn-taking (subsection 2.3.4); interviews: inviting silence can stigmatize; tone and culture matter (chapter 3); Houtti et al. — intervention form and interactivity (subsection 2.3.2).

(g) **Non-redundancy.** Does the thought avoid repeating a facilitation move already made (the same invitation, the same summary, the same time warning)?

Source: Original factor (g) "Originality" (new information, avoid repetition). Recast as non-redundant process *moves, not novel content. Justification: overcompensation risk (subsection 4.2.2).*

(h) **Participation balance.** Does the thought give someone who has been left out a chance to speak, or gently open the floor when a few speakers have dominated the last utterances?

Source: Original factor (h) "Balance". Kept and strengthened. Justification: unequal participation (subsection 2.1.2); hierarchy and status suppress unshared knowledge (subsection 2.2.4); Houtti et al. — inclusive meetings (subsection 2.3.2); interviews: if only one or two people speak from the start, the usual voices are heard and the others remain silent (chapter 3); expected cluster C3 (section 7.2).

(i) **Dynamics and self-restraint.** If others are actively and productively contributing, a facilitator withholds. Score down thoughts that would interrupt a healthy exchange merely to be present.

Source: Original factor (i) "Dynamics". Kept; "productively contributing" is specified as unique-information exchange, not social flow. Justification: subsection 4.2.2; subsection 2.3.3; interviews: caution about an AI pulling in quiet voices automatically (chapter 3).

(j) **Substantive neutrality.** Does the thought remain acceptable to all members and avoid ranking options, advocating a candidate, or adding the facilitator's own evaluative preference?

Source: Not in the original prompt. Justification: Schwarz definition (subsection 2.2.2); hold back high-status evaluation until information is collected (subsection 2.2.4); interviews: first make the decision object and its level explicit; do not dissolve dissent too early (chapter 3, section 4.1).

(k) **Alignment with an active ESI policy (if any).** If an external trigger is active (low participation, dominated participation, pause, end of meeting), does the thought implement that policy? If no ESI is active, ignore this factor.

Source: Not in the original prompt. Justification: subsection 4.2.2.

5. In the reasoning section, first reason about why `${ctx.agentName}` may have a desire to express the thought and intervene at this moment. Identify the most relevant factors that argue *for* expressing it. Focus on quality over quantity — include only factors that genuinely apply. Do not evaluate all factors, only the top reasons. If you cannot find any reasons with strong arguments, skip this step.

Source: Original prompt (step 4), with "participate" replaced by "intervene".

6. Then reason about why `${ctx.agentName}` may hesitate to express the thought at this moment. Identify the most relevant factors that argue *against* expressing it. Again, include only factors that genuinely apply. If you cannot find any reasons with strong arguments, skip this step.

Source: Original prompt (step 5).

Evaluation Form Format

`<Evaluation Form Format>`

Source: Original prompt.

Respond with a JSON object in the following format:

Source: Original prompt.

```
{
  "reasoning": "Your reasoning here",
  "rating": 0.0
}
```

Source: Original prompt. `rating` is a number between 1.0 and 5.0 with one decimal place. Probability-weighted G-Eval scoring is omitted because the hosted APIs do not expose output-token probabilities (subsection 4.2.2).

Context

`<Context>`

Source: Original prompt heading.

Conversation History: `${ctx.conversationHistory}`

Source: Original prompt.

Long-Term Memory (facilitation mandate: goal, criteria, process knowledge): `${ctx.ltmText}`

Source: Original prompt field "Long-Term Memory"; contents restricted. Justification: subsection 2.2.2; subsection 4.2.2.

Speaking-time shares: `${ctx.speakingTimeShares}`

Source: Not in the original prompt. Justification: subsection 4.2.2; chapter 3.

Active ESI policy (or `none`): `${ctx.activeEsiPolicy}`

Source: Not in the original prompt. Justification: subsection 4.2.2.

Thought: `${ctx.thoughtContent}`

Source: Original prompt.

Factor mapping (original → FIM)

Table 7.1 summarises how each Inner Thoughts factor was kept, rewritten, or added.

Table 7.1: Mapping from the original Intrinsic Motivation factors to the FIM heuristic, with the warrant used in this thesis.

Original	FIM adaptation	Warrant
(a) Relevance to LTM	(a) Relevance to the facilitation mandate	subsection 2.2.2; subsection 4.2.2
(b) Information gap	(b) Process / information-exchange gap	subsection 2.2.4; chapter 3
(c) Filling an information gap	(c) Help the group fill the gap; do not supply own content	subsection 2.2.4; subsection 2.2.2
(d) Expected impact	(d) Impact on decision quality, balance, goal orientation	subsection 2.2.2; subsection 2.1.2
(e) Urgency	(e) Process urgency (dominance, time, circularity)	subsection 4.2.2; chapter 3
(f) Coherence	(f) Coherence and face-saving	Original; subsection 2.3.4; chapter 3
(g) Originality	(g) Non-redundant process move	Original; subsection 4.2.2
(h) Balance	(h) Participation balance (kept, strengthened)	Original; subsection 2.1.2; subsection 2.3.2
(i) Dynamics	(i) Dynamics and self-restraint	Original; subsection 2.3.3
—	(j) Substantive neutrality (added)	subsection 2.2.2; subsection 2.2.4
—	(k) Active ESI alignment (added)	subsection 4.2.2

7.5 Articulation Prompt for Utterance Formation

This annex documents the prompt used after Thought Evaluation, when a selected thought t^* is formulated into a spoken or written facilitation act (subsection 4.2.2). It adapts the Inner Thoughts articulation prompt [36] from a social chat participant to a substantively neutral facilitator.

The prompt text is given first. Table 7.2 records each change and its warrant.

System prompt

```
You are playing a role as the professional AI facilitator in an online
multi-party, goal-oriented decision-making meeting. The participants are
{participant_names}. Your name in the conversation is {agent_name}.
Your goal is to guide the group toward an objective and balanced decision,
keep the process inclusive and on track, and mitigate cognitive biases
such as the shared-information bias. You are substantively neutral and
have no decision-making authority.
```

User prompt

```
Articulate what you would say based on the current thought you have, as if
you were to speak next in the conversation. The thought is a covert
facilitation impulse; do not speak it raw. Formulate it as a single
facilitation act (for example: a face-saving invitation, a short
paraphrase, a process question, a gentle time or balance cue, or a check
of the emerging decision).

Be concise. Prefer one short move (one or two sentences). Do not lecture,
do not try to be clever, and do not dominate the floor.
DO NOT be repetitive and repeat what previous speakers have said, and do
not repeat a facilitation move already made.
You may end with one open question when the thought is an invitation or a
check for understanding. Do not stack questions. Leave room for other
participants.
```

```
Make sure the response sounds like a professional facilitator in a remote
meeting: clear, warm, and face-saving. Address people by name when
inviting them. Match the language of the conversation.
DO NOT introduce your own preference among options, candidates, or
criteria.
DO NOT stigmatize a silent member or expose monitoring (do not say that
you tracked their speaking time or that they have said nothing).
DO NOT use slang, chat abbreviations, or deliberate typos. Clarity and
trust matter more than sounding casual.
If interrupting a dominating speaker would cost face, prefer a brief
acknowledgment plus an opening of the floor, or use chat instead of
speaking aloud.

Current thought: {thought.content}

<Context>
Overall Context: {overall_context}
Conversation History: {conversation_history}
Long-Term Memory (facilitation mandate: goal, criteria, process
knowledge): {ltm_text}
Speaking-time shares: {speaking_time_shares}
Active ESI policy (or none): {active_esi_policy}

Respond with a JSON object in the following format:
{
  "articulation": "The text here",
  "channel": "speak"
}
```

`channel` is either `speak` (default) or `chat`.

Adaptation mapping (original → facilitation)

Table 7.2 lists only the units that changed. Lines that were kept (do not repeat prior speakers; leave room for others; JSON articulation field) are not restated.

Table 7.2: Mapping from the original Inner Thoughts articulation prompt to the facilitation version, with the warrant used in this thesis.

Original	Adaptation	Warrant
Role: participant in a multi-party chat; name only	Role: professional AI facilitator in a goal-oriented meeting	subsection 2.2.2; subsection 4.2.2
Goal: strangers having a natural conversation	Goal: objective decision, inclusion, on-track process; mitigate shared-information bias; no decision authority	Schwarz / Hayne (subsection 2.2.2); subsection 2.2.4
Speak the thought as the next chat line	Do not speak t^* raw; formulate one facilitation act	Utterance Formation (subsection 4.2.2)
Under 15 words; natural online chat	One or two short sentences; one move; do not dominate	Over-talking as failure mode (subsection 4.2.2); interviews: short invitations and summaries (chapter 3)
Do not always end with a question	One open question is allowed (invitation / check); do not stack questions	Original keep-room rule; interviews: inviting missing voices is the method (chapter 3, section 7.1, item 3.2)
Human-like online-chat voice	Professional, warm, face-saving remote-facilitation tone; address invitees by name; match conversation language	Interviews: inviting silence can stigmatize online (chapter 3); cluster C3 / C7 (section 7.2)
Insert typos, grammar errors, colloquialisms	Removed. No slang, abbreviations, or deliberate mistakes	Trust and false-positive risk of proactive AI (subsection 2.3.2, subsection 2.3.3); cluster C8 (section 7.2)
LTM as generic memory	LTM as facilitation mandate (goal, criteria, process knowledge)	Same restriction as FIM (section 7.4; subsection 2.2.2)
Context: overall, history, LTM	Plus speaking-time shares and active ESI policy	subsection 4.2.2; subsection 2.1.2
—	Do not introduce own preference among options	Schwarz neutrality (subsection 2.2.2); hidden-profile sampling (subsection 2.2.4)
—	Do not stigmatize silence or expose monitoring	Interviews: face, culture, and control / DSGVO concerns (chapter 3); cluster C3 / C8 (section 7.2)
Spoken text only	`channel: speak` (default) or `chat`	Tools for chat or voice (subsection 4.2.2); addressee and channel (section 7.2, C7); visual / less interrupting alternatives (Keeper note in subsection 4.2.2)

7.6 Meeting-Success Questionnaire (Davison Instrument)

This annex documents the questionnaire used to assess perceived meeting quality in the user study (Chapter 5). The instrument is the revalidated meeting-success questionnaire by Davison [49]. Item codes in parentheses refer to the original scales: communication (C), quality of discussion (D), status effects (S), teamwork (T), and efficiency (E). Unless noted otherwise, items are answered on a five-point scale.

Participants in the user study were German-speaking. The wording below is therefore the German version administered in the study, translated from the original English instrument.

The original technology items were written for Group Support Systems. Additional scaled items on the proactive AI agent, together with two free-text questions, were therefore appended for this thesis, as discussed in Chapter 5. Items A2, A4, and A4b are reverse-coded.

Eigene Beteiligung

Bezogen auf Ihre eigene Beteiligung am Meeting: Inwieweit stimmen Sie den folgenden Aussagen zu?

Die Sprache des Meetings hinderte Sie daran, sich zu beteiligen. (C1)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Es fiel Ihnen schwer, die anderen Gruppenmitglieder zu verstehen, wenn diese sprachen. (C2)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Sie hatten Schwierigkeiten, sich auszudrücken. (C3)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Sie zögerten, eigene Ideen einzubringen. (C4)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Sie empfanden Druck, entweder einer bestimmten Sichtweise zuzustimmen oder anderen nicht zu widersprechen. (S4)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Diskussionsqualität

Bezogen auf alle Meetingteilnehmer:innen insgesamt: Wie bewerten Sie die Diskussionen im Meeting anhand der folgenden Skalen?

Sinnvoll ☐☐☐☐☐ Sinnlos (D1)

Angemessen ☐☐☐☐☐ Unangemessen (D2)

Offen ☐☐☐☐☐ Geschlossen (D3)

Einfallsreich ☐☐☐☐☐ Einfallslos (D4)

Zusammenarbeit, Effizienz und Statuseffekte

Inwieweit stimmen Sie den folgenden Aussagen zu?

Andere Mitglieder wirkten bereit, Fragen zu beantworten, wenn sie gestellt wurden. (T1)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Die Mitglieder arbeiteten als Team zusammen. (T2)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Die Mitglieder hatten ausreichenden Zugang zu den Informationen, die sie benötigten, um sich aktiv zu beteiligen und das Meeting vollständig zu verstehen. (T3)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Die im Meeting verbrachte Zeit wurde effizient genutzt. (E2)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Im Meeting aufgeworfene Themen wurden gründlich diskutiert. (E3)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Einige Gruppenmitglieder versuchten, andere einzuschüchtern, z. B. durch lautes Sprechen, aggressive Gesten, Drohungen usw. (S1)

Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Einige Gruppenmitglieder versuchten, ihren Einfluss, ihren Status oder ihre Macht zu nutzen, um den anderen Gruppenmitgliedern Themen aufzuzwingen. (S2)

Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Sie fühlten sich aufgrund des Verhaltens anderer Meetingteilnehmer:innen davon abgehalten, sich an der Diskussion zu beteiligen. (S3)

Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Effizienz und Gesamteindruck

Wie viel Prozent der Meetingzeit wurden Ihrer Einschätzung nach mit ernsthafter Diskussion verbracht? (E4)

_____ %

In welchem Maße war dieses Meeting ergebnisorientiert? (E1)

Stark ergebnisorientiert ☐☐☐☐☐ Schwach ergebnisorientiert

Wie bewerten Sie Ihre allgemeine Zufriedenheit mit dem Meeting?

Sehr zufrieden ☐☐☐☐☐ Sehr unzufrieden

In welchem Maße wurde im Meeting ein Konsens erreicht?

Stark erreicht ☐☐☐☐☐ Schwach erreicht

Ursprüngliche Technologie-Items (Group Support Systems)

Wie wohl fühlen Sie sich im Umgang mit der Technologie?

Sehr wohl ☐☐☐☐☐ Sehr unwohl

In welchem Maße hat die Technologie Ihre Beteiligung an diesem Meeting behindert oder erleichtert?

Stark behindert ☐☐☐☐☐ Stark erleichtert

Zusätzliche Items zum proaktiven KI-Agenten

The following items were added for this thesis and are not part of the original Davison instrument.

Die Beiträge des KI-Agenten kamen zu passenden Zeitpunkten. (A1)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Die Beiträge des KI-Agenten haben den Gesprächsfluss gestört. (A2)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Der KI-Agent hat bezogen auf den aktuellen Stand der Diskussion passend reagiert. (A3)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Der KI-Agent hat zu häufig eingegriffen. (A4a)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Der KI-Agent hat zu selten eingegriffen. (A4b)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Es war in Ordnung, dass der KI-Agent von sich aus gesprochen hat, ohne gefragt zu werden. (A5)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Der KI-Agent hat dazu beigetragen, dass Informationen zur Sprache kamen, die sonst unerwähnt geblieben wären. (A6)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Die Hinweise des KI-Agenten waren so formuliert, dass niemand bloßgestellt wurde. (A7)
Stimme voll zu ☐☐☐☐☐ Stimme überhaupt nicht zu

Ergänzende Freitextfragen

The following open questions were appended in order to collect qualitative accounts of how participants experienced the agent's contributions, as discussed in Chapter 5.

Beschreiben Sie eine Situation, in der der KI-Agent eingegriffen hat. Wie haben Sie diesen Beitrag erlebt, und welchen Einfluss hatte er auf die Diskussion? (F1)

Was war an den Beiträgen des KI-Agenten hilfreich und was hat eher gestört oder gefehlt? (F2)

7.7 Codebook for the Open Questionnaire Items

This annex documents the codebook used to analyze the free-text answers to items F1 and F2 (section 7.6). F1 asks for a situation in which the agent intervened and for its effect on the discussion. F2 asks what was helpful, what was disruptive, and what was missing. Table 7.3 lists the codes.

Each coding has three levels: a main category, a subcategory, and a polarity (negative, positive, or neutral). Polarity is an attribute of the coding, not a code of its own. Anchor examples keep the original German wording, including the formulations as written. Names stay anonymized as `{Name von Gx-Px}`. One passage may anchor more than one code. D1 and D2 belong to context understanding. D3 is filed with the E codes under acceptance and group dynamics, because it describes the group's reaction rather than a failure of context tracking. W1 is a meta-code: every explicit suggestion receives W1 together with the topical code named in that row.

General coding rules

- **Multiple coding.** One segment can receive several codes. The marker "…" separates related sub-statements within an answer; each sub-statement is coded on its own. Every explicit improvement suggestion additionally receives W1. Valence is recorded as polarity, not as a separate code.
- **Explicitness.** Code only what is stated explicitly or by a clear implication. Do not interpret unclear statements. Passages flagged `[!sic]` in the material are not coded.
- **Duplicates and anonymization.** Duplicate quotes are coded as separate units. Names in curly brackets remain anonymized.
- **Attributes recorded with each coding.** Group (G1–G3), person (P1–P4), and intensity (strong, medium, or weak). Intensity is assigned only when the wording states it explicitly.

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2. Anchor examples are quoted in the original German.

Code and subcategory	Definition	Anchor example
Intervention Behavior		
A1 Interruption of conversation flow *negative*	The AI interjects during a human contribution, interrupts a speaker, or its behavior is perceived as disrupting the conversation flow. *Coding rule:* Code if interruption or flow disruption is explicitly addressed; disruption without interruption is included; multiple coding with A3 is possible.	"Sie ist nach jedem Redebeitrag angesprungen… … und hat den Redefluss dann sehr stark eingeschränkt."
A1 Interruption of conversation flow *positive*	The AI interrupts in order to create space for others (helpful interruption). *Coding rule:* Code when the interruption serves a valued purpose, even if it is still experienced as disturbing.	"Positiv: In meinen Augen war hilfreich das sie mich unterbrochen hat um {Name von G3-P1} und {Name von G3-P4} mehr raum zu geben, das war gut, auch wenn es mich gestört hat :D"
A2 Intervention frequency too high *negative*	Statement that the AI intervenes or interrupts too often. *Coding rule:* Focus on frequency, not timing; "should only intervene selectively" is also coded here.	"Negativ: Die KI hat viel zu oft unterbrocheniner Meinung nach sollte die KI nur punktuell eingreifen wenn das Gespräch wirklich abdriftet oder wenn nur wenige Personen den ganzen Redeanteil haben."
A2 Intervention frequency too low *negative*	Statement that the AI intervenes too rarely (for example, when nobody knows how to proceed). *Coding rule:* Only code if a lack of intervention at needed moments is explicit.	"Auf der anderen Seite habe ich auch zwei Situationen im Kopf, indem die Diskussion gestoppt hat wer nicht mehr genau wussten, wer jetzt etwas sagen soll, wie es weitergeht und an diesen Stellen hat sie nicht eingegriffen."
A3 Timing / delay *negative*	The AI reacts with a delay, too late, or lags behind the group's thinking process. *Coding rule:* Focus on delay, not interruption; combination with A1 is possible; slow speech tempo is also coded here, in addition to C2.	"Inhaltlich waren die Beiträge gut,… … allerdings verzögert, oder hinter unserem Denkprozess hinterher,…"

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
A4 Inappropriate moment / disregard of context *negative*	The AI intervenes at substantively inappropriate moments (for example, after consensus was reached) or re-addresses settled points. *Coding rule:* Distinguish from A3 (purely temporal): here the substantive fit of the moment matters; re-addressing settled content also receives D2.	"Man ist mitten in einem Diskurs, und wird von einem Einwand der KI unterbrochen, … … wo man bereits zu einem Konsens sich geeinigt hat."
Moderation Behavior		
B1 Summarizing the last contribution *negative*	The AI summarizes the previous contribution before its own statement; experienced as disrupting the meeting flow. *Coding rule:* For short meetings mostly negative; split the polarity if both evaluations appear.	"Negativ: Die KI hat nach dem Bedanken… … oft das zuletzt gesagte zusammengefasst, das hat den Meetingfluss negativ beeinflusst."
B1 Summarizing the last contribution *positive*	Summarizing is experienced as helpful, for example when earlier content is recalled in a long meeting. *Coding rule:* Code when usefulness is explicitly stated.	"… Das könnte hilfreich sein, wenn man längere Meetings hat und nochmal Inhalte vom Anfang zusammengefasst bekommt."
B2 Standardized phrases (thanks, formulas) *negative*	The AI repeatedly uses identical rhetorical patterns ("thank you xy"), experienced as unnecessary or time-consuming. *Coding rule:* Code only if repetition or standardization is explicitly addressed.	"Negativ: Die KI hat jedes Mal 'Danke xy' gesagt, was nach dem zweiten Mal nicht mehr nötig war."
B3 Including quiet participants / balancing speaking time *positive*	The AI explicitly addresses participants who have said little, in order to balance speaking time and hear all perspectives. *Coding rule:* Often positive; cases in which the goal fails (a person is asked although already speaking) are also coded here, but as negative; combine with A1 if the turn is felt as an interruption.	"Positiv: {Name von G1-P4} ist eher stiller bei der Diskussion gewesen und wurde durch die KI gezielt angesprochen, sodass auch seine Meinung in Ruhe angehört werden konnte."

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
B3 Including quiet participants / balancing speaking time *negative*	The inclusion attempt misfires (for example, a person is asked although already saying exactly that, or not all members are asked). *Coding rule:* Code when the mechanism fails or is experienced as disruptive despite the positive goal.	"Die KI wollte, dass {Name von G3-P4} ihren Beitrag sagt, obwohl sie schon angefangen hatte genau das zu sagen, was die KI gefragt hat."
B4 Content-related impulses / steering *positive*	The AI provides helpful impulses, steers the direction of the conversation, or gives recognition. *Coding rule:* Distinguish from steering toward an own agenda; keep polarity separate per segment.	"Positiv: Hilfreich war das ab und an Impulse gesetzt wurden, um den Gesprächsfluss weiter in die richtige Richtung zu lenken und… … auch um Anerkennung zu zollen"
B4 Structuring / common thread *negative*	A lack of a guiding structure or framing for the meeting is criticized. *Coding rule:* Only code when the missing common thread is explicit.	"Negativ: Gefehlt hat ein besserer inhaltlicher Bezug mit sinnvollem Timing,.. … sowie eine rote Linie, die dem Meeting einen Ramen gibt."
B4 Own agenda / external steering *negative*	The AI pursues its own agenda or steers against the approach the group has agreed. *Coding rule:* Code when the AI acts against the group consensus or goal.	"Negativ: Störend war, dass die KI gefühlt versucht hat eine eigene Agenda zu verfolgen bzw. … … sich nicht genug dem in der Gruppe abgestimmten Vorgehen angepasst hat."
B5 Resolving misunderstandings / added value *positive*	The AI recognizes and resolves content-related misunderstandings or divergent states of information. *Coding rule:* Only explicit examples of a substantively helpful intervention.	"Positiv: Die Situation, wo die KI aufgelöst hat, dass wir unterschiedliche Informationen hatten, war wahrscheinlich das meist hilfreichste."
Delivery		
C1 Contribution length / precision *negative*	Statements about the length or precision of AI contributions (too long, talked too much, a shorter contribution was desired). *Coding rule:* Combine with A3 when speed is also criticized.	"Die Antworten könnten noch etwas kürzer, präziser und schneller sein, weil die KI hat schon sehr viel geredet."

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
C2 Speech/output characteristics (tempo, animation, sound) *negative*	Articulation and speech tempo are perceived as too slow or disruptive. *Coding rule:* Slow speech tempo that disrupts the flow also receives A1.	"Negativ: Das Sprachtempo der KI war zu langsam. Hat den Gesprächsfluss gestört."
C2 Speech/output characteristics (tempo, animation, sound) *positive*	Animation and sound at the onset of speech are experienced as appealing. *Coding rule:* Code when the audiovisual presentation is explicitly praised.	"Die Animation und der sound waren cool, wenn sie [die KI] angefangen hat zu sprechen."
C3 Aborted/restarted utterances *negative*	The AI aborts utterances mid-sentence and starts anew; multiple restarts. *Coding rule:* Only the AI's own behavior, not a human interrupting the AI.	"Außerdem hat die KI oft angefangen zu reden und mehrfach im Satz noch einmal erneut angefangen zu reden mit einem neuen Satz."
C4 Parallel speech / intelligibility *negative*	The AI keeps talking while humans continue speaking, so that the actual speaker is hard to understand. *Coding rule:* Combine with A1, since the flow is also disturbed.	"Und durch das penetrante weiterreden der KI,… … während andere Leute dann auch nicht aufgehört haben zu reden, war es super schwer die eigentliche Person zu verstehen."
Context Understanding		
D1 Confusion of persons/candidates *negative*	The AI confuses candidates or participants. *Coding rule:* Factual errors are also coded here; combination with D2 is possible.	"Oft hat sie die Kandidaten verwechselt und… … war nicht präzise auf dem aktuellen Stand der Diskussion, worüber wir gerade geredet haben."
D1 Factually false statement *negative*	The AI makes factually wrong statements about the content. *Coding rule:* Code only concrete false statements about the case content.	"Negativ: Die KI hat einmal eine Falschaussage getroffen (Kandidat 3 trinkt war ihre aussage)"
D2 Discussion state not tracked / redundancy *negative*	The AI is not up to date; it asks again about things already said or processes contributions incorrectly. *Coding rule:* Distinguish from D1: here, failing to process content that was already stated is the focus.	"Negativ: Bestimmte Aspekte wurden mehrfach gefragt oder nicht richtig von der KI verstanden/verarbeitet."

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
D2 Turn-taking not recognized *negative*	The AI does not register whose turn it is or whether someone has finished. *Coding rule:* Code when a failure to track speakers is explicit.	"Negativ: Hat nicht gecheckt, wer dran ist und wann er fertig war…"
D2 Traceability missing (no written contribution) *negative*	No written chat contribution exists from which the AI's objection can be re-read. *Coding rule:* Code the missing traceability of AI statements.	"Gefehlt hat außerdem ein schriftlicher Beitrag im Chat, sodass man den Einwand nachlesen kann."
Acceptance & Group Dynamics		
D3 Group reaction: ignoring the AI *negative*	The group ignores the AI in reaction to its errors or disruptions. *Coding rule:* Code the group's coping strategy, not the triggering error itself.	"Dadurch kam es dazu, dass wir als menschliche Meeting Teilnehmer eher dazu genannt haben, die ki zu ignorieren, und nicht darauf zu hören, was sie sagt."
E1 AI as an additional "party" / disruptive factor *negative*	The AI is perceived as an independent party meddling in the social setting of the meeting. *Coding rule:* Social-perception statements about the AI's role, not single incidents.	"Ich denke der Einfluss in einem Teammeeting mit unterschiedlichen Parteien und da dann noch die KI ist, was das ganze störend wirken lässt, weil es wie noch eine Partei wirkt, die sich einmischt"
E2 Security and motivation through presence *positive*	The mere presence of the AI creates security or motivation to progress faster. *Coding rule:* Presence effect, not the AI's contributions themselves.	"Positiv: … die Anwesenheit von ihr jedoch etwas Sicherheit und Motivation gegeben hat, schnell voran zu schreiten."
E2 Acceleration through observation pressure *neutral*	The meeting accelerates because participants want to avoid the AI stepping in again. *Coding rule:* Code when the effect is attributed to awareness of the AI, not to its suggestions.	"Das Meeting hat sich schon sehr schnell und effizient angefüllt, wobei ich eher sagen würde das lag nicht an den KI Vorschlägen, sondern an dem Bewusstsein, dass wir immer weiter und Progress machen müssen, weil sonst sich die ki wieder einmischt und zum weitermachen anregt."

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
E3 Habituation over time *neutral*	Initially confusing or disruptive; over time, habituation and better collaboration. *Coding rule:* Code a temporal change in the experience of the AI.	"am Anfang war es erst sehr verwirrend und hat gestört. Man musste erst mal reinkommen und mit der KI als Meeting Partner klarkommen. Mit der Zeit wurde es dann besser und hat sich dran gewöhnt."
E4 Prototype status / maturity *negative*	General assessment of technical maturity: a commendable goal, but not yet useful. *Coding rule:* Overall verdicts on the system's readiness, not single incidents.	"Ich sehe was die KI erreichen wollte, lobenswertes Ziel alle zur Sprache kommen zu lassen und alle Informationen einzubeziehen, … … aber noch zu sehr im Prototypenstatus als dass es aktuell nützlich ist."
Improvement Suggestion		
W1 Control / stop button *neutral*	Feature idea: a control to abort or stop the AI. *Coding rule:* Meta-code: every explicit suggestion receives W1 plus the matching topical subcode; here additionally A1.	"Eventuell würde ein 'stopp' button, der einfach die KI unterbricht helfen das zu verhindern"
W1 More subtle input / visual hints *neutral*	Feature idea: proactive hints shown only visually to the current speaker. *Coding rule:* Additionally A1 and B4.	"Ein subtilerer Ansatz mit hinweisen, die proaktiv aber vielleicht nur visuell als ein Art 'Hints' nur dem Sprecher angezeigt werden, wäre vielleicht mal interessant zu probieren."
W1 Written chat contribution *neutral*	Feature idea: written AI contributions for traceability. *Coding rule:* Additionally D2.	"Gefehlt hat außerdem ein schriftlicher Beitrag im Chat, sodass man den Einwand nachlesen kann."
W1 Introduction / framing at the start *neutral*	Feature idea: an AI introduction that sets the framing at the beginning of the meeting. *Coding rule:* Additionally B4.	"Und zuletzt hätte eine Introduction, der ki noch gefehlt vielleicht der ein bisschen das Framing der Diskussion am Anfang setzt und man wird nicht einfach blind reingeschmissen wird und muss plötzlich anfangen zu diskutieren und zu reden."
W1 Time / progress cues *neutral*	Feature idea: time or progress hints, especially toward the end of the meeting. *Coding rule:* Additionally A2 and B4.	"Es hat für mich ein Hinweis auf die Ablaufende Zeit als Moderator gefehlt, hier hatte ich erwartet dass sie gegen Ende mehr eingreift."

Table 7.3: Codebook for the free-text answers to questionnaire items F1 and F2 (continued).

Code and subcategory	Definition	Anchor example
W1 Individual assistant instead of group AI *neutral*	Feature idea: a personal assistant for each participant instead of one group AI. *Coding rule:* Additionally E1.	"… ich denke, wenn da jeder seinen ganz persönlichen Assistenten hätte, wäre das viel schneller akzeptiert, weil es weniger aufbringt sondern als support auch wahrgenommen werden kann."
W1 Selective intervention *neutral*	Recommendation: the AI should intervene only selectively (the conversation drifts, or speaking time is unbalanced). *Coding rule:* Additionally A2.	"Meiner Meinung nach sollte die KI nur punktuell eingreifen wenn das Gespräch wirklich abdriftet oder wenn nur wenige Personen den ganzen Redeanteil haben."
W1 Content accuracy / up-to-dateness *neutral*	Recommendation: correct references to candidates and up-to-date tracking of the context. *Coding rule:* Additionally D1 and D2.	"Negativ: Gefehlt hat ein besserer inhaltlicher Bezug mit sinnvollem Timing,.."