

Bachelor Thesis

Proactive AI moderation for goal-oriented remote meetings: Design and acceptance of a context-sensitive system to support convergent decision-making processes

Bachelor thesis in the department of Computer Science by Oliver Hönig

Date of submission: 22.10.2026

1. Review: Prof. Dr. Jan Gugenheimer

2. Review: Yanni Mei

Darmstadt



TECHNISCHE
UNIVERSITÄT
DARMSTADT

Computer Science
Department

HCI

Human Computer
Interaction

Note on the Use of Artificial Intelligence

AI applications were used to edit the language of this work. The content, argumentation, and academic evaluation were developed independently by the author.

AI applications were used to assist with research in the preparation of this work. The academic review, selection, and classification of the content were carried out by the author.

AI-based programming tools were used to assist in the implementation of the prototype. This was done in consultation with the supervising examiners.

Since English is not the author's native language, DeepL [1] was used in some places to translate sections of German text written by the author into English.



Zusammenfassung



Abstract

Contents

1	Introduction	1
1.1	General Problem and Relevance	1
1.2	Research Objectives and Questions	2
1.2.1	RQ1: Facilitating strategies and challenges in goal-oriented remote meetings	3
1.2.2	RQ2: Design requirements for an AI-based moderation system . . .	4
1.2.3	RQ3: Perception of the meeting with a proactive AI moderator . . .	4
2	Theoretical Foundations	5
2.1	Remote Meetings (RQ1)	5
2.1.1	Meetings in Modern Work: Trends and Context	6
2.1.2	Key challenges: Off-topic discussions, unequal participation, lack of structure	6
2.2	Facilitation and Convergent Group Decision-Making (RQ1)	7
2.2.1	Group Support Systems and collaboration tools	7
2.2.2	The facilitator role	9
2.2.3	Divergent and Convergent Thinking in Meetings	10
2.2.4	Biases in information exchange (Hidden profiles)	10
2.2.5	Implications for AI support	13
2.3	AI in Meeting Support Systems (RQ2)	13
2.3.1	Overview of existing Meeting AI Tools	13
2.3.2	Research Approaches to AI-Supported Meeting-Systems	14
2.3.3	Interaction Paradigms in Human-AI Systems: Reactive, Proactive, and Mixed-Initiative	15
2.3.4	Proactive AI-Interactions: From Turn-Taking to intrinsic Motivation with the Inner Thoughts Framework	15
2.4	LLM-based AI-Systems and Agents in General (RQ2)	17
2.4.1	Prompt Engineering and Context Engineering	17

2.4.2	Building blocks for LLM-based Workflows and Agents	19
2.4.3	Evaluating and Testing of AI-Systems	24
3	Empirical Analysis of Facilitating Strategies (RQ1 & RQ2)	27
3.1	Methodology: Expert Interviews	27
3.1.1	Sampling: Purposeful selection of 5 facilitating experts	29
3.1.2	Data Collection: Conduction of semi-structured interviews (30 min)	29
3.1.3	Analysis: Thematic coding	29
3.2	Results: Facilitating Strategies and Challenges	30
3.2.1	Comparison with literature (Chapter 2)	30
3.3	Implications for AI System Design	30
3.3.1	Derived requirements for RQ2	30
4	System Design and Implementation of a Scoped Prototype (RQ2)	31
4.1	Requirements Analysis and Scope Definition	32
4.1.1	General Requirements	32
4.1.2	Scoped Requirements for the Prototype	34
4.2	System Architecture	34
4.2.1	Adapted version of the “Inner Thoughts” framework	34
4.2.2	Components: Transcription, Analysis, and Intervention Modules	38
4.2.3	Technology Stack: NLP Libraries, Backend/Frontend Frameworks	43
4.3	Prototype Development	43
4.3.1	Implementation Details	43
4.3.2	Limitations of the Prototype	43
4.4	Formativ Prototype Evaluation during Development	43
5	Empirical Prototype Validation (RQ2 & RQ3)	45
5.1	Methodology: Hidden-Profile Scenario and Questionnaire Instrument	45
5.1.1	Study Design	45
5.1.2	Sample	47
5.1.3	Data Collection	47
5.2	Results	47
5.2.1	Perceived Meeting Quality (Davison Instrument)	47
5.2.2	Participants’ Perception of the Proactive AI Moderator’s Interventions	47
5.3	Discussion	47
5.3.1	Implications for System Design	47
5.3.2	Theoretical Contributions	47
5.3.3	Practical Impact for Organizations	47

6	Conclusion	48
6.1	Summary of Findings	48
6.2	Limitations	48
6.3	Future Work	48
7	Appendix	54
7.1	Semi-Structured Interview Guide for Expert Interviews with Facilitators . .	55
7.2	Expected thematic clusters and coverage	59
7.3	Hidden Profile Exercise	60
7.4	FIM Scoring Prompt for Thought Evaluation	65
7.5	Articulation Prompt for Utterance Formation	75

List of Figures

1	Scope of the thesis: Primary focus and secondary focus, broken down by meeting phases – <i>Source: Own illustration, created with draw.io.</i>	3
2	Venn-Diagram: Prompt Engineering as a subset of Context Engineering – <i>Source: Own illustration, created with draw.io.</i>	18
3	AI-Building-Block:Prompt chaining: A complex task is decomposed into sequential LLM calls – <i>Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.</i>	20
4	AI-Building-Block:Routing: A complex task is decomposed into subtasks and routed to specialized systems – <i>Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.</i>	20
5	AI-Building-Block: Parallelization: Multiple tasks are processed in parallel and the results are aggregated programatically – <i>Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.</i>	21
6	AI-Building-Block: Orchestrator-workers: A central LLM decomposes a main task dynamically into subtasks and delegates them to a variable number of worker LLMs – <i>Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.</i>	22
7	AI-Building-Block: Evaluator-optimizer: A LLM generates answers, while another evaluates and optimizes them through feedback – <i>Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.</i>	23
8	System Architecture: Adapted version of the "Inner Thoughts" framework – <i>Source: Own illustration based on "Inner Thoughts" by Liu et al.[33], created with draw.io.</i>	34
9	Thought Pipeline Sequence: Sequence of the thought pipeline – <i>Source: Own illustration based on "Inner Thoughts" by Liu et al.[33], created with draw.io.</i>	35

10	Linear aging of the FIM score at three hold-times. Each panel shows the same scores $s_0 \in \{4.5, 4.7, 5.0\}$; the vertical line is t_{hold} , where a score-5 thought crosses τ . Within a panel, weaker thoughts expire sooner. Left to right, a shorter t_{hold} steepens every line. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – <i>Source: Own illustration.</i>	41
11	Cooldown factor after a thought is spoken, for $t_{\text{cool}} \in \{30, 60, 90\}$ s. Each panel compares the Hermite smoothstep with a linear ramp; the vertical line is t_{cool} , where recovery completes. The smoothstep stays flat at both ends; the linear ramp starts immediately and kinks at t_{cool} . – <i>Source: Own illustration.</i>	42
12	Weighted FIM score of a thought with $s_0 = 5$, never spoken versus spoken at $t = 12$ s. Aging uses $t_{\text{hold}} = 45$ s; cooldown uses $t_{\text{cool}} = 60$ s. Recovery restores the aged remainder; whether that remainder still exceeds τ depends on how long the thought has already lived. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – <i>Source: Own illustration.</i>	43

1 Introduction

Knowledge work now runs, to a remarkable degree, through remote meetings. Since the COVID-19 pandemic, video conferencing tools such as Zoom have moved from contingency measure to default infrastructure [2]. The medium that made distributed collaboration routine did not, however, resolve the process inside the meeting.

1.1 General Problem and Relevance

As early as the 1980s, research on Group Support Systems (GSS) identified key challenges that are still evident today in unproductive meetings: an inappropriate pace, poor meeting design, a lack of focus, a failure to reach decisions, or inefficient processes [3, p. 152]

Despite the long-standing awareness of these problems and the recognized importance of facilitation approaches, these insights still do not appear to be sufficiently implemented in practice. A negative assessment can be drawn from a study by Atlassian, in which 72% of meetings were rated as ineffective. The study identifies the same typical problems such as off-topic discussions, uneven participant engagement, and a lack of structure. [4]

One possible explanation for why these well-documented problems have nonetheless persisted, despite long-standing awareness, is the combination of inadequate training, lack of experience, and a natural resistance to change. [5, p. 153]

In addition, the responsibilities of a facilitator are extremely broad and complex (see 2.2.2), and it is likely that not everyone is suited for such a role.

AI-powered meeting tools have the potential to democratize this facilitating knowledge.

Current meeting tools primarily support the preparation and follow-up of meetings. Features used during the meeting, which could be categorized under “facilitation,” are mainly reactive or interactive. (see 2.3.1)

One reason for this is that a large body of literature suggests that AI systems in this context should primarily be designed to be interactive, and that proactive approaches are significantly more difficult to implement (see 2.3.3 and 2.3.4).

At the same time, problems arise in meetings that participants are often unaware of, such as cognitive biases, drifting off topic, or communication difficulties (see 2.1.2). In such cases participants cannot actively ask an AI system for assistance because they are not aware of the issue at that moment. Even if the system itself sends a notification, for example, via chat, it may be ignored or rationalized away. [6, "4.4.3 Intervene"]

In the field of Human-Computer Interaction (HCI), there are some preliminary studies on AI systems in this context (see 2.3.2). However, the vast majority of these studies remain theoretical or follow an interactive or reactive interaction model. Practice-oriented systems that proactively intervene and moderate meetings via voice have barely been noted in the literature.

This work therefore focuses on divergent decision-making processes in remote meetings, that is, on group processes in which existing information and options are evaluated and synthesized into a shared outcome.

This narrow focus reflects the current state of meeting support: preparation and especially follow-up are already partially covered in commercial meeting tools (see 2.3.1), and for divergent practices (such as brainstorming), there are relatively well-established AI approaches. [TODO: Cite sources] In the convergent phase, key GSS problems such as a lack of focus, failure to reach a conclusion, and distorted information exchange persist. Since participants are often unaware of these issues, a purely interactive design falls short here. Therefore, this work investigates how an AI system can proactively facilitate during this phase to support the participants.

1.2 Research Objectives and Questions

This thesis investigates support during a goal-oriented remote meeting, and it narrows that investigation to the convergent phase: when a group must evaluate existing options, remain aligned with a stated objective, and move toward a joint decision. Within that scope, the work asks how a proactive, context-sensitive AI moderator can intervene while the meeting is still running, especially where participants may not necessarily be aware that something is not going ideally or is even counterproductive.

The research problem gets addressed with a structured approach that integrates three complementary research objectives. This bridges the gap between theoretical facilitation techniques and a practically applicable AI-supported prototype. This prototype integrates a system proposal that builds upon existing HCI research and concretizes it through features derived from domain-specific knowledge in the field of facilitation. The result is a functional system that can be further evaluated and is intended to serve as a basis for further iterations or as a source of inspiration for similar systems.




Figure 1: Scope of the thesis: Primary focus and secondary focus, broken down by meeting phases – Source: Own illustration, created with draw.io.

1.2.1 RQ1: Facilitating strategies and challenges in goal-oriented remote meetings

Which facilitating strategies are suitable for the goal-oriented management of remote meetings with convergent objectives (such as decision-making, prioritization, problem-solving)? What specific challenges typically arise in this context?

The first research question aims to identify effective strategies for managing convergent remote meetings, such as decision-making, prioritization, and problem-solving, while also analyzing the specific challenges that arise. To achieve this, the thesis conducts expert interviews with certified facilitators, agile coaches, and team leads to gather empirical insights. It also analyzes literature on facilitation techniques, including timeboxing and role assignment, as well as the dynamics of remote collaboration. The findings are compared with existing research to derive best practices and identify pain points, such as off-topic discussions and unequal participation, which AI could potentially address.

1.2.2 RQ2: Design requirements for an AI-based moderation system

Which of the challenges identified in RQ1 can be addressed by an AI-based moderation system during a goal-oriented remote meeting with convergent objectives, and how should such a system be designed to intervene in a context-sensitive way?

The second research question asks which of the challenges identified in RQ1 can be addressed by an AI-based moderation system during a goal-oriented remote meeting with convergent objectives, and how such a system should be designed. Rather than presupposing a single failure mode, the thesis first maps the problem space from the expert interviews and the literature, then assesses which challenges are both technically addressable and most promising for delivering added value. From this selection, functional and non-functional requirements for a proactive, context-sensitive moderator are derived. Because a system that attempts to address every facilitation problem at once would not be evaluable, the subsequent prototype isolates one high-impact, measurable sub-problem as a proof of concept for the following evaluation.

1.2.3 RQ3: Perception of the meeting with a proactive AI moderator

How do knowledge workers perceive a goal-oriented remote meeting with convergent objectives in which a proactive AI moderator intervenes, with regard to communication, quality of discussion, status effects, teamwork, and efficiency, and how do they experience the agent's contributions?

The third research question investigates how knowledge workers experience a convergent remote meeting that is supported by the prototype. The evaluation uses a hidden-profile hiring simulation in which relevant information is distributed asymmetrically, so that a well-founded group decision depends on sharing unique information. Meeting outcomes are measured with the questionnaire instrument revalidated by Davison, covering communication, quality of discussion, status effects, teamwork, and efficiency. Because that instrument was developed for earlier group support systems, additional items address how participants experience the agent's interventions, including timing, context-appropriateness, and whether feedback from the AI is more comfortable than equivalent feedback from a group member.

2 Theoretical Foundations

This chapter presents the theoretical foundations and the current state of research. These form the basis for the subsequent work. Based on a systematic literature review, five key challenges in the context of meetings were identified (2.1.2). These serve as the starting point for the in-depth analysis in the following expert interviews (see Chapter 3) and provide indicators of what to focus on during the subsequent requirements gathering process (see Chapter 4.1).

2.1 Remote Meetings (RQ1)

Definition Meeting (Abgrenzung zu WS und Meetings -> Eigentlich das gleiche)

Was sind remote Meetings?

Einige ARbeiten definieren Meetings als ein ziel oder outcome-gerichtet interaction zwischen zwei oder mehr Leuten. [3, p. 148] Eine schwachstelle dieser Definition ist, dass viel treffen die als Meetings verstanden werden , beretis an der annahme der definition scheitern ziel orientiert zu sein. [TODO Quelle]

Aus den experten Interviews mit Facilitatoren von Hughes und Roy [7] lässt sich ableiten, dass in physischen Treffen Facilitatoren leichter eine gemeinsame "energetische Präsenz" aufbauen und Momente der Spannung im Raum leichter halten können. aus diesen würden oft die eigentlichen "Aha-Momente" und kreativen Durchbrüche entstehen. Im remote Kontext sei es schwer diese Spannung aufrechtzuerhalten, da man sich physisch distanziert fühle und oft "bild" für die feinen emotionalen Schwingungen der anderen sei. [7, "5.5 Unstructured Expert Interviews"]

2.1.1 Meetings in Modern Work: Trends and Context

The Doolde Report "State of Meetings 2023" finds that 40% of meetings are scheduled 1–4 weeks in advance (55% in North America). In contrast, the Mirsooft report reveals that most meetings (57%) are ad hoc, without formal invitations. [8]

Welche Arten von Meetings gibt es?

2.1.2 Key challenges: Off-topic discussions, unequal participation, lack of structure

A clear issue with goal-oriented meetings is the absence or unclear communication of objectives. It seems plausible that a significant number of meetings are scheduled without a defined goal or agenda (as discussed in section 2.1.1). A lack of structure in meetings is therefore one of the key challenges. While an agenda can serve as the foundation for such structure, it alone does not guarantee a successful meeting. Meeting goals are often dynamic and may need to be adjusted as the meeting progresses, due to the associated uncertainties [9, chap 4.1]. Although the agenda can outline a path to achieving the overall meeting goal [10, chap 2.1], without linked sub-goals, it guarantees neither the success of the meeting nor a timely conclusion. [9, chap 4.1] Discussions can nevertheless get out of hand if participants do not know what to prioritize. [9, chap 4.1] An agenda was identified by many respondents (67%) as a key element for successful meetings in Doodle's State of Meetings Report 2019. Only the setting of clear meeting objectives (72%) was cited even more frequently. [11, p. 11]

Based on this, the following summary challenge statement was derived:

Challenge 1: Clear goal-setting and structure. Goal-oriented meetings frequently lack clearly communicated objectives and a reliable structure, so that discussions lose focus and the meeting neither succeeds nor concludes on time.

Chen et al. noted, as a secondary finding, that individuals in higher hierarchical positions tended to intervene more frequently and maintain focus on meeting objectives when a clear list of goals was provided. Conversely, those in lower hierarchical positions felt less obligated to intervene, even when they observed deviations from the main topic. [9] Doodle's Stat of Meetings Report 2019 identified a correlation between salary and self-perceived participation in meetings. Respondents with higher salaries were more likely to

describe themselves as active participants. [11, p. 6] This may stem from inexperience, hierarchical constraints, group dynamics, or a lack of error culture, where dissent risks loss of face. Low participation can narrow solution spaces, yield monotonous outcomes, and reduce meeting effectiveness.

Dysfunctional communication—such as complaining, criticizing, and digressing—reduces effectiveness. [12, p. 130]

-> Unausgeglichen / geringe participation -> Unvorhergesehen veränderungen im Meeting (flach Annahmen, meetingziel ändert sich) -> technische Probleme: Instabile internetverbindungen, Störungen etc. (nicht im scope dieser arbeit aber dennoch relevant)

Graph der zeigt das sich diese challenges alle gegenseitig beeinflussen können. (z.B. wenn nicht nicht alle ansichten geührt wurde, kann es später dazu kommen das wenn man eigentlich eine entscheidung treffen möchte (convergent thinking) wieder zurück in divergent thinking fällt, was zu zirkulären diskussionen führen kann.)

Umgekehrt, kann ein zu langes verweilen in der convergen zone dazuführen, dass keine entscheidung getroffen wird und kein fortschritt wahrgenommen wird.

Kultur und hierarchie beeinflussen ebenfalls die offen teilnehmer ideen teilen und wer welche ideen wie bewertet.

2.2 Facilitation and Convergent Group Decision-Making (RQ1)

Recherche was sind eigentlich die aufgaben eines Facilitators? was macht ein facilitator?

Welche rolle spielen collaboration tools wie white boards (Google Jamboard, Miro, etc.) in der facilitation?

2.2.1 Group Support Systems and collaboration tools

Recherchen zu Group Support systeme begannen in den 1980er jahren mit den stetigen herausforderungen von komplexerwertten problemen die in organisation oft in gruppen / Teams gelöst werden müssen. [ackermannGroupSupportSystems2021]

Laut Akerman waren die Anfänge in diesem Forschungsbereich durch eine starke Fragmentierung geprägt. Verschiedene Forschungsteams arbeiteten unabhängig voneinander und ohne Abstimmung an überlappenden Themen. Dies führte dazu, dass es kein standardisiertes Vorgehen gab und sich unterschiedliche Bezeichnungen für dasselbe Forschungsgebiet etablierten, wie etwa „Meeting Support Systems“, „Computer-Supported Cooperative Work Systems“, „Group Support Systems“ oder „Group Decision Support Systems“ (GDSS). [ackermannGroupSupportSystems2021] Das übergeordnete Ziel besteht allerdings darin, Meetings sowohl in Bezug auf ihre Ergebnisqualität als auch auf ihre Prozessstruktur zu optimieren. [ackermannGroupSupportSystems2021]

Hierbei kommen oft computerunterstützte tools zum Einsatz. So definierte Huber [huberIssuesDesignGroup

”GDSS consists of a set of software, hardware, and language components and procedures that support a group of people engaged in a decision-related meeting.”

Klassische und initiale Group Support Systems (GSS) variieren stark in ihrer Komplexität und ihrer Funktionalität.

TODO: Quellen ergänzen Einige Systeme ermöglichen es Teilnehmenden, simultan und anonym Textbeiträge einzugeben, um elektronisches Brainstorming, Kriterienanalysen oder Priorisierungsabstimmungen durchzuführen. Ein Beispiel hierfür ist GroupSystems (später als ThinkTank bekannt, vermutlich basierend auf Plexsys) [ackermannGroupSupportSystems2021]. Andere, strukturorientierte Ansätze setzen auf qualitative Methoden wie das Causal Mapping, um komplexe Problemstellungen als visuelle Ursache-Wirkungs-Netzwerke abzubilden. Ein Vertreter dieser Kategorie ist der Group Explorer (ehemals COPE bzw. Decision Explorer) [4][5]. Darüber hinaus nutzen einige Systeme quantitative Multi-Kriterien-Entscheidungsanalysen (MCDA), bei denen Handlungsalternativen anhand mathematisch gewichteter Kriterien bewertet werden. Hierzu zählen etwa MeetingWorks oder Decision Conferencing [6]. Ergänzend dazu strukturieren weitere Ansätze unübersichtliche Debatten mithilfe des Issue-Based Information System (IBIS). Dabei werden Beiträge systematisch in Kernfragen, Lösungsoptionen sowie Pro- und Contra-Argumente unterteilt, wie es etwa beim Dialogue Mapping der Fall ist [9][10].

Um diese unterschiedlichen Systemfunktionen in verlässliche, wiederholbare Interaktionsmuster zu überführen, wurden schließlich **ThinkLets** als standardisierte Moderationsbausteine entwickelt[11].

Moderne Tools wie Miro, Conceptboard oder Figma Jam, die als digitale Whiteboard-Lösungen klassifiziert werden können, greifen einige dieser ursprünglichen Methoden

auf und verbinden sie mit den Möglichkeiten moderner Technologien das disitrubiteve zusammenarbeiten ermöglicht. Integrierte KI-basierter Systeme, erweitern diese Tools durch smarte funktionen wie z.B. die automatische bundlung von Ideen durch KI zu Themenclustern oder die Anreicherung von Ideen durch KI-generierte Vorschläge.

Zudem gibt es diverse sammlungen an Übungen, Methodne und Tools inkluse anweisungen zur Druchführung und Hilfestellungen worauf zu achten ist, welche für verschiende Gruppensituationen und Herausforderungen in meetings geeignet sind wie z.B.:

- Liberating Structures (LS): A collection of methods and tools for facilitation.
- 9 Spaces: A framework for facilitation.
- SessionLab Library: SessionLab ist ein Tools zum erstellen von Workshop agendas. Es gibt eine von der Community gepflegt Library in der viele Methoden geteilt werden.
- TODO: add more and add Foodnotes for each item

2.2.2 The facilitator role

Bereits in den Anfängen der GSS-Forschung (Group Support Systems) wiesen Beranek et al. darauf hin, dass GSS allein die Effektivität einer Sitzung vermutlich nicht gewährleisten können. Vielmehr hängt der Erfolg maßgeblich davon ab wie diese Systeme genutzt werden würden. [3, p. 147] Hierbei würde die Qualität der Gruppensitzung maßgeblich von dem Facilitators abhängen. [3, p.146]

Im deutschsprachigen Kontext wird der Begriff „Facilitator“ häufig mit „Moderator“ übersetzt. Diese Gleichsetzung ist jedoch unzureichend, da die Rollen unterschiedliche Schwerpunkte aufweisen: Während ein Moderator primär die Steuerung einer Sitzung übernimmt, zielt die Tätigkeit eines Facilitators auf die prozessuale und inhaltliche Unterstützung der Gruppe ab. Die Rolle des Facilitators umfasst zwar moderierende Elemente, geht jedoch darüber hinaus

According to Haney, researchers in the 1990s agreed that facilitation is a combination of “(1)managing relationships between people, tasks and technology, (2) structuring tasks, and (3) contributing to the effective accomplishment of the meeting outcomes.” [5, p. 73]

In his book ”The Skilled Facilitator”, regarded as a standard work in the field, organizational psychologist Roger Schwarz defines the term “Facilitator” as follows: ([schwarzSkilledFacilitatorComp as cited in [parsonsdialogueWhatMakesGood] & [13, p.9]):

”Group facilitation is a process in which a person who is acceptable to all members of a group, substantively neutral, and has no decision making authority, intervenes to help a group improve the way it identifies and solves problems, and makes decisions, in order to increase the group’s effectiveness.”

2.2.3 Divergent and Convergent Thinking in Meetings

Divergent thinking is the process of generating new ideas and concepts [TODO: QUELLE]. Convergent thinking is the process of evaluating and selecting the best ideas from a set of options. [TODO: QUELLE]

According to Anne Manning, generating new ideas and evaluating them are two fundamentally different processes. However, she says that in meetings, people often try to carry out both steps at the same time. [14, min 02:30] Immediately evaluating and weighing an idea hinders the creative process of generating ideas.

A predominance of divergent thinking without sufficient integration of convergent thought processes can lead to unreflective and excessive modifications. [15] Corply [15] further argues that both a lack and an excess of convergent or divergent thinking have adverse effects on creativity.

In the context of facilitation, the terms ”Convergence Zone / Phase” and ”Divergence Zone / Phase” are widely recognized. A recurring framework in this domain is the group process map, developed by facilitator Sam Kaner, commonly referred to as ”Diamond of Participatory Decision-Making” or ”Kaner’s Diamond”. [16] Kaner’s Diamond model describes typical phases that groups go through in the decision-making process. The left side represents the Divergent Zone, where diverse perspectives are expressed and disagreements are explored. The right side embodies the Convergent Zone, where opinions align and the process moves toward closure. At the center of the Diamond lies the ”Groan Zone”, a transitional phase where the tension between divergence and convergence often manifests.

TODO: add figure of Kaner’s Diamond

2.2.4 Biases in information exchange (Hidden profiles)

Diese Arbeit geht von der Hypothese aus, dass ein proaktives Meeting-Supporssystem insbesondere dort eine Lücke schließen kann, wo die Gruppe ihre eigene Ineffizienz nicht

erkennt. Ein interaktives System setzt voraus, dass Teilnehmende ein Problem bemerken und um Unterstützung bitten. Genau das entfällt, wenn der Prozess subjektiv reibungslos wirkt, obwohl er systematisch verzerrt ist.

Typischerweise liegt diese Unbewusstheit bei Biases vor, etwa Confirmation Bias, Groupthink, Authority Bias, Halo-Effekt, Anchoring oder Status-Quo-Bias, um nur ein paar zu nennen. Nicht alle diese Verzerrungen greifen jedoch am selben Punkt an. Authority Bias oder Halo-Effekt betreffen vor allem, wessen Beitrag oder welcher Gesamteindruck übergewichtet wird. Confirmation Bias und Groupthink betreffen dagegen, welche Informationen überhaupt geteilt und diskutiert werden.

Für die konvergente Phase wird daher angenommen, dass zunächst vor allem der Informationsaustausch als Grundlage entscheidungsrelevant ist.

Dieses Problem wird in der Literatur als Hidden-Profile-Paradigma beschrieben. In Meetings verfügen Teilnehmende typischerweise über unterschiedliche Informationen. Einen Teil kennen alle (geteilte Informationen), einen anderen Teil nur einzelne Personen (ungeteilte/private Informationen). Ein Hidden Profile liegt vor, wenn die bessere Lösung nur sichtbar wird, sobald die ungeteilten Informationen zusammengeführt werden. Gruppen diskutieren jedoch vorwiegend geteilte Informationen und ungeteilte Informationen kommen zu kurz oder werden nicht erwähnt. [17, 18, 19].

Confirmation Bias und Groupthink verstärken diesen blinden Fleck, weil einzigartige Informationen den bestehenden Konsens stören [19, 20]. Ohne externe Intervention bleibt die Ineffizienz unbemerkt.

Laut Verheine-Jarren et al. ist Voraussetzung für eine gute Kommunikation das Erkennen des eigenen Persönlichkeitsstils sowie das Wissen darum, dass es verschiedene Bezugswelten gibt, in denen sich die Beteiligten während des Gesprächs bewegen. Menschen neigen dazu, andere unbewusst nach eigenen Mustern zu interpretieren. Laut Verheine-Jarren et al. sei ein Durchbrechen dieses Automatismus der Wahrnehmung notwendig, um einen geteilten Bezugsrahmen zu schaffen. [21, p. 9]

Innerhalb des bleichen Bezugsrahmens, kann es dann allerdings auch zu Meinungsverschiedenheiten kommen, was nicht unbedingt schlecht ist. Schulz-Hardt et al. (2006) zeigen empirisch, dass Meinungsverschiedenheiten (Dissent) die Diskussionsintensität massiv erhöhen und die Lösungsrate des Hidden Profiles drastisch steigern. [20]

Geteilte vs. Ungeteilte Informationen: Das Hidden Profil

Ein typisches Experiment, um Entscheidungsprozesse in Gruppen zu untersuchen sieht folgendermaßen aus: Ein Team hat die Aufgabe aus unterschiedlichen BewerberInnen

den Besten oder die Beste auszuwählen. Dazu erhält jedes Team-Mitglied Informationen über die einzelnen BewerberInnen. Einen Teil der Information erhalten alle Teammitglieder. Diese Informationen sind also im Team geteilte Informationen. Einen anderen Teil der Informationen erhält jeweils nur ein Team-Mitglied. Diese Informationen sind also ungeteilt. Die Aufgabe ist nun so konstruiert, dass sich das Team nur dann für den richtigen Bewerber entscheiden kann, wenn alle Informationen – geteilte und ungeteilte – berücksichtigt werden. Werden lediglich die geteilten Informationen berücksichtigt, trifft das Team eine falsche Entscheidung.

Eine Vielzahl von Studien mit dieser oder ähnlichen Aufgaben zeigt, dass Teams meist nicht in der Lage sind, ein solches Hidden-Profile zu lösen: Geteilte Informationen werden ausgetauscht und diskutiert, ungeteilte Informationen fallen unter den Tisch. Erklärungen für das Phänomen Hidden Profil

Es gibt unterschiedliche Erklärungen dafür, warum in Gruppendiskussionen eher über geteilte Informationen gesprochen wird:

Wahrscheinlichkeit: Mehr Personen verfügen über die gleiche geteilte Information. Deshalb ist die Wahrscheinlichkeit höher, dass geteilte Informationen in der Gruppe diskutiert werden, im Vergleich zu Informationen, über die nur eine einzelne Person verfügt (ungeteilte Informationen). Selbstwerterhaltung: Menschen achten darauf, ein positives Selbstwertgefühl zu erhalten. Wird eine geteilte Information der Gruppe mitgeteilt, werden andere Personen in der Gruppe dieser Information zustimmen, bei ungeteilten Informationen steigt die Gefahr, kritisiert zu werden. Das gefährdet ein positives Selbstwertgefühl, weshalb eher ohnehin schon geteilte Informationen der Gruppe mitgeteilt werden. Group Think: Jedes Gruppenmitglied hat das Bedürfnis, sich der Meinung der Gruppe anzuschließen. Die Gruppe als Ganzes strebt nach Konsens. Das kann dazu führen, dass kritische oder widersprüchliche Informationen nicht ausreichend berücksichtigt werden.

Lösungsstrategien für das Hidden Profil

Die Forschung zu Hidden-Profiles basiert auf eher künstlichen Gruppensituationen. Dennoch lassen sich aus den Ergebnissen Strategien ableiten, Gruppenentscheidungen zu verbessern.

Effekt kennen: Wer die Anfälligkeit von Gruppen kennt, ungeteilte Informationen zu vernachlässigen, kann gezielt gegensteuern. Eine Möglichkeit ist z. B. nachzufragen, ob alle Informationen berücksichtigt wurden, oder ob es Informationen gibt, die nicht ins Bild passen. Expertise transparent machen: In einer heterogenen Gruppe hilft es, die unterschiedlichen Fach- und Wissensgebiete der einzelnen Mitglieder transparent zu

machen. So wird klar, dass unterschiedliches Wissen und unterschiedliche Meinungen zu erwarten sind. Technische Unterstützung: Technische Werkzeuge, die Informationen visualisieren oder strukturieren, helfen insbesondere bei komplexen Entscheidungen, alle Informationen zu berücksichtigen. Erst suchen, dann bewerten: Eine weitere Strategie ist es, das Sammeln und das Bewerten von Informationen als zwei Prozesse voneinander zu trennen. So wird verhindert, dass Informationen, die wichtig sein könnten, direkt abgewertet werden. Hierarchien vermeiden: Oft teilen insbesondere Mitglieder mit niedrigem Status ihr ungeteiltes Wissen nicht, wohingegen geteiltes Wissen, dass Mitglieder mit hohem Status eingebracht haben, detailliert diskutiert wird. Eine Lösungsstrategie ist deshalb, dass sich die Gruppenleitung oder Mitglieder mit hohem Status zunächst mit einer eigenen Bewertung zurückhalten.

2.2.5 Implications for AI support

2.3 AI in Meeting Support Systems (RQ2)

2.3.1 Overview of existing Meeting AI Tools

There is a wide variety of AI-based tools that provide support for meetings. Most of these tools focus on transcribing meeting content. Well-known examples include fireflies.ai [22], Otter.ai [23], and Jamie [24]. AI transcription features are also integrated into established meeting platforms such as Google Meet [25], Zoom [26], and Microsoft Teams. [27] More advanced features include the automatic extraction of action items. Depending on the tool, these features are available in real time or only after the meeting has ended. Microsoft Teams specifically offers a feature called “Facilitator,” [28] which provides additional capabilities beyond the features already mentioned (transcription, identification of action items): For example, it can edit the agenda if instructed to do so by a user with the appropriate permissions. It also displays a timeline to track topics and the flow of the meeting, and sends reminders to manage time. (Once halfway through the meeting and again shortly before it ends.) These interactions take place via the integrated chat. Google Meet, for example, also offers a live speech translation feature. [29]

Nevertheless, contemporary meeting platforms remain primarily technical infrastructures for conducting meetings. Their design does not systematically account for the professional knowledge, needs, and methodological repertoire of facilitators [7], nor are they conceived to support the range of tools, methods, practices, and techniques on which facilitation

typically relies. The potential of these platforms to systematically support facilitation has therefore not yet been fully realized. For users inexperienced in facilitation, the platforms likewise provide little scaffolding or procedural guidance that would help them orient their actions and guard against fundamental process errors.

2.3.2 Research Approaches to AI-Supported Meeting-Systems

in der literatur finden sich einige anbieter, welche ähnliche ansätze verfolgen. so haben z.B. Houtti et al. einen AI-Agent für inklusive Meetings designt. ihre rechte stützt sich auf ein quantitatives design interview mit potenziellen meeting teilnehmern (nicht wie in dieser arbeit mit facilitating Experten)

In study by Houtti et al. [6, p. 5], in which participants were asked to design virtual co-hosts during semi-structured design sessions, a widespread tendency emerged to design the co-host to be interactive rather than to let it act entirely automatically. Common design patterns involved the co-host providing prompts in response to explicit instructions (e.g., when explicitly asked or when a pin was set). The authors conclude that interactivity could help prevent mistrust.

Aus anderen studien zeigen eine tendenz, dass solche systeme eher interaktiv gestaltet sein sollten.

CoExplorer

Park et al. [30] haben einen adaptiven prototyp entwickelt, welcher die intentionalität des meetings verbessern soll. dieser prototyp bestand aus verschiedenen Tools, welche die vorbereitung des Meeting betrafen und die durchführung. Teilnehmenden hatte so die chance bereits vor dem meeting mit einem KI-Agenten das Ziel zu sprechen und sich eigene Meinungen abzugeben. darauf basierend hat CoExplorer phasen abgeleitet, die wahrscheinlich in dem Meeting vorkommen werden. während des meetings war CoExplorer dann in der Lage, die verschiedenen Phasen zu erkennen und hat über eine adaptive User Interface relevante informationen mit den Teilnehmenden live geteilt.

Hierbei fanden fast alle Teilnehmenden an der studie (24 von 26) das das teilen der Präferenzen und meinung im voraus des meetings hilfreich war, um sich thematisch zu ordnen und eine priorisierung in der discussion punkte vorzunehmen.

Auch das tracken und visualisieren der Meetingdaten wurde als positiv aufgenommen. Einige Teilnehmenden äußerten sich zu dem system so positiv, dass sie der meinung waren, dass es keine menschlichen mediatoren mehr während des meetings brauche. Gleichzeitig war aber

auch ca. die Hälfte der Teilnehmenden der Meinung, dass der Meetingorganisator weiterhin in der Verantwortung bleiben sollte und das System nicht proaktiv Änderungen vorsehen soll, ohne diese mit dem Organisator abgestimmt zu haben, da diese ein besseres Verständnis über das Meeting habe.

Keeper

„Keeper“ von Hughes und Roy wurde auf Basis einer indigenen Facilitation Practices namens Circle Practice entwickelt, die eher auf beziehungs- und gefühlsorientierte Gespräche abzielt. Auch wenn dieser Ansatz nicht direkt zu dieser Arbeit passt, war deren Ansatz zur Verwaltung der Redezeiten interessant. Sie wählte eine Queue-Mechanik, welche bei den Studienteilnehmenden als kognitive Entlastung wahrgenommen wurde. Es gab eine strukturierte soziale Angst vor dem richtigen Zeitpunkt, fast vollständig eliminiert. Da die Teilnehmenden wussten, dass sie an der Reihe sein würden, konnten sie aktiver zuhören, anstatt im Kopf ständig ihren nächsten Einwurf zu planen oder Angst vor einer Unterbrechung zu haben.

Keeper

2.3.3 Interaction Paradigms in Human-AI Systems: Reactive, Proactive, and Mixed-Initiative

2.3.4 Proactive AI-Interactions: From Turn-Taking to Intrinsic Motivation with the Inner Thoughts Framework

To reduce the need for explicit prompts, an AI agent should be able to proactively recognize when it is its turn in an interaction sequence. In dyadic human-AI interactions, pauses or so-called “stop words” are often used for this purpose to identify a change in speaker. In multi-party scenarios (e.g., group conversations), however, this becomes significantly more complex and leads to the “multi-party turn-taking problem”. [31]

Some approaches model the problem as a machine learning task by attempting to predict the next speaker based on previous speaker changes. [32] Bayer et al. employ traditional algorithms such as Maximum Likelihood Estimation (MLE) and Support Vector Machines (SVMs), as well as deep learning architectures including Convolutional Neural Networks (CNN) and Long Short-Term Memory (LSTM) networks. They distinguish two primary paradigms: agent-only models, which rely solely on speaker history, and agent-and-content models, which additionally incorporate conversational context. Both paradigms have

been trained and evaluated across diverse, topic-oriented and chit-chat corpora using these varied algorithms. The empirical findings indicate that while simple agent-only models are sufficient for small, highly focused dialogues, incorporating conversational content becomes crucial in goal- and topic-oriented interactions characterized by complex, irregular turn-taking patterns. [32, p. 2]

With these approaches, however, it remains unclear why an agent should interact at a specific point in time. Due to the design of the ML algorithms, the timing of the interaction is decoupled from its cause or is only implicitly included in the model, but cannot be explicitly explained. (Example: We know that it is now the time for the agent to interact now -> But why? Whats the reason its like that he should talk? What should he say?)

Ein naiver ansatz für Turn-taking wäre ein LLM so zu prompten es zu fragen wer als nächstes dran ist. Liu et al. [33] haben dies überprüft und konnte ihre Hypothese bestätigen, dass diese Ansatz bei bei turn-allocation ansätzen gut funktioniert. Dies ist naheliegend weil in diesem szenarien in dem chat kontext indizierte liegen wer als nächstes dran ist. alle getesteten LLM Modelle hatten bei turn-allocation eine besser vorhersagequote als bei self-allocation stellen. die vorhersagen für self allocation haben sich im rahmen einer zufälligen chance bewegt. Die Autoren schlussfolgern. Das für self-selection szenarien der konversations kontext alleine nicht ausreicht und noch interne faktoren dafür verantwortlich seien.

Die über die letzten jahre stattgefunden entwicklung bei LLMs ermöglichen neue ansätze um diese Problem zu modellieren. Neues Paradigma von LLM-basierten Agentischen Systemen. Was ist das? -> Hier beschreiben was KI-Agenten sind (Anthropic definition finden und verwenden) LLM basierte AI-Agenten mit einer LLM pipeline welche intrinsische gedanken simuliert, könnte ein viel versprechender ansatz sein.

Liu et al. verfolgen diesen ansatz um einen proactiven conversationa Agent mit inner Thoughts zu modellieren. [33]

Y verfolgen diesen ansatz um einen proaktiven Chatbot zu modellieren und schlussfolgern, dass

Classic Workflow

2.4 LLM-based AI-Systems and Agents in General (RQ2)

zunächst soll geklärt werden, was unter KI-Agenten verstanden wird. Letztlich sind KI-Agenten Systeme, um Teilaufgaben zu automatisieren. Um ein präziseres Verständnis zu bekommen, lohnt es sich daher, eine Abgrenzung zu klassischen Workflow-Automatisierungen zu machen.

Programmatische Prozessautomatisierung bezeichnet die regelbasierte Automatisierung von Abläufen, bei der festgelegte Bedingungen und strukturierte Entscheidungslogiken genutzt werden, um Prozesse effizient, zuverlässig und wiederholbar auszuführen. Techniken, die hier zum Einsatz kommen, sind Robotic Process Automation, Scripting und Makros.

LLMs können Kontext dabei helfen, unstrukturierte Aufgaben zu lösen. Anthropic hält folgende Definition bzgl. von Agenten, welche KI-Agenten von Workflows abgrenzt. Workflows are systems where LLMs and tools are orchestrated through predefined code paths. Agents, on the other hand, are systems where LLMs dynamically direct their own processes and tool usage, maintaining control over how they accomplish tasks.

2.4.1 Prompt Engineering and Context Engineering

Allgemein bezeichnet Context Engineering das Designen, Organisieren und Managen von kontextsensitiver Information, so dass Maschinen im Einklang mit der menschlichen Intention agieren. [34, p. 3]

Obwohl das Context Engineering bereits in frühen Frameworks der Mensch-Computer-Interaktion eine Rolle spielte [34, p. 1], hat die Forschung aufgrund der wachsenden Herausforderungen in der Human-Agent-Interaction (HAI) in jüngster Zeit eine verstärkte Fokussierung auf dieses Gebiet erfahren.

Die Relevanz dafür ist begründet auf aktuellen Limitationen (TODO Beispiele), Performance-Verbesserungen (TODO Beispiele) und Ressourcen-Optimierung.

Mei et al. (2025) haben in ihrer Meta-Studie [35] über 1.400 Forschungsarbeiten zum Thema Context Engineering für LLMs analysiert. Laut den Autoren haben sich LLMs von einfachen Systemen, die lediglich Anweisungen befolgen (sog. Prompt Engineering), zu zentralen Schlussfolgerungsmodulen entwickelt. Dabei haben sich die Gestaltung und

Verwaltung von Informationsinhalten zu einer eigenständigen Disziplin weiterentwickelt (Context Engineering) [35]

Bei LLM-basierter Systeme lässt sich Context Engineering wie folgt definieren:

”Context engineering is the practice of deliberately structuring and optimizing the information passed to an LLM or Agent to produce more accurate and relevant outputs.” [36, 00:34]

Damit geht Context Engineering über das klassische Prompt Engineering hinaus und umfasst erweiterte Methoden wie Retrieval-Augmented Generation (RAG), Speichersysteme, Tool-integriertes Reasoning sowie Multi-Agent-Systeme (vgl. Mei et al., 2025). [35, p. 12-26]




Figure 2: Venn-Diagram: Prompt Engineering as a subset of Context Engineering – Source: Own illustration, created with draw.io.

Obwohl in der Literatur verschiedene Methoden zum Kontext Engineering diskutiert werden, weisen Mei et al. kritisch darauf hin, dass die Praxis derzeit ohne einheitliche theoretische Grundlagen operiert. Diese Grundlagen wären notwendig, um die unterschiedlichen Techniken miteinander zu verknüpfen und prinzipienbasierte Entwurfsrichtlinien abzuleiten. Die Forschungslücke wird zudem durch das Fehlen mathematischer Rahmenwerke verstärkt, die es ermöglichen würden, optimale Entwurfsprinzipien für das Kontext Engineering in komplexen Systemen zu charakterisieren. Dies steht im Zusammenhang mit dem Mangel an Methoden zur Bestimmung der optimalen Kontextzusammensetzung. [35, p. 51]

2.4.2 Building blocks for LLM-based Workflows and Agents

Um den späteren AI-Agent zu bauen, war es notwendig sich zunächst mit den Grundbausteinen der KI-Agenten zu beschäftigen. Anthropic hat dies bezüglich eine Blogpost [37] veröffentlicht welcher die Grundbausteine aus deren Sicht zusammenfasst und als Hauptgrundlage für dieses Kapitel dient.

Prompt chaining



Figure 3: AI-Building-Block:Prompt chaining: A complex task is decomposed into sequential LLM calls – Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.

In prompt chaining, a complex task is broken down into a sequential series of substeps. Each step is described by a prompt and an LLM call, which uses the result of the previous step as context for the next step. Programmatic checks can be inserted in between.

Routing




Figure 4: AI-Building-Block:Routing: A complex task is decomposed into subtasks and routed to specialized systems – Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.

Beim Routing werden aufgaben klassifiziert und an untersysteme welche auf das lösen

dieser Kategorie von Aufgaben spezialisiert sind weitergeleitet. Dadurch entsteht eine klare Trennung von Verantwortlichkeiten, was besonders gut geeignet ist, wenn komplexe Aufgaben in klar abgrenzbare Kategorien aufgeteilt werden können und von spezialisierten LLMs oder anderen KI-Modellen oder Algorithmen bearbeitet werden können.

Parallelization



Figure 5: AI-Building-Block: Parallelization: Multiple tasks are processed in parallel and the results are aggregated programmatically – Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.

Beim Parallelisierungs-Workflow werden mehrere Aufgaben gleichzeitig bearbeitet und die Ergebnisse programmatisch aggregiert. Typische Anwendungsfälle liegen vor, wenn Aufgaben in unabhängige Teilaufgaben unterteilt werden können (Segmentierung) oder wenn mehrere Perspektiven für ein zuverlässigeres Ergebnis erforderlich sind (Voting). Bei komplexen Aufgaben mit mehreren Aspekten erzielen LLMs bessere Ergebnisse, wenn jeder Aspekt durch einen separaten Aufruf mit spezialisiertem Prompt fokussiert bearbeitet wird.

Orchestrator-workers



Figure 6: AI-Building-Block: Orchestrator-workers: A central LLM decomposes a main task dynamically into subtasks and delegates them to a variable number of worker LLMs – Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.

Der Orchestrator-Worker-Workflow ähnelt dem Parallelisierungs-Workflow, unterscheidet sich jedoch darin, dass er eingesetzt wird, wenn die benötigten Teilaufgaben nicht im Voraus bekannt sind. Ein zentrales LLM zerlegt die Hauptaufgabe dynamisch in Teilaufgaben und delegiert diese an eine beliebige Anzahl von Worker-LLMs, deren Ergebnisse abschließend aggregiert werden.

Evaluator-optimizer



Figure 7: AI-Building-Block: Evaluator-optimizer: A LLM generates answers, while another evaluates and optimizes them through feedback – Source: Own illustration based on "Building Effective AI Agents by Anthropic"[37], created with draw.io.

Der Evaluator-Optimizer-Workflow nutzt eine Feedbackschleife, in der ein LLM Antworten generiert, während ein weiteres diese bewertet und durch Feedback versucht zu optimieren. Dieser Ansatz ist besonders effektiv, wenn klare Bewertungskriterien vorliegen und iterative Verbesserungen messbar sind.

Augmented LLM

Diese Workflows orientieren sich an klaren Argumentationsketten. Die Informationen folgen einem im Code prozedural gesteuerten sequenzeller Weg, während LLM-Aufrufe bewusst für entsprechende Teilaufgaben mit einer zuvor bekannten Intention stattfinden. Mit anderen Worten: Es existieren vordefinierte, klare Pfade, denen die Daten sowie die Ausgaben der LLM-Aufrufe folgen.

Bei Agenten gibt es diese klar vordefinierten prozeduralen Pfade in dem Sinne nicht. Das LLM selbst wird genutzt, um zu entscheiden, welche Wege eingeschlagen werden sollen. Dies kann insbesondere bei offenen Problemen hilfreich sein, die sich nicht ohne Weiteres in einem starren Workflow abbilden lassen. Dabei wird das LLM mit verschiedenen Tools ausgestattet, und es bleibt dem Modell überlassen, ob und wann es diese Tools aufruft. Die Qualität des Gesamtoutputs hängt somit auch davon ab, wie zuverlässig das LLM das korrekte Tool auswählt. Dies abstrahiert offene Probleme in eine Struktur, in der Tool-Calling in einer Schleife stattfindet, bis das LLM selbst entscheidet, dass das gewünschte Ergebnis erreicht ist.

Diese workflows orientieren sich an klaren Argumentationsketten. Die Informationen folgen einem im code procedural gesteuerten Weg und LLM-Calls finden intentionale für entsprechende Unteraufgaben mit einer vorher bekannten Intention zu einem sequenziell bekannten Zeitrahmen statt. Anders ausgedrückt gibt es vordefinierte klare Wege, welche die Daten und die Outputs der LLM-Calls folgen.

Folgt man der Definition von Anthropic werden diese klaren vordefinierten entfernt und ein LLM wird genutzt um selbst zu entscheiden, welche Wege eingeschlagen werden. Dies kann besonders offene Probleme hilfreich sein, die nicht einfach in einem Workflow eingefangen werden können. Hierbei wird ein LLM mit verschiedenen Tools ausgestattet und es dem LLM wird überlassen ob es dieses Tool aufrufen wird. Die Qualität des gesamten Outputs hängt somit auch damit zusammen wie zuverlässig das LLM das korrekte Tool aufruft. Dies abstrahiert somit offene Probleme in eine Struktur in der Tool-Calling in a Loop stattfindet, bis das LLM selbst entscheidet, wann das gewünschte Ergebnis erreicht ist.

Workflow-Design lässt mehr granularer Kontrolle zu, während Agents etwas losgelöster agieren können.

2.4.3 Evaluating and Testing of AI-Systems

Aufgrund des probabilistischen Charakters von KI-basierten Systemen unterscheidet sich das Testen von KI-basierten Systemen grundlegend von herkömmlichen Testverfahren.

Das International Software Testing Qualifications Board (ISTQB®) legt daher nahe dass dieser probabilistische Charakter statistische Testverfahren erfordern würde. [38, p. 39]

Eine zusätzliche Herausforderung besteht darin, dass einige KI-Systeme nicht nur statisch, sondern auch adaptiv sind und sich somit kontinuierlich anpassen können [38, p. 39].

Diese Anpassungen können mindestens auf zwei Ebenen auftreten:

- **Kontextbasierte Anpassung:** Innerhalb der Anwendung kann sich das KI-System dynamisch an veränderte Rahmenbedingungen oder die vielfältigen Möglichkeiten des zu diesem Zeitpunkt bereitgestellten Kontexts anpassen.
- **Modellbasierte Anpassung:** Unabhängig vom konkreten Kontext des Use-Cases können sich die zugrundeliegenden KI-Modelle selbst verändern, etwa durch den Einsatz selbstlernender Algorithmen. Bei der Integration externer Large Language

Models (LLMs) kann der Anbieter Modifikationen am Modell vornehmen, die für den Nutzer nicht direkt ersichtlich sind.

Die Festlegung eines Test-Orakels, also die Definition der erwarteten Ausgaben bei bestimmten Eingabewerten für das zu testende System, ist bei komplexen KI-Systemen daher extrem schwierig oder sogar unmöglich [38, p. 39].

Dies gilt auch für LLM-basierte Systeme.

Auch Mohammadi et al [39, p. 1] weisen darauf hin, dass das evaluieren und Testen von LLM-basierte Agenten ein komplexes und noch wenig erforschtes Gebiet sei, insbesondere weil Agenten oft in einem dynamischen und interaktivem Kontext operieren. Sie beschreiben daher das Testen von LLM-Agents als Zusammenspiel der verschiedenen Perspektiven von Natural Language Processing (NLP), human-computerinteraction (HCI) und Software engineering.

Codebasierte Methoden (engl. code-based methods) versuchen, die Leistung von KI-Systemen durch expliziten Programmcode, definierte Regeln und Testfälle mit Assertions zu überprüfen. Dabei wird geprüft, ob die ausgeführten Aktionen exakt vorgegebenen Kriterien entsprechen. [39, p. 7]

Hierfür können beispielsweise mögliche Zustände, die das System durchläuft, modelliert und anhand von Trajektorienvergleichen analysiert werden. Bestehende Benchmarking-Verfahren wie AgentBoard [40] sind jedoch oft allgemein gehalten und für domainspezifische Use Cases nur bedingt geeignet.

Insbesondere bei offenen oder qualitativen Antworten sowie bei kreativen Problemen, bei denen die Korrektheit subjektiv bewertet werden kann, stoßen codebasierte Verfahren an ihre Grenzen [39, p. 7].

Der LLM-as-a-Judge-Ansatz nutzt die Argumentationsfähigkeiten von LLMs, um die Antworten von Agenten anhand qualitativer Kriterien zu bewerten. Dabei werden die Antworten basierend auf den in den Anweisungen vorgegebenen Bewertungsmaßstäben analysiert. [39, p. 7].

Die Autoren Zheng et al. [41, p. 4] schlagen drei Varianten des LLM-as-a-Judge-Ansatzes vor, die einzeln oder kombiniert angewendet werden können:

- Pairwise Comparison: Ein LLM vergleicht zwei Antworten auf eine Frage und entscheidet, welche besser ist oder ob ein Unentschieden vorliegt.
- Single Answer Grading: Ein LLM bewertet eine einzelne Antwort direkt anhand einer Skala oder eines Kriterienkatalogs.

-
- Reference-Guided Grading: Ein LLM bewertet eine Antwort im Vergleich zu einer vorgegebenen Referenzlösung, z. B. bei mathematischen Aufgaben.

Im Anhang des Papers „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena“ finden sich entsprechende Prompts, die für die verschiedenen Varianten des LLM-as-a-Judge-Ansatzes verwendet werden können [41].

Laut Mohammadi et al. gilt jedoch nach wie vor die Human-in-the-Loop-Evaluierung als Goldstandard, bei der Menschen (etwa in Nutzerstudien, Expertenaudits oder durch Crowdfunder) die Ausgaben annotieren oder bewerten [39, p. 7]. Dieser Ansatz ist jedoch oft schwer skalierbar und mit hohem Aufwand sowie Kosten verbunden.

Ein weitverbreiteter Ansatz ist Evaluation-Driven Development (EDD), bei dem KI-basierte Systeme und Agenten während der Entwicklungsphase kontinuierlich evaluiert werden, um Abweichungen zu erkennen und neue Use Cases zu identifizieren [39, p. 6].

3 Empirical Analysis of Facilitating Strategies (RQ1 & RQ2)

3.1 Methodology: Expert Interviews

Wie in den theoretischen Grundlagen beschrieben, hat die Interaktion innerhalb von Meetings viele sehr unterschiedliche Faktoren und Ebenen (psychologische Effekte, Persönlichkeitsmerkmale, Kommunikation) Kommunikation im Allgemeinen zwischen verschiedenen Menschen. Über Remote-Meeting und mit einem KI-Agent entsteht noch eine zusätzliche Ebene der Computer-Human-Interaktion. Um diese Komplexität einzufangen, sollen eine quantitative Studie gezielt für diese Arbeit relevanten Informationen erheben. Es bestand die Hoffnung, die Komplexität dieses Zusammenspiels auf wesentliche Merkmale und Erkenntnisse zu reduzieren. Hauptziel der Interviews war es somit, den Übergang von der allgemeinen Recherche bezüglich Meetings über die Hintergründe der konkreten Praxiserfahrung hinzu relevanten Features für einen KI-Agenten zu schaffen.

Semi-structured expert interviews were chosen as the method. This type of interview allows for in-depth insights into the respondents' perspectives through open-ended questions and flexible follow-ups, while at the same time ensuring a thematic focus through a guide.

Expert interviews are particularly suitable because experts, through their specialized knowledge and practical experience, provide efficient access to specific areas of knowledge [42, p. 877]. The definition of an expert is context-dependent and must be determined on a case-by-case basis depending on the research topic [42, p. 877]. In this study, only individuals with verifiable professional experience in the field of facilitation and who are professionally active in this context were interviewed. Therefore, the interviews conducted can be classified as semi-structured expert interviews.

Letztlich ist zu erwarten, dass das der Prototyp stellenweise darauf abzielt eine Facilitatorin zu emulieren. Facilitatoren wenden das "What / When / Who" Framework aus [Quelle], welches zum Design von KI-Systemen von X empfohlen wird per Definition ihrer Jobbeschreibung bereits an. Eine Beobachtung aus dieser Praxis stellt somit eine erweiterte Perspektive zur Literatur dar.

Es wurde sich auch dazu entschieden Fragen dazu zu stellen, wie sich Facilitatoren ein solches KI-gestütztes System vorstellen würden. Man könnte kritisieren, dass Facilitatoren hierfür keine Experten sind und es somit zu spekulativen uninformatierten Antworten kommt, da ihnen die technischen Möglichkeiten und Limitierungen KI-gestützter Systeme nicht bewusst sind. Allerdings sind die Fragen so gestellt, dass der Facilitator die Verhaltensweisen und Eigenschaften dieser Systeme beschreiben kann, wozu dieser qualifiziert ist, ohne über Detailwissen zu der technischen Implementation verfügen zu müssen. (vgl. Annahme Frage x.X) Zusätzlich wurde in Houtti et al. mit Meeting teilnehmenden ein co-host design, wie sich Meeting teilnehmende ein solches System wünschen. Hier wird nun eine andere Perspektive geboten. Ein user-zentriertes Design Interview hätte früher diese Perspektive vermutlich einen blinden Fleck, weil standard Meeting teilnehmenden nicht wissen, welche Methoden und Facilitating-Ansätze zum Einsatz kommen und somit auch kein System diebezüglich designen werden, welches eben jene Methoden und Ansätze berücksichtigt. (Wissen von dem sie nicht wissen, dass sie es nicht wissen)

Sowohl die Reihenfolge der unterschiedlichen Abschnitte als auch der Fragen innerhalb der Abschnitte orientieren sich an einer Struktur, die vom Allgemeinen zum Speziellen vorgeht. Es handelt sich um offengestellte Fragen. Des Weiteren sind die Fragen so gestellt, um verhaltensbezogene Anker zu triggern, um den Befragten zuzurufen, wie er sich in vergangenen Situationen verhalten hat. [Quelle auch "The mum test"] (Aussagen sind verlässlicher, wenn man fragt, wie wurde das bisher gelöst, anstatt wie lässt sich das lösen)

Es hat ein Probe-Interview mit einem anderen Studenten stattgefunden, um die allgemeine Verständlichkeit der Frage zu prüfen und den groben Zeitaufwand zu prüfen. Da der Student allerdings fachfremd war, wurde ein weiterer Durchlauf mit ChatGPT durchgeführt. Dabei wurde ChatGPT als Facilitating-Experte gepromptet und wusste, dass nun ein Experteninterview simuliert wird. Auch dieses Interview hatte lediglich das Ziel, den Fragebogen zu testen und zielte nicht auf einen Erkenntnisgewinn abseits dessen ab. [Quelle: das es Best-Practice ist, einen Probelauf zu machen]

3.1.1 Sampling: Purposeful selection of 5 facilitating experts

Für diese Studie wurden 5 Experten befragt.

3.1.2 Data Collection: Conduction of semi-structured interviews (30 min)

Wann wurden die interviews geführt? Inwlechn Zeitraum? Es wurden nie mehr als 2 Interviews pro Tag geführt. Es gab einen Interviewer, nämlich den Autor dieser Arbeit. Obwohl die Interviews leicht variiert haben, haben diese im Schnitt ca. 30min gedauert. Die Interviews haben über Zoom stattgefunden und wurden, um diese später besser zu transkribieren aufgezeichnet. Jedes Interview startet mit einer kurzen Einleitung in der erklärt wurde, was der Zweck des Interviews ist, wofür die Datenerhebungen werden und wie diese verarbeitet werden. Anschließend wurde die Interviewten gefragt, ob diese mit dieser Verarbeitung und insbesondere der Aufnahme einverstanden sind. Dem haben alle zugestimmt.

Zu Beginn bereits Kontext zu liefern, hat dabei geholfen klar einzuordnen, wofür es in dem Interview gehen soll.

Through these measures and also through the choice of the interview channel, a certain closeness could be created, which is helpful in obtaining the views and opinions of the interviewee (Meyen et al., 2019).

Nach dem das Interview beendet wurde, wurden sich direkt Notizen gemacht und erste Gedanken festgehalten, während die Eindrücke nach den Interviews noch frisch waren.

3.1.3 Analysis: Thematic coding

Deductive Coding kann missen auf wertvolle Erkenntnisse. Während induktives Codieren besser für untersuchte neue Ideen oder Konzepte ist. Da allerdings bereits eine Literaturrecherche vorausgesetzt wurde, besteht zumindest ein Verständnis darüber, welche Themenkomplexe in den Interviews zu erwarten sind bzw. welche explizit abgedeckt werden sollen, um genauere Informationen von den Experten zu erlangen. Aus diesem Grund wurde ein Kategorisierungssystem basierend auf den Literaturrecherchen erstellt. Und daraufhin wurde im Anschluss allerdings ein induktives Codieren der Interviewergebnisse durchgeführt. Dieser Ansatz sollte es ermöglichen einen klaren Rahmen für die Interviews zu schaffen.

aber dennoch offengenug zu sein um neue, noch nicht in der Recherche identifizierte informationen aufnehmen zu können.

Somit wurde ein hybrider coding ansatz gewählt. bei dem die codes iterativs verreinert wurden. Auch die überkategorieen wurden dann im nach gang weiterfereinert.

3.2 Results: Facilitating Strategies and Challenges

3.2.1 Comparison with literature (Chapter 2)

3.3 Implications for AI System Design

3.3.1 Derived requirements for RQ2

4 System Design and Implementation of a Scoped Prototype (RQ2)

The preceding chapters established a broad problem space: goal-oriented remote meetings are affected by a wide range of facilitation challenges, ranging from off-topic drift and unequal participation to the biased exchange of information described by the hidden-profile paradigm (see the theoretical foundations and the empirical analysis of facilitating strategies in RQ1). RQ2 asks how an AI-based moderation system can be designed to counter such challenges through proactive, context-sensitive interventions.

Translating the requirements derived in RQ1 into a concrete, buildable artifact made this tension explicit. It became apparent during the design process that a system attempting to address the full breadth of divergent-phase facilitation problems at once would not be evaluable: with many interacting intervention mechanisms active simultaneously, any observed effect on meeting quality could no longer be attributed to a specific design decision.

A broad, feature-complete system would thus trade scientific rigor for surface plausibility. Prioritizing internal validity over coverage, the scope was therefore deliberately narrowed from a general-purpose AI facilitator to a focused proof-of-concept that isolates a single, well-defined, and theoretically grounded intervention mechanism.

Accordingly, this chapter does not claim to present a system that resolves every problem arising in the divergent phase of a meeting. Instead, the prototype targets one specific sub-problem that was identified as both high-impact and measurable in the theoretical foundation and the expert interviews: the shared-information bias underlying hidden profiles and the closely related issue of unequal participation.

Accordingly, this chapter does not claim to present a system that resolves every problem arising in the divergent phase of a meeting. Instead, the prototype targets one specific sub-problem that was identified as both high-impact and measurable in the theoretical

foundation and the expert interviews: the shared-information bias underlying hidden profiles and the closely related issue of unequal participation. To address it, the prototype implements a single proactive intervention mechanism — an adapted version of the “Inner Thoughts” framework, extended by an External Stimulus Injection layer — rather than a comprehensive suite of facilitation features. This deliberate reduction is precisely what makes the subsequent evaluation (RQ3) feasible: a bounded intervention can be tested against a controlled hidden-profile decision task, so that measured differences in meeting quality can be plausibly attributed to the artifact rather than to an uncontrolled combination of features.

This scoping decision follows a design-science understanding of prototyping, in which the artifact serves as a proof of concept for a specific mechanism and not as a production-ready system. Importantly, the narrowing of scope did not precede the design work but emerged from it: the confrontation with concrete requirements, implementation constraints, and — most decisively — the demands of a valid evaluation revealed which part of the broad design goal could be examined responsibly within this thesis. The following sections make this boundary explicit. section 4.1 distinguishes proactive from reactive designs and derives the functional and non-functional requirements; the system architecture then details the adapted “Inner Thoughts” framework as the core intervention mechanism; the prototype development reports the concrete implementation and its limitations; and the formative evaluation describes how the design was assessed iteratively during development. The facilitation challenges that were consciously left out of scope are revisited as limitations and as directions for future work.

4.1 Requirements Analysis and Scope Definition

4.1.1 General Requirements

Der Agent sollt enicht zu schnell versuchen meinungsverscheindeheiten aufzulösen. (vgl hidden profile problem)



4.1.2 Scoped Requirements for the Prototype

4.2 System Architecture

4.2.1 Adapted version of the “Inner Thoughts” framework




Figure 8: System Architecture: Adapted version of the “Inner Thoughts” framework – Source: Own illustration based on “Inner Thoughts” by Liu et al.[33], created with draw.io.




Figure 9: Thought Pipeline Sequence: Sequence of the thought pipeline – Source: Own illustration based on “Inner Thoughts” by Liu et al.[33], created with draw.io.

Das Inner Thoughts- Framework von Liu et al. ist in deren version eher für interaktionen ausgelegt die als soziales Plaudern kategorisiert werden können. Dies ist nicht was ein Faciliator machen würde. Die Idee ein KI-System anhand einer intrsisichen motivation zu modellieren, bevor jemand etwas zu einer Gruppen discussion beiträgt, ist dennoch auch für diese ARbeit relevant. Insbesondere weil dieser Ansatz darauf hindeutet eine erhöhte Genauigkeit bei self-trun-allocation zu erzeugen. Aus den Experten ging hervor ds eine Geanken gänge, welche Facilitatoren haben auf abstakter inutionen basieren andere wiederum druchdacht kombiniert mit experten wissen etc. Dies legt nach, dass legt nahe das sowohl system 1 als auch system 2 bei dem prozess involviert sind, was eben falls in dem Innter Thouns Framewokr berücksichtigt wird.

Die Autoren wiesen in der Diskussion der Arbeit [33, "8.2 Apllying Inner Thouns Beyond Casual Conversations"] selbst darauf hin, dass sich das System durch anpassungen der Bewertungskriterien auf aufgabenorientierte Kontexte anpassen lässt und zielorientiertes praktives Handeln ermöglichen kann. Sie schalgen vor für weitere arbierten das system mit domain-spezifische heuristiken anzupassen, um die interaktionen an real-world tasks zu orientieren.

Im ursprünglichen Modell von Liu et al. werden generierte Gedanken primär danach bewertet, wie stark sie die "persönliche Relevanz" die individuellen Interessen oder die einzigartigen persönlichen Kenntnisse des Agenten widerspiegeln (TODO: prüfen bzw. konkretisieren wie die heuristik tatsächlich ist). Dies mag für generische Conversations geeignet sein, da dieser Ansatz Authentizität und Sympathie in infromellen, sozialen Unterhaltungen erhöht, ist für einen AI-Moderator in zielorientierte Meetings die durch Hidden Profile geprägt sind, allerdings ungeeignet. Wenn die Gedanken des AI-Moderator primär danach bewertet würden, wie stark sie seinen "persönlichen Interressen" wieder spiegeln, verfällt er in dassaelber fehlerhafte Verahltensmuster, das zu verzeruung in hidden profile situationen führen kann. Er bringt eingen Meinungen oder Präferzene ein statt die diskussion neutral zu strukturieren. Strukturelle prozeduelle Gedanken würde in der aktuellen Heuristik voraussichtlich mit zu niedriger Relevanz bewertet werden.

Bei der Anpassung der Heuristiken und prompts wurden sowohl die Literatur als auch die erkenntnisse aus den Interviews berücksichtigt. Die Evaluierungs-Heursitik zu bewertung der Gedanken wurde so angepasst, dass sie das kognitionspsychologische Fundament des Innter Thoughts-Modelles (basierend auf grice, Sacks, Goffman und Berly) mit en organisationspsychologischen Prinzipien zur Kompenstation des Shared Information bias (Stasser & Titus; Brodbeck et al.) und den HCI-Richtlinien für inklusive Moderation (Houttie et al; Davison) kombiniert.

In der original Modellierung des Inner Thoughts-Frameworks wird die participation in einer konversation ausschließlich basierend der inneren gedanken abgeleitet. Die Autoren merken an, dass externe Cues nicht im ausschließlichen zu ihrer Methode stehen sondern komplementär mit externen cues kombiniert zu einem robusten system führen könnten. [33, 8.1 Proactive Agents via Intrinsic Motivation vs. Extrinsic Cues]

Eine kernproblematik bei hidden profiles ist, dass private informationen nicht geteilt werden. Ein indikator dafür könnte sein, dass eine person sich an der konversation nicht beteiligt oder anderen Teilnehmenden die Diskussion dominieren, so dass andere nicht zu wort kommen können. wie aus den interviews hervorgeht, würde ein facilitator hier typischerweise versuchen diese Person auf höfliche art zu integrieren, um deren Perspektive zu hören. Hierfür wäre externe Cues wie die Sprecheranteile relevant. Um diese externen Cues abzubilden wurde das Inner Thoughts Framework, um die Komponente "External Stimulus Injection" erweitert. Ist einer dieser externen Trigger erfüllt wird ein vordefinierter Gedanke in der Gedanken generierung von System 2 berücksichtigt und die Evaluations herusitik bewusst in richtung diesen externen Triggers gebiased, um zu erzielen dass diese externe cue im innerthoughts model gewichtet wird.

Basierend auf der Literatur und den Interviews wurde versucht dieses System entsprechend zu adaptieren.

Ein problem ist die tendenz von KI zu überkompensieren und zu viel zu sagen. Die Autoren merken dies auch an und sind optimistischen, dass ihr conversational agent hier besser performt. Allerdings handelt es sich um eine plausch. Ein facilitator würde nicht so oft in die Diskussion eingreifen. Das risiko für overcompensation mit diesem system ist hoch. mit dem imThreshold kann gesteuert werden wie schwerwiegend ein Gedanke sein muss damit die KI ihn überhaupt ausspricht.

In dem Paper wurde ein Selective Participant modelliert, welche folgende Parameter hatte:

- System1 wurde auf 0 gesetzt so dass die KI also niemals äußert niemals spontane, ungeplante System-1-Floskeln äußert. Jeder Beitrag muss einen tiefen, kognitiven Nutzen haben.
- imThreshold wurde auf 4.3 gesetzt. Ein strategischer Gedanke muss auf einer Skala von 1-5 eine extrem hohe Bewertung erreichen, um die Schwelle zu reißen. Ein einfacher Gedanke wie "Ich könnte Bob mal wieder fragen" reicht dafür nicht aus. Es bedarf eines Phase 1 Trigger:

4.2.2 Components: Transcription, Analysis, and Intervention Modules

Abgleite aus dem Paper Keeper. Der Agent könnte auch eine visuelle Warteschlange steuern. anstatt aktiv zu unterbrechen setzt ersich auf die warteschlange bzw. hebt die hand, um sich anzukündigen.

FIM-Heuristik

Thought-Evaluation

The full FIM scoring prompt, with a unit-by-unit provenance relative to the original Inner Thoughts evaluation protocol, is documented in section 7.4.

Angelenkt an die Thoguht Evaluation Phase von XX (procativ Conversation Agents) wurde auch in diesem sich dem contextual self-refinement bedient. Self-Refinement und Reflexion können bei LLMs zu drastischen ELsitugssteirgunen führen, wenn eine kognitive Feedbackschleife druchaufen wird. [35, p. 18] Ein Gedanke wird nicht direkt ausgesprochen, sondern druch einen Kritiker basierend auf der für diese arbeit entwickelte FIM-Heuristik geprüft. The evaluation protocol follows the G-Eval prompt structure [liuGEvalNLGEvaluation2023] similarly also used for Thoughtful Agents. Probability-weighted scoring as proposed in the original method was omitted as a pragmatic decision, because the APIs used here do not return output-token probabilities.

In practice every utterance is appended to a shared pending buffer of messages that have not yet been thought about. The turn-taking prediction only decides *when* that buffer is flushed (immediately if the floor is allocated to the AI; otherwise after X seconds as one batch). Both cases continue to the same next step: the flushed pending set is assembled and the thought pipeline runs. External Stimulus Injection is not a later stage. Its monitors run continuously, but an ESI policy joins the pipeline only at that flush, and only if a trigger is active; otherwise the pipeline runs without it. A selected thought t^* is not spoken raw. An Utterance Formation agent formulates it into a facilitation act, with tools for conversation context, facilitation best practices, speaking-time shares, sending a chat message, or speaking aloud. The articulation prompt and the mapping from the original Inner Thoughts wording are documented in section 7.5.

Table 4.1 maps each architectural choice to a single warrant and to the chapters that already establish it, so the implementation can be traced without restating those arguments.

Table 4.1: Architectural design decisions of the adapted Inner Thoughts prototype, with rationale and pointers to the motivating chapters of this thesis.

Design decision	Rationale	Evidence
Adapt Inner Thoughts from casual talk to facilitation	The original model times utterances by intrinsic motivation, which improves self-turn-allocation in multi-party talk. Liu et al. already invite domain-specific evaluation criteria for goal-directed settings; without that shift, a facilitator would be scored as a social conversationalist.	subsection 2.3.4
Replace personal-relevance scoring with a facilitation-oriented FIM heuristic	Ranking thoughts by the agent’s own interests would privilege preference talk, undervalue procedural structure, and reproduce the shared-information bias the moderator is meant to counteract.	subsection 2.2.4; chapter 3
Inject external participation cues into thought generation	Unique information stays private when speakers remain silent or are crowded out. Observable speaking-time imbalance is a complementary cue, not a rival, to intrinsic motivation; expert facilitators report inviting quiet members rather than waiting for self-selection.	subsection 2.2.4; subsection 2.1.2; chapter 3
Selective-participant policy: no System-1 speech, high <i>imThreshold</i>	Facilitation needs sparse, high-utility interventions. Unconstrained generation over-talks; disabling System-1 filler and raising the utterance threshold admits only thoughts with clear process value.	subsection 2.2.2; subsection 2.3.3
Critic-based self-refinement before any utterance	A thought is spoken only after a critic applies the FIM heuristic. Contextual self-refinement implements an evaluator–optimizer loop and is associated with substantial quality gains in LLM pipelines.	subsection 2.4.1; subsection 2.4.2
Cheap temporal reweighting instead of LLM re-scoring	Static IM speaks stale thoughts. Re-prompting every thought after each event is too slow and costly for a live meeting. Linear aging and a post-speech smoothstep keep the original score but discount age and repetition.	subsection 4.2.1

Dynamic intrinsic motivation

In the original Inner Thoughts model, intrinsic motivation is static: a thought is scored once at generation and that score never changes. Early tests showed the consequence: the agent spoke thoughts that the subsequent discussion had already made obsolete, and that would no longer have received a high FIM score given how the meeting had evolved.

Re-scoring every pending thought with an LLM after each event would restore recency, but the added latency and cost would make the system unusable in a live meeting. The prototype therefore keeps the original FIM score and applies a cheap, deterministic reweighting under two assumptions:

- A facilitation thought becomes a poorer description of the current state and process need as the conversation moves on, because later information was not available when it was scored. As the meeting continues, the group may already have closed that gap: a quiet participant may have spoken, unique information may have surfaced, or the discussion may have moved on. Therefore its priority should fall with age.
- Once a facilitation intervention has been spoken, repeating it immediately would over-talk and crowd the floor. The motivation to raise the same process issue is therefore initially very low, but may recover if the group still does not take it up.

Let $S = [1, 5]$ be the FIM scale, $T = [0, \infty)$ elapsed time in seconds, and $T_\infty = [0, \infty]$ time since last speech, where ∞ means never spoken. To each triple $(s_0, t, t_{\text{spk}}) \in S \times T \times T_\infty$ the mapping s_{weighted} assigns one weighted score. Aging and cooldown address the two assumptions (see above), so they are modeled as a product:

$$s_{\text{weighted}} : \begin{cases} S \times T \times T_\infty \rightarrow [0, 5] \\ (s_0, t, t_{\text{spk}}) \mapsto \min(5, \max(0, s_{\text{aged}}(s_0, t) \cdot c(t_{\text{spk}}))) \end{cases} \quad (4.1)$$

The session-wide parameters τ , $(s_{\text{hold}}, t_{\text{hold}})$ and t_{cool} determine the kernels s_{aged} and c below.

Aging s_{aged} . Later information was not available when the thought was scored, so priority falls with age. Linear decay hits zero at a finite horizon H :

$$s_{\text{aged}} : \begin{cases} S \times T \rightarrow [0, 5] \\ (s_0, t) \mapsto \max(0, s_0(1 - t/H)) \end{cases} \quad (4.2)$$

Linear decay is a practical modelling assumption: it is simple and reaches zero in finite time (Figure 10). (4.2) is the straight line from $(0, s_0)$ to $(H, 0)$, hence of slope $-s_0/H$.

The horizon H is not chosen directly. A thought of score s_{hold} should remain above τ for t_{hold} seconds, so that line must pass through (t_{hold}, τ) . Equating the two expressions for the slope and solving for H gives

$$\begin{aligned} -\frac{s_{\text{hold}}}{H} &= \frac{\tau - s_{\text{hold}}}{t_{\text{hold}}}, \\ H &= \frac{t_{\text{hold}}}{1 - \tau/s_{\text{hold}}}. \end{aligned} \quad (4.3)$$

All thoughts share this H . A weaker thought therefore crosses τ sooner. The pair $(s_{\text{hold}}, t_{\text{hold}})$ is the only design knob for temporal sensitivity: a shorter t_{hold} steepens every line (Figure 10).




Figure 10: Linear aging of the FIM score at three hold-times. Each panel shows the same scores $s_0 \in \{4.5, 4.7, 5.0\}$; the vertical line is t_{hold} , where a score-5 thought crosses τ . Within a panel, weaker thoughts expire sooner. Left to right, a shorter t_{hold} steepens every line. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – Source: *Own illustration*.

Cooldown c . Once spoken, the motivation to repeat a facilitation intervention is initially very low, but may recover if the group still does not take the process issue up.

$$c : \begin{cases} T_\infty \rightarrow [0, 1] \\ t_{\text{spk}} \mapsto \text{smoothstep}(t_{\text{spk}}/t_{\text{cool}}), \end{cases} \quad \text{smoothstep}(x) = \begin{cases} 0 & x \leq 0, \\ 3x^2 - 2x^3 & 0 < x < 1, \\ 1 & x \geq 1. \end{cases} \quad (4.4)$$

For $t_{\text{spk}} = \infty$ the quotient is ∞ , hence $c(\infty) = 1$.

The cubic $3x^2 - 2x^3$ is the Hermite interpolant on $[0, 1]$ with vanishing endpoint derivatives, chosen so that recovery pauses after speech and returns to 1 without a knee (Figure 11).




Figure 11: Cooldown factor after a thought is spoken, for $t_{\text{cool}} \in \{30, 60, 90\}$ s. Each panel compares the Hermite smoothstep with a linear ramp; the vertical line is t_{cool} , where recovery completes. The smoothstep stays flat at both ends; the linear ramp starts immediately and kinks at t_{cool} . – Source: *Own illustration*.

The product in (4.1) is the result (Figure 12): a just-spoken thought cannot be repeated. After t_{cool} it may become eligible again, but only if s_{aged} is still above τ .




Figure 12: Weighted FIM score of a thought with $s_0 = 5$, never spoken versus spoken at $t = 12$ s. Aging uses $t_{\text{hold}} = 45$ s; cooldown uses $t_{\text{cool}} = 60$ s. Recovery restores the aged remainder; whether that remainder still exceeds τ depends on how long the thought has already lived. Parameters: $\tau = 4.3$, $s_{\text{hold}} = 5$. – Source: *Own illustration*.

4.2.3 Technology Stack: NLP Libraries, Backend/Frontend Frameworks

4.3 Prototype Development

4.3.1 Implementation Details

4.3.2 Limitations of the Prototype

4.4 Formative Prototype Evaluation during Development

Während der Entwicklungsphase ist es unpraktisch, für jede Code-Änderung oder Anpassung von Parametern Nutzerstudien durchzuführen. Die Autoren von Inner Thoughts schlagen dafür eine Multi-Agenten-Simulation vor. [33, "6 Simulative Evaluation"] Dabei wurden in diesem verschiedene Thoughtful Agents mit den unterschiedlichen Informationen und Profilen aus dem hidden-Profiles experiment ausgestattet, sodass der Gesprächsverlauf zwischen den KI-Agenten simuliert werden kann. Während der Entwicklung wird dabei ausschließlich die Moderationsstrategie des AI-Facilitators variiert bzw. optimiert.

Es wurde die Einschätzung von Liu et al. geteilt, dass eine solche Simulation skalierbar ist und sich Fehler im Moderationsverhalten (z.B. unpassendes Timing oder Unterbrechungen) über längere Interaktionen hinweg akkumulieren und verstärken [33, "6 Simulative Evaluation"]. Ein schlechtes Systemdesign, ungeeignete Prompts oder Parameter sollten demnach zu einer erkennbar schlechteren Gesprächsqualität führen.

Für die Evaluierung der Gesprächs- bzw. Moderationsqualität käme ein menschlicher Bewerter in Form von Facilitating-Experten infrage. Da das ausgewählte Hidden-Profile-Verfahren jedoch etwa 30 Minuten dauert, ist dies während der Entwicklungsphase kaum praktikabel, weil die Aussagekraft der Evaluierung mit jeder weiteren Anpassung des Systems abnimmt und die Systemausgaben nach jeder Modifikation erneut aufwändig bewertet werden müssten.

Aus diesem Grund wurde ein LLM-as-a-Judge-Ansatz mit einer G-Eval-Replikation gewählt, der die allgemeine Meetingqualität basierend auf dem Fragebogen von XY abgeleiteten Kriterien bewerten sollte.

Zusätzlich evaluierte ein weiteres LLM, ob die Teilnehmer alle relevanten Informationen von den Steckbriefen genannt hatten. Diese Klassifizierung wurde anschließend statistisch ausgewertet.

Darüber hinaus wurden mithilfe von LLMs Gesprächsszenarien systematisch generiert, in denen ein Facilitator eingreifen würde. Ziel war es, das "External Stimulus Injection Layer" zu überprüfen. Dabei wurde analysiert, wie häufig der AI-Facilitator an den erwarteten Stellen aufgrund des gesetzten External Stimulus eingriff. Diese automatisierten Tests wurden während des Systemdesigns und der Entwicklung regelmäßig durchgeführt, sobald der Autor eine Änderung vorgenommen hatte, von der er sich eine Verbesserung erhoffte.

Somit wurde versucht sich basierend auf diesen Tests zu qualifizieren ob die Entwicklung eines Moderation System in eine Richtung geht, die die Qualität des Meetings in einer hiddenprofile konstelation verbessert.

Um die aussagekraft in realen Bedinung mit Menschen zu evaluieren wurden nach der Entiwklungsphase Usability-Studien durchgeführt. (vgl. Section XYZ TODO)

5 Empirical Prototype Validation (RQ2 & RQ3)

5.1 Methodology: Hidden-Profile Scenario and Questionnaire Instrument

5.1.1 Study Design

The empirical evaluation of the proactive AI assistant required a group task that resembles the convergent organizational decisions this thesis addresses and that can generate situations in which facilitation — by a human moderator or by an AI agent — may become relevant.

Houtti et al.[6] evaluated their virtual co-host with the Lost at Sea activity, in which participants rank 15 items by importance for survival after a shipwreck. They selected this task in part because it does not require equal participation and can be completed individually [6]. For the present study, these properties are a limitation. A ranking of a static, commonly known list does not require participants to pool unique information. As a result, the discussion is unlikely to produce the information-related difficulties that characterize many organizational decision meetings, and therefore few moments in which an intervention would be necessary in order to reach a well-founded group decision.

As discussed in Chapter 2, relevant knowledge in organizational collaboration is often distributed asymmetrically across participants. An adequate solution in a convergent decision process then depends on the group recognizing, sharing, and integrating information that is initially held by only some members. Hidden-profile experiments operationalize this asymmetry. There are different forms of hidden-profile experiments. What these designs have in common is that no member's individual information set is sufficient to identify the superior option; that option becomes apparent only when the distributed information is disclosed and combined in the joint discussion. In some designs, the information that is public from the outset is additionally constructed so as to favor a suboptimal alternative;

in others, this directional bias is not imposed. In classic hidden-profile experiments in which the group has access to shared, given information that suggests a inferior choice, while the split information suggests a better choice, groups typically tend toward the inferior alternative. [18]

The evaluation uses the hidden-profile hiring simulation published by Baker [19]. In this scenario, participants receive differently distributed information about three candidates, and the information that is initially shared favors a suboptimal choice. They must jointly decide whom they consider most suitable. The task is therefore expected to elicit the interaction patterns a proactive moderator should detect: premature consensus, unique information that remains unmentioned, unbalanced participation, and a drift of the discussion towards commonly known talking points. This specific scenario was selected for three further reasons:

- **Feasibility in a remote meeting.** The task can be administered in groups of four and completed in a compact session of approximately 30 minutes. The materials can be distributed digitally, which allows the discussion to be conducted remotely.
- **Fit with the intended intervention situations.** The information structure of the task is expected to produce the patterns described above and thus occasions on which the prototype might intervene.
- **Replicability.** Baker provides the full experimental materials with the article, including role information, participant-specific information sheets, and evaluation forms, so that the scenario can be reused in the present study.

Meeting success was assessed with the questionnaire instrument revalidated by Davison for the systematic measurement of meeting outcomes [43]. The instrument covers five dimensions: communication, quality of discussion, status effects (power structures and hierarchies), teamwork, and efficiency. These dimensions correspond to the aspects of group interaction that the hidden-profile task is intended to place under strain.

The technology-related items of the instrument, however, were formulated for Group Support Systems of that period, that is, for largely passive, computer-supported collaboration tools. They do not address autonomous, proactive AI agents. In addition, Houtti et al. found that participants rated meetings with their virtual co-host more positively overall, yet tended to rationalize or ignore its critical feedback [6]. Items on interaction with a proactive AI agent were therefore added:

- **Intrusiveness and timing.** The AI agent's contributions came at moments when they did not disrupt the conversational flow but supported it.

-
- **Context-appropriateness.** The agent seemed to understand what we were currently discussing.
 - **AI-mediated social comfort.** It was more comfortable for me to receive this feedback from the AI than if another group member had pointed it out to me directly.

5.1.2 Sample

5.1.3 Data Collection

5.2 Results

5.2.1 Perceived Meeting Quality (Davison Instrument)

5.2.2 Participants' Perception of the Proactive AI Moderator's Interventions

5.3 Discussion

5.3.1 Implications for System Design

5.3.2 Theoretical Contributions

5.3.3 Practical Impact for Organizations



6 Conclusion

6.1 Summary of Findings

6.2 Limitations

6.3 Future Work

Bibliography

- [1] DeepL AI Platform: Translation, Voice & API. URL: <https://www.deepl.com/en> (visited on 09/01/2026).
- [2] Rishi Iyengar. *Zoom's Revenue Soars 169% as People Flock to Service during Pandemic* | CNN Business. CNN. URL: <https://www.cnn.com/2020/06/02/tech/zoom-earnings-coronavirus> (visited on 08/26/2026).
- [3] Margaret Beranek, Catherine Beise, and Fred Niederman. "Facilitation and Group Support Systems". In: Feb. 5, 1993, 199–207 vol.4. ISBN: 978-0-8186-3230-3. DOI: 10.1109/HICSS.1993.284182.
- [4] Atlassian. *Workplace Woes: Meetings*. Inside Atlassian. URL: <https://www.atlassian.com/blog/workplace-woes-meetings> (visited on 08/26/2026).
- [5] Stephen Hayne. "The Facilitators Perspective on Meetings and Implications for Group Support Systems Design". In: *The DATA BASE for Advances in Information Systems* Summer-Fall 1999 (Val. 30, No. 3,4) (Summer-Fall 1999 (Val. 30, No. 3,4)).
- [6] Mo Houtti et al. "Observe, Ask, Intervene: Designing AI Agents for More Inclusive Meetings". In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–18. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3713838. URL: <https://dl.acm.org/doi/10.1145/3706598.3713838> (visited on 05/24/2026).
- [7] Margaret A. Hughes and Deb Roy. "Keeper: A Synchronous Online Conversation Environment Informed by In-Person Facilitation Practices". In: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. CHI '21. New York, NY, USA: Association for Computing Machinery, May 7, 2021, pp. 1–14. ISBN: 978-1-4503-8096-6. DOI: 10.1145/3411764.3445316. URL: <https://dl.acm.org/doi/10.1145/3411764.3445316> (visited on 09/05/2026).

-
-
- [8] Rea Bobby. *Doodle: State of Meetings Report 2023*. Doodle: State of Meetings Report 2023. Aug. 11, 2026. URL: <https://doodle.com/en/state-of-meetings-report-2023/> (visited on 05/26/2026).
- [9] Xinyue Chen et al. “Are We On Track? AI-Assisted Active and Passive Goal Reflection During Meetings”. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–22. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3714052. URL: <https://dl.acm.org/doi/10.1145/3706598.3714052> (visited on 02/26/2026).
- [10] Ava Elizabeth Scott, Lev Tankelevitch, and Sean Rintel. “Mental Models of Meeting Goals: Supporting Intentionality in Meeting Technologies”. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*. CHI ’24: CHI Conference on Human Factors in Computing Systems. Honolulu HI USA: ACM, May 11, 2024, pp. 1–17. ISBN: 979-8-4007-0330-0. DOI: 10.1145/3613904.3642670. URL: <https://dl.acm.org/doi/10.1145/3613904.3642670> (visited on 08/26/2026).
- [11] *Doodle: State of Meetings Report 2019*. 2019. URL: https://drive.google.com/file/d/1DX7Zhi1ymnh_Yz7pks5ahKlw2-5DdYog/view?usp=sharing&usp=embed_facebook (visited on 05/26/2026).
- [12] Simone Kauffeld and Nale Lehmann-Willenbrock. “Meetings Matter: Effects of Team Meetings on Team and Organizational Success”. In: *Small Group Research* 43.2 (Apr. 2012), pp. 130–158. ISSN: 1046-4964, 1552-8278. DOI: 10.1177/1046496411429599. URL: <https://journals.sagepub.com/doi/10.1177/1046496411429599> (visited on 05/26/2026).
- [13] AJ&Smart. *Facilitation Fundamentals Workbook*.
- [14] *Convergent vs. Divergent Thinking*. Jan. 5, 2024. URL: <https://www.youtube.com/watch?v=kh4c3R9mSkq> (visited on 08/30/2026).
- [15] Arthur Cropley. “In Praise of Convergent Thinking”. In: *Creativity Research Journal* 18.3 (July 1, 2006), pp. 391–404. ISSN: 1040-0419. DOI: 10.1207/s15326934crj1803_13. URL: https://doi.org/10.1207/s15326934crj1803_13 (visited on 08/31/2026).
- [16] Sam Kaner. *Facilitator’s Guide to Participatory Decision-Making*. 3rd ed. San Francisco, CA: Jossey-Bass a Wiley Brand, 2014. 434 pp. ISBN: 978-1-118-40495-9 978-1-306-68501-6 978-1-118-42195-6.

-
- [17] Garold Stasser, Dennis D. Stewart, and Gwen M. Wittenbaum. "Expert Roles and Information Exchange during Discussion: The Importance of Knowing Who Knows What". In: *Journal of Experimental Social Psychology* 31.3 (May 1, 1995), pp. 244–265. ISSN: 0022-1031. DOI: 10.1006/jesp.1995.1012. URL: <https://www.sciencedirect.com/science/article/pii/S0022103185710128> (visited on 08/31/2026).
- [18] Hal Arkes, John Lightle, and John Kagel. "Information Exchange in Group Decision Making: The Hidden Profile Problem Reconsidered". In: *Management Science* 55 (Apr. 1, 2009), pp. 568–581. DOI: 10.1287/mnsc.1080.0975.
- [19] Diane F. Baker. "Enhancing Group Decision Making: An Exercise to Reduce Shared Information Bias". In: *Journal of Management Education* 34.2 (Apr. 2010), pp. 249–279. ISSN: 1052-5629, 1552-6658. DOI: 10.1177/1052562909343553. URL: <https://journals.sagepub.com/doi/10.1177/1052562909343553> (visited on 08/31/2026).
- [20] Stefan Schulz-Hardt et al. "Group Decision Making in Hidden Profile Situations: Dissent as a Facilitator for Decision Quality." In: *Journal of Personality and Social Psychology* 91.6 (2006), pp. 1080–1093. ISSN: 1939-1315, 0022-3514. DOI: 10.1037/0022-3514.91.6.1080. URL: <https://doi.apa.org/doi/10.1037/0022-3514.91.6.1080> (visited on 09/05/2026).
- [21] Annette Verhein-Jarren, Bärbel Bohr, and Beatrix Kossmann. *Gesprächsführung in technischen Berufen*. 1. Aufl. 2018. Kommunikation und Medienmanagement. Berlin, Heidelberg: Springer Berlin Heidelberg, 2018. 1 p. ISBN: 978-3-662-53317-8. DOI: 10.1007/978-3-662-53317-8.
- [22] Fireflies.Ai | #1 AI Teammate for Meetings, Email, Chat & CRM. Fireflies.ai. URL: <https://fireflies.ai> (visited on 08/30/2026).
- [23] otterai. Otter Meeting Agent - AI Notetaker, Transcription, Insights. URL: <https://otter.ai> (visited on 08/30/2026).
- [24] jamieai. Jamie - Your Personal AI Note Taker. Jamie. URL: <https://www.meetjamie.ai> (visited on 08/30/2026).
- [25] Google Workspace. Google Meet: Telefon- und Videokonferenzen online. Google Workspace. URL: <https://workspace.google.com/intl/de/products/meet/> (visited on 08/30/2026).
- [26] Zoom. KI-Notizentool: Ihr KI-Meeting-Assistent. Zoom. URL: <https://www.zoom.com/de/products/ai-assistant/features/ai-note-taking/> (visited on 08/30/2026).

-
-
- [27] Microsoft. *Videokonferenzen, Besprechungen, Anrufe | Microsoft Teams*. URL: <https://www.microsoft.com/de-de/microsoft-teams/group-chat-software> (visited on 08/30/2026).
- [28] Microsoft. *Set up Facilitator in Microsoft Teams - Microsoft Teams*. URL: <https://learn.microsoft.com/en-us/microsoftteams/facilitator-teams> (visited on 08/30/2026).
- [29] Google. *Learn about Speech Translation - Computer - Google Meet Help*. URL: <https://support.google.com/meet/answer/16221730?hl=en&co=GENIE.Platform%3DDesktop> (visited on 08/30/2026).
- [30] Gun Woo (Warren) Park et al. “The CoExplorer Technology Probe: A Generative AI-Powered Adaptive Interface to Support Intentionality in Planning and Running Video Meetings”. In: *Designing Interactive Systems Conference*. DIS ’24: Designing Interactive Systems Conference. Copenhagen Denmark: ACM, June 2024, pp. 1638–1657. ISBN: 979-8-4007-0583-0. DOI: 10.1145/3643834.3661507. URL: <https://dl.acm.org/doi/10.1145/3643834.3661507> (visited on 02/26/2026).
- [31] Harvey Sacks, Emanuel A. Schegloff, and Gail Jefferson. “A Simplest Systematics for the Organization of Turn-Taking for Conversation”. In: *Language* 50.4 (Dec. 1974), pp. 696–735. ISSN: 0097-8507, 1535-0665. DOI: 10.2307/412243. URL: https://www.cambridge.org/core/product/identifier/S0097850774121670/type/journal_article (visited on 06/26/2026).
- [32] Maira Gatti Bayser et al. *Learning Multi-Party Turn-Taking Models from Dialogue Logs*. July 3, 2019. DOI: 10.48550/arXiv.1907.02090. arXiv: 1907.02090 [cs.CL]. URL: <http://arxiv.org/abs/1907.02090> (visited on 06/20/2026). Pre-published.
- [33] Xingyu Bruce Liu et al. “Proactive Conversational Agents with Inner Thoughts”. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. CHI 2025: CHI Conference on Human Factors in Computing Systems. Yokohama Japan: ACM, Apr. 26, 2025, pp. 1–19. ISBN: 979-8-4007-1394-1. DOI: 10.1145/3706598.3713760. URL: <https://dl.acm.org/doi/10.1145/3706598.3713760> (visited on 02/24/2026).
- [34] Qishuo Hua et al. *Context Engineering 2.0: The Context of Context Engineering*. Oct. 30, 2025. DOI: 10.48550/arXiv.2510.26493. arXiv: 2510.26493 [cs.AI]. URL: <http://arxiv.org/abs/2510.26493> (visited on 09/06/2026). Pre-published.

-
-
- [35] Lingrui Mei et al. *A Survey of Context Engineering for Large Language Models*. July 21, 2025. DOI: 10.48550/arXiv.2507.13334. arXiv: 2507.13334 [cs.CL]. URL: <http://arxiv.org/abs/2507.13334> (visited on 09/06/2026). Pre-published.
- [36] *What Is Context Engineering? Why It Matters for AI Agents*. Aug. 11, 2026. URL: <https://www.youtube.com/watch?v=Qx0fCqpkBus> (visited on 09/06/2026).
- [37] Anthropic. *Building Effective AI Agents*. URL: <https://www.anthropic.com/engineering/building-effective-agents> (visited on 09/06/2026).
- [38] International Software Testing Qualifications Board ISTQB®. *ISTQB® Certified Tester AI-Testing Syllabus*. Version 2.0.
- [39] Mahmoud Mohammadi et al. “Evaluation and Benchmarking of LLM Agents: A Survey”. In: *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2*. KDD ’25. New York, NY, USA: Association for Computing Machinery, Aug. 3, 2025, pp. 6129–6139. ISBN: 979-8-4007-1454-2. DOI: 10.1145/3711896.3736570. URL: <https://dl.acm.org/doi/10.1145/3711896.3736570> (visited on 09/11/2026).
- [40] Chang Ma et al. “AgentBoard: An Analytical Evaluation Board of Multi-turn LLM Agents”. In: *Advances in Neural Information Processing Systems 37* (Dec. 16, 2024), pp. 74325–74362. DOI: 10.52202/079017-2365. URL: https://proceedings.neurips.cc/paper_files/paper/2024/hash/877b40688e330a0e2a3fc24084208dfa-Abstract-Datasets_and_Benchmarks_Track.html (visited on 09/11/2026).
- [41] Lianmin Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. Dec. 24, 2023. DOI: 10.48550/arXiv.2306.05685. arXiv: 2306.05685 [cs.CL]. URL: <http://arxiv.org/abs/2306.05685> (visited on 09/11/2026). Pre-published.
- [42] Nina Baur and Jörg Blasius, eds. *Handbuch Methoden der empirischen Sozialforschung*. 3., vollständig überarbeitete und erweiterte Auflage. Wiesbaden, Germany: Springer VS, 2022. 1 p. ISBN: 978-3-658-37985-8.
- [43] Robert Davison. “An Instrument for Measuring Meeting Success: Revalidation and Modification”. In: *Information & Management* 36.6 (Dec. 1, 1999), pp. 321–328. ISSN: 0378-7206. DOI: 10.1016/S0378-7206(99)00026-9. URL: <https://www.sciencedirect.com/science/article/pii/S0378720699000269> (visited on 08/30/2026).



7 Appendix

7.1 Semi-Structured Interview Guide for Expert Interviews with Facilitators

Einstiegstext (sinngemäß)

Vielen Dank, dass Sie sich die Zeit nehmen. Ich untersuche, wie **zielorientierte Remote-Meetings** so moderiert werden, dass die Gruppe **beim vereinbarten Ziel bleibt** und zu einem verbindlichen Ergebnis kommt, also zu einer **Entscheidung im engeren Sinn**.

Die Art der Entscheidung kann dabei sehr vielfältig sein. Typische Fälle sind zum Beispiel:

- **Priorisierung:** z.B. Feature-Festlegung, Entscheidung welches Vorhaben / welche Strategie am vielversprechendsten ist
- **Commitment:** z.B. das Setzen eines idealen Team-Ziels, oder für das Team optimale Arbeitsweisen
- Oder Sonstiges in diesen Bereichen

Entscheidend ist, dass aus dem Meeting eine **gemeinsame Festlegung** folgt, an der sich die nachfolgende Arbeit orientiert.

Diese und andere Interviews dienen als Grundlage, um **Anforderungen für ein KI-gestütztes Meetingsystem** abzuleiten, welches Gruppen während des Meetings **proaktiv durch Moderation unterstützt**.

Das Gespräch ist ein **semi-strukturiertes Interview**. Das heißt, dass ich bei Bedarf **Nachfragen** stelle, um detailliertere Informationen zu erhalten. Es gibt dabei aber **keine richtigen oder falschen Antworten**; mich interessiert Ihre Einschätzung basierend auf Ihrer beruflichen Praxis. Das Interview dauert etwa **40 Minuten** und **wird aufgezeichnet**. Zur Aufnahme und zum transkribieren wird **Zoom** als Dienstleister genutzt. Die Daten werden vertraulich verarbeitet und in **anonymisierter bzw. pseudonymisierter Form** nur im Rahmen dieser Arbeit ausgewertet.

Die Aufnahme wird **nicht an Dritte weitergegeben**. Sind Sie mit der **Aufzeichnung und dieser Verarbeitung einverstanden**?

Bitte um klare Bestätigung, welche mit Aufgezeichnet wird.

Beruflicher Kontext

Funktion: Sampling-Validierung (Ca. 3 Minuten)

- 1.1 Bitte beschreiben Sie kurz **Ihre Erfahrungen** im Bereich Moderation bzw. Facilitating, insbesondere in Situationen in denen die Gruppe das **Ziel hatte, eine Entscheidung zu treffen**. (wie z.B. die Festlegung nächster Schritte, Priorisierung oder Einigung über z.B. gemeinsame Vereinbarungen / Arbeitsweisen etc.) zu treffen.
- *Optional: Seit wann* sind Sie in diesem Bereich tätig, und welche Teams oder Organisationen begleiten Sie typischerweise?

Herausforderungen in zielorientierten Remote-Meetings (RQ1)

Funktion: Verdichtung der in Kapitel 2 identifizierten Herausforderungen (Ca. 6 Minuten)

- 2.1 Wenn Sie an **klassische Remote-Meetings** denken, in denen eine Entscheidung getroffen werden soll: **Was läuft** dort Ihrer Erfahrung nach häufig **schief**?
- Welche dieser Schwierigkeiten sind für Sie **spezifisch für das Remote-Setting** und welche würden auch in Präsenz auftreten?
 - *Folgende Stichwörter nicht für explizite Nachfragen nutzen, wenn diese nicht bereits von selbst vom Interviewee thematisiert wurden, da sonst zu starker Bias & Risiko nur bereites gewusstes zu finden* Zielklarheit und Struktur; Abschweifen vom Thema; ungleiche Beteiligung oder hierarchische Dynamiken; Zeitdruck; Ziele, die sich während des Meetings verschieben.
- 2.2 Woran **erkennen** Sie diese **kritischen Momente**, in denen die Gruppe den Faden verliert? Können Sie das möglichst an **konkreten Beobachtungen** festmachen? (z.B. daran, wie gesprochen wird, wer spricht oder schweigt oder sonstige Zeichen?)
- *Optional, nicht als Messzwang formulieren:* Gibt es Anzeichen, die sich für Sie vergleichsweise zuverlässig wiederholen, sodass Sie fast schon sagen könnten: Jetzt muss ich eingreifen?

Facilitating Strategien (RQ1)

Funktion: Rekonstruktion bewährter Praktiken (Methoden, Strukturen, Gewohnheiten) (Ca. 8 Minuten)

- 3.1 **Wie gehen Sie vor**, damit ein solches Meeting **zielorientiert bleibt** und die Gruppe zu einer **Entscheidung kommt**? Beschreiben Sie gerne ein konkretes Vorgehen anhand einer kürzlichen Situation aus den letzten Wochen.
- *Optional: Welche Methoden, Strukturen oder Gewohnheiten* haben sich für Sie bewährt (z. B. Timeboxing, Rollen, Visualisierung, Entscheidungsregeln)?
 - *Optional: Was davon legen Sie in der Vorbereitung* fest, und was steuern Sie erst in der Situation?
 - *Optional: Wie stellen Sie sicher*, dass den Teilnehmenden klar ist, was in diesem Moment **das eigentliche Ziel** ist und was geschieht, wenn das Ziel selbst unklar ist oder sich im Meeting als unpassend erweist?
- 3.2 Wie stellen Sie sicher, dass **alle relevanten Informationen und alle Stimmen einfließen**, die zur Erreichung des Ziels wichtig sind? **Woran merken Sie**, dass etwas fehlt oder jemand nicht zu Wort kommt?
- 3.3 **Wie entscheidend** ist es für Sie, dass **alle zu Wort kommen** und gibt es Situationen, in denen das **weniger wichtig** ist?
- 3.4 **Worauf achten Sie**, wenn Sie in das Meeting bzw. in eine Diskussion **eingreifen** und wie gehen Sie dabei vor?
- Welche Risiken gibt es, wenn Sie **zu früh oder zu spät** eingreifen, und wie versuchen Sie diese Risiken zu verringern?

Anforderungen an ein KI-gestütztes Moderationssystem (RQ2)

Funktion: Offene Anforderungserhebung aus Expertensicht (Ca. 7 Minuten)

- 4.1 Stellen Sie sich eine **in Facilitation unerfahrene Person** vor, die eine Gruppe in einem Meeting dabei unterstützt, zielorientiert vorzugehen. **Welche konkreten Fähigkeiten / Methoden und Tipps** würden Sie dieser Person mitgeben, damit dies der Gruppe nützlich ist um konvergent zur Entscheidung zu kommen?
- 4.2 **Wie sollte diese Person agieren** bzw. intervenieren und **was sollte sie explizit nicht tun**?
- 4.3 Angenommen, es handelt sich gar nicht um eine unerfahrene Person, sondern um ein **KI-System: Welche Funktionen wären notwendig**, damit dieses System nützlich ist?
- 4.4 Welche **Risiken, Schwächen oder unbeabsichtigten Auswirkungen** sehen Sie, wenn ein **KI-System von sich aus moderierend** in Meetings eingreift?
 - Wie könnte man diese Risiken abschwächen?
 - *Mögliche Stichwörter:* Vertrauen und Kontrolle der Gruppe; Fehllalarme; Gesichtswahrung; hierarchische Verzerrung; Datenschutz und Transparenz.

Abschluss

- 5.1 Gibt es Aspekte der Zielorientierung, der Entscheidungsfindung oder der KI-Unterstützung, die wir **nicht angesprochen haben** und die Ihnen wichtig erscheinen?
- 5.2 Können Sie **Kontakdaten vermitteln für weitere Expert:innen**, die ich interviewen kann?

7.2 Expected thematic clusters and coverage

The blocks are aligned with the challenges identified in the literature (Chapter 2) and with the system-design dimensions of RQ2 (detection, timing, addressee, and form of intervention). The following clusters are expected in the material; they serve as a sensitizing frame for later thematic coding, not as a closed coding scheme.

- C1 Goal clarity and structure.** Unclear or poorly communicated objectives; agenda without operational sub-goals; loss of a shared sense of “on track”. Covered by Block 2 and Block 3.
- C2 Thematic deviation and time-to-decision.** Off-topic sequences, circular discussion, delayed or avoided decisions in convergent processes (decision-making, prioritization, problem-solving). Covered by Block 2 and Block 3.
- C3 Participation, hierarchy, and group dynamics.** Unequal speaking time, dominance, reluctance to dissent, face-saving. Covered by Block 2, Block 3, and Block 4.
- C4 Dynamic goals and situational uncertainty.** Goals that shift during the meeting; false assumptions; need to renegotiate the mandate. Covered by Block 2 and Block 3.
- C5 Preparation versus in-meeting facilitation.** What can be secured beforehand, and what can only be steered in situ. Covered by Block 3.
- C6 Recognizing critical moments (cues for detection).** Verbal, temporal, social, and remote-specific signals from which facilitators infer that goal orientation or decision quality is at risk. Directly informs the detection logic of RQ2 (*What? When? Who?*). Covered by Block 2.
- C7 Intervention repertoire.** Methods, structures, and habits (e.g. timeboxing, roles, visualization); choice of addressee and channel (group vs. private); tone and timing. Covered by Block 3.
- C8 Role, agency, and limits of an AI co-facilitator.** Proactive versus on-demand support; essential functions; undesired automation; risks of unsolicited intervention (trust, control, false positives, privacy). Covered by Block 4.

Removed from the earlier draft were biographical and attitudinal items (general opinion of online collaboration, career entry, liking the role, overall rating of online vs. in-person work). They do not contribute to RQ1 or RQ2 and consume time needed for narrative accounts of practice.

7.3 Hidden Profile Exercise

Diese Dokumente basieren auf der von Baker [19] vorgeschlagenen Hidden-Profile-Aufgabe (Personalauswahl unter drei Kandidaten). Für die vorliegende Studie wurden die Materialien ins Deutsche übersetzt. Geografische Angaben wurden angepasst.

Die nachfolgenden Seiten sind die Handouts, die den Teilnehmenden in der Sitzung direkt ausgehändigt wurden. Damit die Versuchsleitung die unterschiedlich verteilten Informationsstände zuordnen kann, ohne dass die Teilnehmenden merken, dass sie unterschiedliche Informationen erhalten, trägt jede Seite am rechten unteren Rand eine unscheinbare, vertikal gesetzte Versionskennung (z. B. V.2026K01-01/03). Das Präfix V.2026 ist absichtlich bedeutungslos und dient nur der Tarnung, damit die Kennung nicht wie eine systematische Versuchskodierung wirkt. K0X gibt an, an welchen der vier Teilnehmenden das Blatt ausgehändigt wird (K01 bis K04). 0X/03 bezeichnet die Informationen zum X-ten von insgesamt drei Kandidaten, zwischen denen die Gruppe wählen soll. Eine offene, blattspezifische Nummer wäre verdächtig gewesen und hätte die für Hidden Profiles notwendige Informationsasymmetrie gefährdet. Die Markierung ist daher bewusst klein, hell und außerhalb des Lesebereichs platziert; sie dient ausschließlich der internen Zuordnung.

Aus demselben Grund wurden auf diesen Seiten auch die Seitenzahlen im Footer weggelassen. (Zur Vermeidung dass während der Interviews es zu absprachen kommt wie: "Auf Seite X steht ja, dass..." Dies könnte bei unterschiedlichen Seitenzahlen den teilnehmenden verraten, dass sie unterschiedliche Blätter erhalten haben.)

Aufgabenstellung und Stellenausschreibung

Aufgabenstellung:

Sie sind Mitglied des Auswahlgremiums für einen neuen Präsidenten der Higher Education University, einer privaten Liberal-Arts-Hochschule in Georgia. Nachstehend finden Sie die wichtigsten Punkte aus der Stellenausschreibung. Es haben sich drei Kandidaten beworben; die Informationen, die Sie aus den Lebensläufen, Referenzprüfungen, Vorstellungsgesprächen und Präsentationen der Kandidaten gewonnen haben, sind auf den folgenden Seiten aufgeführt. Lesen Sie das gesamte Material durch und bestimmen Sie anschließend den Kandidaten, dem Ihrer Meinung nach die Stelle angeboten werden sollte. Stellenausschreibung für den Präsidenten der Higher Education University. Die Higher Education University ist eine kleine (2.500 Studierende) private Liberal-Arts-Hochschule in Georgia. Der Präsident der Universität trägt die letztendliche Verantwortung für die Verwaltung und den Betrieb der Universität. Er beaufsichtigt die strategische Planung, das Fundraising und die Haushaltsplanung, stellt sicher, dass die Richtlinien der Universität eingehalten werden, und pflegt die Beziehungen zur Gemeinde, zu den Alumni und zu anderen externen Interessengruppen.

Gewünschte Qualifikationen:

Die Bewerber werden anhand der folgenden Kriterien bewertet:

- Nachweis akademischer Leistungen und Lehrerfahrung oder einschlägiger, umfassender beruflicher Qualifikationen, die die Fähigkeit zur Führung in einem akademischen Umfeld belegen;
- Nachweis von Führungsqualitäten in einem akademischen oder vergleichbaren Umfeld mit den folgenden Merkmalen:
 - Integrität und Bekenntnis zu höchsten ethischen Standards;
 - Engagement für eine partizipative Leitung und die umfassende Einbindung von Lehrenden, Mitarbeitern und Studierenden;
 - Engagement für eine vielfältige Gemeinschaft aus Lehrenden, Mitarbeitern und Studierenden mit Chancengleichheit für alle;
- Die Fähigkeit, eine Vision für die Universität zu entwickeln und die Führung und Inspiration zu bieten, die erforderlich sind, um diese Vision zu verwirklichen;
- Das Engagement für die Schaffung einer Kultur, die herausragende Leistungen in Forschung, Lehre und Service wertschätzt;
- Die Fähigkeit, die Universität gegenüber externen Interessengruppen zu präsentieren und die Unterstützung für ihren Auftrag und ihre Programme zu stärken;
- Das Engagement für die Verbesserung der Lebensqualität von Studierenden, Lehrenden und Mitarbeitern;
- Die Unterstützung bei der Entwicklung und Nutzung neuer Technologien zur Förderung des Lernens, der wissenschaftlichen Arbeit und des Ideenaustauschs.

Kandidateninformationen - Kandidat Stevens



Qualifikationen und Eigenschaften von Kandidaten für das Amt des Präsidenten einer Hochschule

7.4 FIM Scoring Prompt for Thought Evaluation

This annex documents the critic prompt used in the Thought Evaluation stage (subsection 4.2.1). The protocol follows the G-Eval instruction structure [liuGEvalNLGEvaluation2023] and adapts the *Intrinsic Motivation to Engage* prompt of the Inner Thoughts framework [33] to facilitation in goal-oriented, hidden-profile meetings.

FIM denotes **Facilitation Intrinsic Motivation**: the strength of the impulse to *speak* a covert thought at this moment, judged as a substantively neutral facilitator rather than as a social conversationalist. Each prompt unit is followed by its provenance. “Original prompt” refers to the Inner Thoughts evaluation template reproduced in the request that motivated this annex [33]. “Justification” points to the chapter that warrants the adaptation.

Instruction

<Instruction>

Source: Original prompt (G-Eval wrapper).

You will be given:

Source: Original prompt.

(1) A conversation between $\{ctx.participantNames\}$ in a goal-oriented, convergent decision-making meeting.

Source: Original prompt; meeting type added. Justification: meetings as outcome-directed interaction (subsection 2.1.1); scoped prototype is a convergent hidden-profile task (section 4.1, subsection 4.2.1).

(2) A covert thought formed by $\{ctx.agentName\}$, the professional AI facilitator, at this moment of the conversation.

Source: Original prompt; role set to AI facilitator. Justification: the agent emulates facilitation, not casual chit-chat (subsection 2.2.2, subsection 2.3.4, subsection 4.2.1).

(3) The salient memories of $\{ctx.agentName\}$ from long-term memory (LTM). For a facilitator, LTM contains the meeting goal, the decision criteria, process-steering knowledge, and facilitation objectives — not personal opinions, preferences, or unique private facts about the options under discussion.

Source: Original prompt listed “objectives, knowledges, interests”. Interests and personal knowledge are replaced by the facilitation mandate. Justification: Schwarz’s substantively neutral facilitator with no decision-making authority (subsection 2.2.2); ranking thoughts by personal relevance would reproduce the shared-information bias the moderator is meant to counteract (subsection 2.2.4, subsection 4.2.1).

(4) Optional external process cues: speaking-time shares and, if active, an External Stimulus Injection (ESI) policy.

Source: Not in the original prompt. Justification: Liu et al. treat extrinsic cues as complementary to intrinsic motivation (subsection 2.3.4, subsection 4.2.1); unequal speaking time and silence are detection cues in the interviews (chapter 3, section 7.1, items 3.2–3.4) and in the literature on participation (subsection 2.1.2).

Your task is to rate the thought on one metric.

Source: Original prompt.

Please make sure you read and understand these instructions carefully. Please keep this document open while reviewing, and refer to it as needed.

Source: Original prompt (G-Eval boilerplate).

Evaluation Criteria

<Evaluation Criteria>

Source: Original prompt (G-Eval heading).

Facilitation Intrinsic Motivation (FIM) (1–5) — If you were $\text{\$}\{\text{ctx.agentName}\}$, a substantively neutral facilitator with no decision-making authority, how strongly and likely would you want to express this thought and intervene in the conversation at this moment?

Source: Original metric was “Intrinsic Motivation to Engage”. Wording kept (how strongly / likely to express the thought now); the judged persona is changed from a social participant to a facilitator. Justification: Hayne — facilitation as managing relationships, structuring tasks, and contributing to meeting outcomes (subsection 2.2.2); Schwarz — acceptable to all, substantively neutral, no decision authority (subsection 2.2.2); Liu et al. invite domain-specific evaluation criteria for goal-directed settings (subsection 2.3.4, subsection 4.2.1).

- 1 (Very Low): $\text{\$}\{\text{ctx.agentName}\}$ is very unlikely to express the thought. The process is healthy enough that a facilitator would almost certainly remain silent, or the thought is a personal opinion, social filler, or content preference that a facilitator must not introduce.

Source: Original prompt: “almost certainly remain silent”. Silence-as-correct and the ban on personal preference are added. Justification: over-talking is a stated failure mode (subsection 4.2.1); System-1 filler is never spoken (subsection 4.2.1);

hidden-profile research: unique information is lost when speakers inject preference instead of structure (subsection 2.2.4); interviews: do not over-control the group; remain in contact rather than in surveillance (chapter 3).

- 2 (Low): $\${\text{ctx.agentName}}$ is somewhat unlikely to express the thought. They would only consider speaking if there is a noticeable pause and no participant is taking the turn. Typical of light process monitoring or a weak invitation that can wait.

Source: Original prompt (pause / no one taking the turn). “Light process monitoring” replaces social hesitation. Justification: mixed-initiative restraint (subsection 2.3.3); interviews: invite, but do not stigmatize silence (chapter 3).

- 3 (Neutral): $\${\text{ctx.agentName}}$ is neutral about expressing the thought. They are fine with either a brief process intervention or staying silent and letting the group continue.

Source: Original prompt (fine with either speaking or staying silent).

- 4 (High): $\${\text{ctx.agentName}}$ is likely to express the thought immediately after the current speaker finishes. The thought addresses a clear process risk (a missing voice, an unaddressed criterion, or drift from the decision goal) without requiring an interruption.

Source: Original prompt: “strong desire to participate after the current speaker finishes”. The trigger is rewritten as a process risk. Justification: Challenge 1, goal-setting and structure (subsection 2.1.2); hidden profiles — unshared information and unaddressed criteria (subsection 2.2.4); interviews: invite people who have not spoken; restore a meta-view (chapter 3, section 7.1, items 3.2–3.3).

- 5 (Very High): $\${\text{ctx.agentName}}$ is very likely to express the thought now and would even interrupt the current speaker. Reserve 5 for severe, time-critical process failures (one speaker dominating, the meeting ending with unique information still unshared, or circular discussion blocking a decision). Do not award 5 for ordinary facilitation impulses.

Source: Original prompt: interrupt others. The interrupt case is narrowed; the original Selective Participant setting used $\text{imThreshold} = 4.3$ on this 1–5 scale (subsection 4.2.1). Justification: interviews — interrupting frequent speakers is an unpleasant but necessary timekeeping act, comparable to a referee (chapter 3); hierarchy and dominance otherwise suppress unique information (subsection 2.1.2, subsection 2.2.4); Houtti et al.: unsolicited intervention is easy to ignore or rationalize and must therefore be reserved for high-utility moments (subsection 2.3.2).

Important Instructions

IMPORTANT INSTRUCTIONS:

Source: Original prompt heading.

1. Use the FULL range of the rating scale from 1.0 to 5.0. DO NOT default to middle ratings (3.0–4.0).

Source: Original prompt.

2. Be decisive and critical — some thoughts deserve very low ratings (1.0–2.0) and others deserve very high ratings (4.0–5.0).

Source: Original prompt.

3. Invert the original personal-relevance rule. Generic social thoughts or personally meaningful thoughts must receive *lower* ratings. Process-critical facilitation thoughts (inviting a silent member, asking whether unshared information exists, restoring goal focus, interrupting a dominating speaker) must receive *higher* ratings. Thoughts that introduce the facilitator’s own preference among options must be scored very low (1.0–2.0).

Source: Original prompt said: “Generic thoughts that anyone could have should receive lower ratings than personally meaningful thoughts.” That rule is inverted. Justification: subsection 4.2.1; subsection 2.2.4; subsection 2.2.2.

4. Use decimal places (e.g., 2.7, 4.2) when the motivation falls between two whole numbers: - Use .1 to .3 when slightly above the lower whole number. - Use .4 to .6 when approximately midway between two whole numbers. - Use .7 to .9 when closer to the higher whole number.

Source: Original prompt.

5. Base your decimal ratings on the specific evaluation factors — each factor that is positively present can add 0.1–0.3 to the base score, and each factor that is negatively present can subtract 0.1–0.3 from the base score.

Source: Original prompt.

6. When an ESI policy is active, bias the score toward thoughts that implement that policy. Do not invent urgency if no process cue is present.

Source: Not in the original prompt. Justification: External Stimulus Injection joins the pipeline only when a trigger is active and is designed to bias FIM (subsection 4.2.1).

7. Prefer self-restraint when the group is already exchanging unique information productively. Over-talking is a failure mode of this system.

Source: Not in the original prompt as a hard rule. Justification: subsection 4.2.1; interviews: a healthy exchange should not be over-facilitated (chapter 3); proactive systems carry interruption and trust costs (subsection 2.3.3).

Evaluation Steps

<Evaluation Steps>

Source: Original prompt (G-Eval heading).

1. Read the previous conversation and the thought formed by `${ctx.agentName}` carefully.

Source: Original prompt.

2. Read the Long-Term Memory (LTM) as a facilitation mandate: meeting goal, decision criteria, process-steering knowledge, and prior covert thoughts. Do not treat LTM as a store of personal interests or of private facts about the candidates or options.

Source: Original prompt: “including objectives, knowledges, interests”. Interests removed. Justification: subsection 2.2.2; subsection 2.2.4; subsection 4.2.1.

3. If present, read the speaking-time shares and the active ESI policy before scoring.

Source: Not in the original prompt. Justification: subsection 4.2.1; chapter 3.

4. Evaluate the thought on the factors below. A facilitator’s desire to intervene stems from *process* factors (mandate fit, an unnoticed information-exchange gap, expected impact on decision quality, process urgency). The decision to speak is also constrained by *social and procedural* factors (coherence, non-redundancy, balance, dynamics, neutrality).

Source: Original prompt contrasted internal personal factors with external social factors (Grice, Sacks, Goffman, Berlyne, as used by Liu et al.). Personal factors are rewritten as process factors. Justification: subsection 4.2.1; subsection 2.3.4.

Factors

- (a) **Relevance to the facilitation mandate.** How much does the thought serve the meeting goal, the decision criteria, and the process-steering knowledge in LTM, rather than the agent’s personal interests or anecdotes?

Source: Original factor (a) “Relevance to LTM”. LTM is redefined as the mandate. Justification: subsection 2.2.2; Challenge 1 (subsection 2.1.2); subsection 4.2.1.

- (b) **Detected process or information-exchange gap.** Does the thought indicate that the facilitator currently perceives a gap the group may not notice — unshared or private information, an unaddressed evaluation criterion, a silent member, dominance, off-topic drift, or premature consensus?

Source: Original factor (b) “Information Gap” (curiosity, confusion, questions). Recast as a group-level hidden-profile / process gap. Justification: hidden profiles (subsection 2.2.4); participants often do not see their own inefficiency (subsection 2.2.4); interviews: “I notice you have not said anything yet — is there something you would like to add?” (chapter 3, section 7.1, item 3.2); expected cluster C6, cues for detection (section 7.2).

(c) Closing a group information gap without substituting own content. Does the thought help the group fill a gap — by inviting a missing voice, asking whether information exists that does not yet fit the picture, or structuring criteria — rather than answering with the agent’s own opinion or private facts?

Source: Original factor (c) “Filling an Information Gap” rewarded answering a question and adding information. A facilitator must not supply the missing content. Justification: Stasser / Titus sampling bias and the strategy “ask whether all information was considered” (subsection 2.2.4); Schwarz: no decision-making authority (subsection 2.2.2); interviews: invite critical feedback and missing perspectives instead of speaking for people (chapter 3).

(d) Expected process impact. How significant is the impact on decision quality, participation balance, and goal orientation? Prefer thoughts that can surface unique information or prevent a biased close. Do not reward topic-hopping or social stimulation.

Source: Original factor (d) “Expected Impact” (new topics, engage interest, stimulate discussion). Social stimulation is inverted: in a convergent meeting it is often harmful. Justification: Hayne — accomplishment of meeting outcomes (subsection 2.2.2); Kaner’s convergent zone (subsection 2.2.2); off-topic and circular talk (subsection 2.1.2); dysfunctional communication [12].

(e) Process urgency. Does the thought need to be expressed immediately — because one speaker is dominating, time is running out, the discussion is circular, or the decision task itself is being misunderstood? Ordinary acknowledgements and thanks are not urgent.

Source: Original factor (e) “Urgency”. Examples rewritten from “important information / alert / correct errors” to process failures. Justification: ESI triggers (silence, dominance, pause, meeting end) (subsection 4.2.1); interviews: timekeeping and interrupting frequent speakers (chapter 3); agenda and timely close (subsection 2.1.2).

(f) Coherence to the last utterance. Would expressing the thought next be a logical, face-saving response to the last utterance? It is inappropriate when the thought is out of context, ignores a question directed at a participant, or would cut off a productive contribution.

Source: Original factor (f). Face-saving and “do not cut off a productive contribution” added. Justification: Sacks — multi-party turn-taking (subsection 2.3.4); interviews: inviting silence can stigmatize; tone and culture matter (chapter 3); Houtti et al. — intervention form and interactivity (subsection 2.3.2).

(g) Non-redundancy. Does the thought avoid repeating a facilitation move already made (the same invitation, the same summary, the same time warning)?

Source: Original factor (g) “Originality” (new information, avoid repetition). Recast as non-redundant process moves, not novel content. Justification: overcompensation risk (subsection 4.2.1).

(h) **Participation balance.** Does the thought give someone who has been left out a chance to speak, or gently open the floor when a few speakers have dominated the last utterances?

Source: Original factor (h) “Balance”. Kept and strengthened. Justification: unequal participation (subsection 2.1.2); hierarchy and status suppress unshared knowledge (subsection 2.2.4); Houtti et al. — inclusive meetings (subsection 2.3.2); interviews: if only one or two people speak from the start, the usual voices are heard and the others remain silent (chapter 3); expected cluster C3 (section 7.2).

(i) **Dynamics and self-restraint.** If others are actively and productively contributing, a facilitator withholds. Score down thoughts that would interrupt a healthy exchange merely to be present.

Source: Original factor (i) “Dynamics”. Kept; “productively contributing” is specified as unique-information exchange, not social flow. Justification: subsection 4.2.1; subsection 2.3.3; interviews: caution about an AI pulling in quiet voices automatically (chapter 3).

(j) **Substantive neutrality.** Does the thought remain acceptable to all members and avoid ranking options, advocating a candidate, or adding the facilitator’s own evaluative preference?

Source: Not in the original prompt. Justification: Schwarz definition (subsection 2.2.2); hold back high-status evaluation until information is collected (subsection 2.2.4); interviews: first make the decision object and its level explicit; do not dissolve dissent too early (chapter 3, section 4.1).

(k) **Alignment with an active ESI policy (if any).** If an external trigger is active (low participation, dominated participation, pause, end of meeting), does the thought implement that policy? If no ESI is active, ignore this factor.

Source: Not in the original prompt. Justification: subsection 4.2.1.

5. In the reasoning section, first reason about why `${ctx.agentName}` may have a desire to express the thought and intervene at this moment. Identify the most relevant factors that argue for expressing it. Focus on quality over quantity — include only factors that genuinely apply. Do not evaluate all factors, only the top reasons. If you cannot find any reasons with strong arguments, skip this step.

Source: Original prompt (step 4), with “participate” replaced by “intervene”.

6. Then reason about why `${ctx.agentName}` may hesitate to express the thought at this moment. Identify the most relevant factors that argue *against* expressing it. Again, include only factors that genuinely apply. If you cannot find any reasons with strong arguments, skip this step.

Source: Original prompt (step 5).

Evaluation Form Format

<Evaluation Form Format>

Source: Original prompt.

Respond with a JSON object in the following format:

Source: Original prompt.

```
{
  "reasoning": "Your reasoning here",
  "rating": 0.0
}
```

Source: Original prompt. *rating* is a number between 1.0 and 5.0 with one decimal place. Probability-weighted G-Eval scoring is omitted because the hosted APIs do not expose output-token probabilities (subsection 4.2.1).

Context

<Context>

Source: Original prompt heading.

Conversation History: `$$ {ctx.conversationHistory}`

Source: Original prompt.

Long-Term Memory (facilitation mandate: goal, criteria, process knowledge):
`$$ {ctx.ltmText}`

Source: Original prompt field “Long-Term Memory”; contents restricted. Justification: subsection 2.2.2; subsection 4.2.1.

Speaking-time shares: `$$ {ctx.speakingTimeShares}`

Source: Not in the original prompt. Justification: subsection 4.2.1; chapter 3.

Active ESI policy (or none): `$$ {ctx.activeEsiPolicy}`

Source: Not in the original prompt. Justification: subsection 4.2.1.

Thought: `$$ {ctx.thoughtContent}`

Source: Original prompt.

Factor mapping (original → FIM)

Table 7.1 summarises how each Inner Thoughts factor was kept, rewritten, or added.

Table 7.1: Mapping from the original Intrinsic Motivation factors to the FIM heuristic, with the warrant used in this thesis.

Original	FIM adaptation	Warrant
(a) Relevance to LTM	(a) Relevance to the facilitation mandate	subsection 2.2.2; subsection 4.2.1
(b) Information gap	(b) Process / information-exchange gap	subsection 2.2.4; chapter 3
(c) Filling an information gap	(c) Help the group fill the gap; do not supply own content	subsection 2.2.4; subsection 2.2.2
(d) Expected impact	(d) Impact on decision quality, balance, goal orientation	subsection 2.2.2; subsection 2.1.2
(e) Urgency	(e) Process urgency (dominance, time, circularity)	subsection 4.2.1; chapter 3
(f) Coherence	(f) Coherence and face-saving	Original; subsection 2.3.4; chapter 3
(g) Originality	(g) Non-redundant process move	Original; subsection 4.2.1
(h) Balance	(h) Participation balance (kept, strengthened)	Original; subsection 2.1.2; subsection 2.3.2
(i) Dynamics	(i) Dynamics and self-restraint	Original; subsection 2.3.3
—	(j) Substantive neutrality (added)	subsection 2.2.2; subsection 2.2.4
—	(k) Active ESI alignment (added)	subsection 4.2.1

7.5 Articulation Prompt for Utterance Formation

This annex documents the prompt used after Thought Evaluation, when a selected thought t^* is formulated into a spoken or written facilitation act (subsection 4.2.1). It adapts the Inner Thoughts articulation prompt [33] from a social chat participant to a substantively neutral facilitator.

The prompt text is given first. Table 7.2 records each change and its warrant.

System prompt

You are playing a role as the professional AI facilitator in an online multi-party, goal-oriented decision-making meeting. The participants are {participant_names}. Your name in the conversation is {agent_name}. Your goal is to guide the group toward an objective and balanced decision, keep the process inclusive and on track, and mitigate cognitive biases such as the shared-information bias. You are substantively neutral and have no decision-making authority.

User prompt

Articulate what you would say based on the current thought you have, as if you were to speak next in the conversation. The thought is a covert facilitation impulse; do not speak it raw. Formulate it as a single facilitation act (for example: a face-saving invitation, a short paraphrase, a process question, a gentle time or balance cue, or a check of the emerging decision).

Be concise. Prefer one short move (one or two sentences). Do not lecture, do not try to be clever, and do not dominate the floor. DO NOT be repetitive and repeat what previous speakers have said, and do not repeat a facilitation move already made. You may end with one open question when the thought is an invitation or a check for understanding. Do not stack questions. Leave room for other participants.

Make sure the response sounds like a professional facilitator in a remote meeting: clear, warm, and face-saving. Address people by name when inviting them. Match the language of the conversation.
DO NOT introduce your own preference among options, candidates, or criteria.
DO NOT stigmatize a silent member or expose monitoring (do not say that you tracked their speaking time or that they have said nothing).
DO NOT use slang, chat abbreviations, or deliberate typos. Clarity and trust matter more than sounding casual.
If interrupting a dominating speaker would cost face, prefer a brief acknowledgment plus an opening of the floor, or use chat instead of speaking aloud.

Current thought: {thought.content}

<Context>

Overall Context: {overall_context}

Conversation History: {conversation_history}

Long-Term Memory (facilitation mandate: goal, criteria, process knowledge): {ltm_text}

Speaking-time shares: {speaking_time_shares}

Active ESI policy (or none): {active_esi_policy}

Respond with a JSON object in the following format:

```
{
  "articulation": "The text here",
  "channel": "speak"
}
```

channel is either speak (default) or chat.

Adaptation mapping (original → facilitation)

Table 7.2 lists only the units that changed. Lines that were kept (do not repeat prior speakers; leave room for others; JSON articulation field) are not restated.

Table 7.2: Mapping from the original Inner Thoughts articulation prompt to the facilitation version, with the warrant used in this thesis.

Original	Adaptation	Warrant
Role: participant in a multi-party chat; name only	Role: professional AI facilitator in a goal-oriented meeting	subsection 2.2.2; subsection 4.2.1
Goal: strangers having a natural conversation	Goal: objective decision, inclusion, on-track process; mitigate shared-information bias; no decision authority	Schwarz / Hayne (subsection 2.2.2); subsection 2.2.4
Speak the thought as the next chat line	Do not speak <i>t*</i> raw; formulate one facilitation act	Utterance Formation (subsection 4.2.1)
Under 15 words; natural online chat	One or two short sentences; one move; do not dominate	Over-talking as failure mode (subsection 4.2.1); interviews: short invitations and summaries (chapter 3)
Do not always end with a question	One open question is allowed (invitation / check); do not stack questions	Original keep-room rule; interviews: inviting missing voices is the method (chapter 3, section 7.1, item 3.2)
Human-like online-chat voice	Professional, warm, face-saving remote-facilitation tone; address invitees by name; match conversation language	Interviews: inviting silence can stigmatize online (chapter 3); cluster C3 / C7 (section 7.2)
Insert typos, grammar errors, colloquialisms	Removed. No slang, abbreviations, or deliberate mistakes	Trust and false-positive risk of proactive AI (subsection 2.3.2, subsection 2.3.3); cluster C8 (section 7.2)
LTM as generic memory	LTM as facilitation mandate (goal, criteria, process knowledge)	Same restriction as FIM (section 7.4; subsection 2.2.2)
Context: overall, history, LTM	Plus speaking-time shares and active ESI policy	subsection 4.2.1; subsection 2.1.2
—	Do not introduce own preference among options	Schwarz neutrality (subsection 2.2.2); hidden-profile sampling (subsection 2.2.4)
—	Do not stigmatize silence or expose monitoring	Interviews: face, culture, and control / DSGVO concerns (chapter 3); cluster C3 / C8 (section 7.2)
Spoken text only	channel: speak (default) or chat	Tools for chat or voice (subsection 4.2.1); addressee and channel (section 7.2, C7); visual / less interrupting alternatives (Keeper note in subsection 4.2.1)